Apuntes de Probabilidad y Estadística

Álvaro Mattus Donaire

1 de mayo de 2026

Notas personales

Índice general

Índice general **ii**

1 ¿Qué probabilidad hay? 1
1.1 Introducción . . . 1
1.2 Eventos, espacios muestrales y probabilidad . . . 3
1.3 Probabilidad condicional . . . 4
1.4 Principio multiplicativo . . . 5
1.5 Independencia . . . 7
1.6 Principio aditivo . . . 9
1.7 Preguntas frecuentes . . . 13
1.7.1 Una nota sobre visualización de eventos . . . 14
1.8 Conteo . . . 16
1.8.1 Permutaciones . . . 18
1.8.2 Combinaciones . . . 19
1.8.3 Algunos casos extra . . . 20

2 Probabilidades++ 23
2.1 Axiomas de probabilidad . . . 23
2.2 Teorema de Bayes . . . 24
2.2.1 Enfermedades y exámenes . . . 29
2.2.2 Odds . . . 31

3 ¡Resultados! ¡Resultados! ¡Resultados! 34
3.1 Introducción . . . 34
3.2 Variables aleatorias discretas . . . 37
3.3 Variables aleatorias continuas . . . 39
3.4 Esperanza y varianza . . . 40
3.4.1 Definición de la esperanza y sus propiedades . . . 40
3.4.2 Definición de la varianza y sus propiedades . . . 45
3.5 ¿Qué significa sumar variables aleatorias? (opcional) . . . 48

4 El zoológico de las variables aleatorias, parte 1 54
4.1 Distribución de Bernoulli . . . 54
4.2 Variables aleatorias discretas y su relación con VAs Bernoulli 56
4.3 Distribución binomial . . . 59

4.4 Distribución geométrica 63
4.4.1 Otra forma de escribir la distribución geométrica . . 66
4.5 Distribución binomial negativa 67
4.6 Distribución hipergeométrica 70
4.7 Distribución de Poisson 71

5 El zoológico de las variables aleatorias, parte 2 75
5.1 Distribución uniforme 75
5.2 Distribución exponencial 78
5.3 Distribución normal 82
5.3.1 Trabajando con la distribución normal 85
5.3.2 Tablas para la distribución normal estándar 88
5.4 Distribución χ^2 92
5.5 Distribución t 94

6 ¿Qué dicen los datos? 97
6.1 Señal versus ruido 98
6.2 Encontrando señales: las medidas de tendencia central . . . 98
6.3 Midiendo el ruido: las medidas de dispersión 103
6.3.1 El rango 103
6.3.2 La desviación media absoluta 104
6.3.3 La varianza y la desviación estándar 107
6.3.4 Comparando dos grupos 110
6.4 Medidas de posición: orden y progreso 111
6.5 Gráficos 113
6.6 Software 115

7 La muestra y la población 116
7.1 La ley de los grandes números 116
7.2 Teorema del límite central 118
7.3 Distribuciones muestrales 120
7.3.1 Distribución muestral de la media muestral 120
7.3.2 Distribución muestral de la proporción muestral . . 120
7.3.3 La distribución muestral de la media muestral para poblaciones de varianza desconocida 121
7.3.4 Distribución muestral de la varianza muestral 122

8 El arte de estimar 126
8.1 ¿Qué hace que un estimador sea bueno? Error cuadrático medio y amigos 129
8.1.1 Cota de Cramér-Rao 131

9 ¿Qué tan seguros estamos? 132

¿Qué probabilidad hay? 1

Idea central

¿Cómo podemos medir, de forma rigurosa, cuán probable es algo? En este capítulo construimos el lenguaje básico de la probabilidad: eventos, espacios muestrales, y las reglas para calcular probabilidades de combinaciones de eventos.

1.1 Introducción

En este texto, cada vez que el color del mismo sea negro, este texto está más enfocado en las ideas que dan sustento a la teoría.

Todos los días nos encontramos con frases que tienen que ver con probabilidades: ¿Irá a llover? ¡Me encontré con Juanito! No lo veía hace años.

Los matemáticos y científicos también se dieron cuenta que necesitaban hablar de probabilidades pero, a diferencia de nuestro uso cotidiano, es necesario un lenguaje, unas definiciones, más precisas.

El problema es que es difícil. Hay varias formas de ver la probabilidad y ninguna cubre todos los significados que le asignamos de forma cotidiana al término. En este curso, haremos uso de la definición frecuentista de probabilidad. Esta definición opera bajo algunos supuestos, por ejemplo que podemos repetir un proceso varias veces, independientemente y bajo las mismas condiciones.

Esto es algo que suele ocurrir con los juegos de azar. De hecho, uno de los orígenes de la teoría de probabilidad es el estudio de los juegos de azar y apuestas.

Por ejemplo, al lanzar un dado ideal, cada cara tiene la misma probabilidad de aparecer que las otras, 1/6 o 16,67 %. La interpretación es que, al lanzar el dado

bajo las mismas condiciones, en el largo plazo cada cara aparecerá 1/6 de las veces.

Definición 1.1.1 *La probabilidad de algo es el porcentaje de veces que se espera que ocurra en el largo plazo, cuando el proceso que le da origen se repite una y otra vez, de manera independiente y bajo las mismas condiciones.*

Si algo es imposible que pase, su probabilidad es 0. Si algo es seguro, su probabilidad es 100 %. Esos son lógicamente los casos extremos, por lo que

Observación 1.1.1 Todas las probabilidades están entre 0 y 1 (0 % y 100 %).

Otro hecho fundamental: supongamos que estamos jugando un juego en el que tenemos un 30 % de ganar. En otras palabras, esperamos ganar un 30 % de las veces que jugamos. Por lo tanto, esperamos perder el otro 70 % de las veces.

Observación 1.1.2 La probabilidad de algo es 100 % menos la probabilidad de su opuesto.

Problema: Apostamos en un juego en el que, al sacar una pelota de una caja, si es roja ganamos y si es azul perdemos. Cada pelota tiene la misma probabilidad de ser escogida.

Si podemos elegir la caja de entre las dos siguientes:

Caja A: Contiene 2 pelotas rojas y 3 pelotas azules.
Caja B: Contiene 20 pelotas rojas y 30 pelotas azules.

¿cuál nos conviene?

¡Hey!

Antes de seguir: ¿elegiría la caja A, la caja B, o le daría igual? Tómese un segundo.

Quizás es un experimento un poco tonto, pero lo que sí es muy útil es la idea de escoger pelotas de colores desde una caja. Resulta que muchas situaciones en probabilidad (y estadística) se pueden modelar de esta forma. Este es, entonces, nuestro primer modelo probabilístico.

1.2 Eventos, espacios muestrales y probabilidad

En este texto, cada vez que el color del mismo sea azul, este texto está más enfocado en la teoría y en las definiciones.

Un experimento es un procedimiento que puede ser repetido indefinidamente y que tiene un conjunto bien definido de resultados. Si el experimento tiene un resultado, es un experimento determinista. Si tiene más de un resultado, es un experimento aleatorio.[1]

1: En este curso sólo nos ocuparemos de experimentos aleatorios.

El conjunto de resultados de un experimento aleatorio se llama el *espacio muestral* del experimento aleatorio.

Cada vez que realizamos un experimento aleatorio, se obtiene un y sólo un resultado. Sin embargo, este resultado puede estar incluido en uno o más *eventos*. Un evento es un subconjunto del espacio muestral. Cada evento está compuesto de cero o más resultados.

Normalmente, nos ocuparemos de eventos con mayor o menor nivel de complejidad en vez de concentrarnos en resultados.

Dicho de otro modo, si tenemos un espacio muestral Ω, cada evento es un elemento de $\mathcal{P}(\Omega)$, el conjunto potencia de Ω.

De esta manera, la probabilidad se define como una función $\mathrm{P} : \mathscr{P}(\Omega) \to [0, 1]$ que cumple con ciertas características, los axiomas de probabilidad (que veremos más adelante).

En la sección anterior hablamos acerca del "opuesto" de un evento. En la literatura, esto se conoce como el *complemento* de un evento. Hay varias formas de escribirlo simbólicamente; una de las más comunes es A^{c} para el complemento del evento A.

1.3 Probabilidad condicional

Imaginemos que tenemos una baraja de naipes. Esta baraja tiene 52 cartas (son 13 cartas por pinta y dejamos fuera a los jokers). Supongamos que saco dos cartas y que gano el juego si la segunda carta es el as de picas.

a) ¿Cuál es la probabilidad de ganar?
b) Si doy vuelta la primera carta y es el 6 de corazones, ¿cuál es la probabilidad de ganar?

En la parte a), la primera carta no importa realmente. Podemos dar vuelta la segunda carta inmediatamente. Por lo tanto, como tengo 52 cartas a disposición, mi probabilidad de ganar es $1/52$ (o 1,92 %).

En la parte b), ya no tengo 52 cartas que "repartir"; sólo tengo 51. Esto ocurre porque ya sé que la primera carta es el 6 de corazones. Por lo tanto, mi probabilidad de ganar es $1/51$ (o 1,96 %).

Esta segunda probabilidad es lo que se conoce como *probabilidad condicional*. El problema pone una condición en la primera carta: tiene que ser el 6 de corazones.

En símbolos,

$$\mathrm{P}(\text{As de picas} \mid \text{6 de corazones}) = \frac{1}{51}$$

(la barra se lee "dado").

1.4 Principio multiplicativo

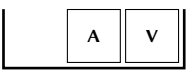
Una caja contiene tres fichas, una roja, una azul y una verde.



Vamos a sacar dos fichas de la caja, sin reemplazo. ¿Cuál es la probabilidad de sacar primero la ficha roja y luego la azul?

Imaginemos que tenemos un grupo grande de personas, digamos 600 personas, cada una de ellas con una caja como la de arriba. Alrededor de 200 de ellas van a sacar la ficha roja la primera vez. De esas doscientas personas, alrededor de 100 van a sacar la ficha azul la segunda vez. Así que $100/600 = 1/6$ o 16,67 % de las personas van a sacar la ficha roja primero y la azul después.

En otras palabras, la cantidad de personas que van a sacar primero la ficha roja es alrededor de $1/3$ de la cantidad original de personas, las que se quedan con



La segunda vez que sacan una ficha, alrededor de la mitad de las personas van a sacar la ficha azul. La fracción que saca la ficha roja y luego la azul es entonces

$$\frac{1}{2} \text{ de } \frac{1}{3} = \frac{1}{2} \cdot \frac{1}{3} = \frac{1}{6}.$$

El método del ejemplo anterior se llama *principio multiplicativo*.

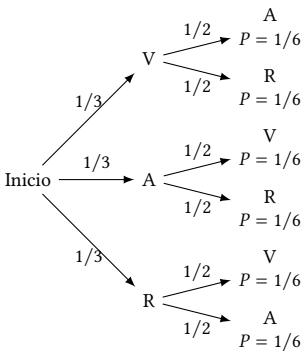


Figura 1.1: Diagrama de árbol para el experimento de sacar dos fichas de la caja.

Definición 1.4.1 (Principio multiplicativo) *La probabilidad de que, de dos cosas, ambas ocurran es la probabilidad de que ocurra la primera multiplicada por la probabilidad de que ocurra la segunda dado que la primera ya ocurrió.*

En símbolos, si A y B son eventos, entonces

$$\mathrm{P}(A \cap B) = \mathrm{P}(A)\,\mathrm{P}(B \mid A).$$

Podría parecer que tenemos un problema con el orden de los eventos. Sin embargo, si recordamos de teoría de conjuntos que $A \cap B = B \cap A$, podemos escribir el principio multiplicativo como

$$\mathrm{P}(A \cap B) = \mathrm{P}(B)\,\mathrm{P}(A \mid B).$$

Otro ejemplo. En nuestro ejemplo de la baraja de naipes de la sección 1.3 (Probabilidad condicional), la probabilidad de sacar primero el seis de corazones y luego el as de picas es

$$\begin{aligned}\mathrm{P}(6\,\heartsuit \cap \text{As}\,\spadesuit) &= \mathrm{P}(6\,\heartsuit)\,\mathrm{P}(\text{As}\,\spadesuit \mid 6\,\heartsuit)\\ &= \frac{1}{52}\cdot\frac{1}{51}\\ &= \frac{1}{2652}.\end{aligned}$$

Esta probabilidad es pequeña, aproximadamente 4 en 10.000.

¿Qué pasaría si nos preguntáramos por la probabilidad de sacar dos ases? La probabilidad de sacar el primer as es 4/52. Dado que la primera carta fue un as, la probabilidad de que la segunda carta también sea un as es 3/51. Por lo tanto, la probabilidad de sacar dos ases es

$$\frac{4}{52}\cdot\frac{3}{51} = \frac{12}{2652}.$$

Esta probabilidad es aproximadamente 1 en 200.

Otro ejemplo. Una moneda se lanza dos veces. ¿Cuál es la probabilidad de sacar cara y luego sello de una moneda justa[2]?

2: una moneda justa es aquella que tiene la misma probabilidad de caer en cara o en sello (y 0 de otra forma, como caer de canto)

La probabilidad de que el primer lanzamiento sea cara es $1/2$. No importa cómo salga este primer lanzamiento, la probabilidad de que el segundo lanzamiento sea sello es $1/2$. Por lo tanto, la probabilidad de que el primer lanzamiento sea cara y el segundo sello es

$$\frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}.$$

1.5 Independencia

La idea de independencia es una que va a aparecer repetidamente dentro de este texto.

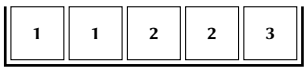
Definición 1.5.1 (Independencia) *Dos eventos son independientes si la probabilidad de que ocurra el segundo dado el primero son iguales, sin importar qué haya ocurrido con el primero. En caso contrario, los eventos son* dependientes.

Un ejemplo. Supongamos que lanzamos una moneda dos veces y ganamos si la segunda vez sale cara.

a) Si en el primer lanzamiento salió cara, ¿cuál es la probabilidad de ganar?
b) Si en el primer lanzamiento salió sello, ¿cuál es la probabilidad de ganar?
c) ¿Los lanzamientos son independientes?

En la parte a), la probabilidad de ganar es 50 % (la probabilidad de que salga cara en el segundo lanzamiento). En la parte b), la probabilidad de ganar es también 50 %. La probabilidad de ganar no se ve influida por el resultado del primer lanzamiento. Eso es independencia.

Otro ejemplo. Se sacan dos fichas con reposición de la siguiente caja



a) Supongamos que la primera ficha tiene una etiqueta 1. ¿Cuál es la probabilidad de que la segunda ficha tenga una etiqueta 2?
b) Supongamos que la primera ficha tiene una etiqueta 2. ¿Cuál es la probabilidad de que la segunda ficha tenga una etiqueta 2?
c) Es independiente el resultado de la primera ficha del resultado de la segunda?

Si la primera ficha tiene etiqueta 1, 2 o 3, la probabilidad de que la segunda ficha tenga una etiqueta 2 es siempre[3] 2 de 5 o 40 %. Por lo tanto, los resultados son independientes.

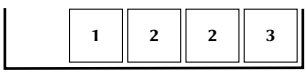
3: porque hay reposición

Otro ejemplo. Tenemos la misma caja del ejemplo anterior, pero ahora sacamos dos fichas sin reposición.

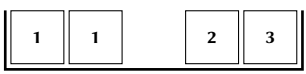
¡Hey!

¿Los resultados seguirán siendo independientes? ¿Por qué sí o por qué no?

Si la primera ficha tiene etiqueta 1, nos quedamos con la caja



y la probabilidad de que la segunda ficha tenga etiqueta 2 es $2/4 = 1/2$ o 50 %. Si la primera ficha tiene etiqueta 2, nos quedamos con la caja



y la probabilidad de que la segunda ficha tenga etiqueta 2 es 1/4 o 25 %. Por lo tanto, los resultados no son independientes.

Observación 1.5.1 Cuando el muestreo es con reposición, los eventos son independientes. Cuando el muestreo es sin reposición, los eventos son dependientes.

La versión en símbolos de la definición de independencia es la siguiente. Si A y B son eventos independientes, entonces

$$\mathrm{P}(B \mid A) = \mathrm{P}(B \mid A^c) = \mathrm{P}(B).$$

Sin embargo, esa no es la definición que aparece en los libros.

Para encontrar la versión popular de la definición, tenemos que recordar que

$$\mathrm{P}(A \cap B) = \mathrm{P}(A)\,\mathrm{P}(B \mid A).$$

Por lo tanto, si A y B son independientes, entonces

$$\mathrm{P}(A \cap B) = \mathrm{P}(A)\,\mathrm{P}(B).$$

Esta es la versión más común de la definición de independencia y es un caso especial del principio multiplicativo.

1.6 Principio aditivo

Esta sección trata sobre cómo calcular la probabilidad de que ocurra al menos uno de dos eventos, es decir, que ocurra el primero, el segundo o ambos. Resulta que cuando ocurren ambos, la situación se complica un poco, por lo que haremos una definición.

Definición 1.6.1 (Eventos mutuamente excluyentes) *Dos cosas son mutuamente excluyentes si la ocurrencia de una impide la ocurrencia de la otra. En otras palabras, si una ocurre, la otra no puede ocurrir.*

Con esa definición, podemos establecer el principio aditivo.

Definición 1.6.2 (Principio aditivo) *Para encontrar la probabilidad de que al menos una de dos cosas ocurra, primero verificamos si son mutuamente excluyentes. Si lo son, entonces simplemente sumamos las probabilidades de cada una.*

Un ejemplo. La probabilidad de sacar un corazón de una baraja bien revuelta es $1/4$. La probabilidad de sacar una pica de una baraja bien revuelta es también $1/4$. ¿Cuál es la probabilidad de sacar un corazón o una pica? Como no es posible sacar una carta que sea a la vez corazón y pica, los eventos son mutuamente excluyentes. Por lo tanto, la probabilidad de sacar un corazón o una pica es $1/4+1/4 = 1/2$ o 50 %.

Otro ejemplo. Lanzamos dos dados (pensemos en uno blanco y uno negro para diferenciarlos). Tu amigo dice que la probabilidad de sacar al menos un 1 es

$$\frac{1}{6} + \frac{1}{6} = \frac{1}{3}.$$

¿Tiene razón?

¡Hey!

¿Está de acuerdo con su amigo? Si no, ¿dónde está el error?

No. La pregunta pide que pase al menos una de estas cosas:

- Que el dado blanco muestre un 1 ⚀.

- Que el dado negro muestre un 1 ⚀.

y que un dado muestre un 1 no impide que el otro también muestre un 1. Estos eventos no son mutuamente excluyentes así que el principio aditivo no corre: no podemos sumar las probabilidades.

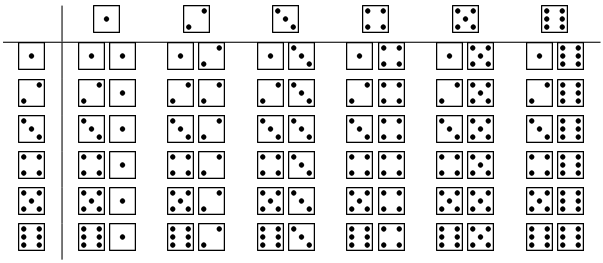


Tabla 1.1: Espacio muestral del lanzamiento de dos dados.

La Tabla 1.1 nos muestra todos los resultados posibles al lanzar dos dados. Hay seis resultados en los que el dado blanco muestra un 1 y seis resultados en los que el dado negro muestra un 1. Pero el número de maneras de obtener al menos un 1 no es $6+6$: sumar a la rápida cuenta dos veces el resultado ⚀⚀. La probabilidad de obtener al menos un 1 al lanzar dos dados es

$$(6 + 6 - 1)/36 = 11/36.$$

Observación 1.6.1 Si queremos encontrar la probabilidad de que al menos un evento ocurra, y los eventos no son mutuamente excluyentes, no sumemos las probabilidades individuales: la suma va a ser demasiado grande.

Definición 1.6.3 (Principio aditivo II: el regreso) *Si queremos calcular la probabilidad de que al menos un evento ocurra y los eventos no son mutuamente excluyentes, podemos sumar la probabilidad*

de cada evento, pero debemos restar la probabilidad de que ocurran ambos eventos conjuntamente. Eso es lo que estamos sumando de más.

El principio aditivo es sencillo de escribir simbólicamente:

$$\mathrm{P}(A \cup B) = \mathrm{P}(A) + \mathrm{P}(B) - \mathrm{P}(A \cap B).$$

Si recordamos que nuestra definición de eventos mutuamente excluyentes es que la ocurrencia de uno impide la ocurrencia del otro, podemos ver que si A y B son mutuamente excluyentes, entonces

$$\mathrm{P}(A \cap B) = 0.$$

Por lo tanto, en ese caso el principio aditivo se reduce a

$$\mathrm{P}(A \cup B) = \mathrm{P}(A) + \mathrm{P}(B).$$

Evidentemente, esto se puede extender a más de dos eventos.

Definición 1.6.4 *Si $A_1, A_2, \ldots, A_n$ son eventos mutuamente excluyentes, entonces*

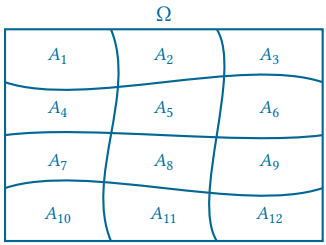
$$\mathrm{P}(A_1 \cup A_2 \cup \cdots \cup A_n) = \mathrm{P}(A_1) + \mathrm{P}(A_2) + \cdots + \mathrm{P}(A_n).$$

Un caso particular de este principio es cuando tenemos una *partición*. Un conjunto de eventos $\{A_1, A_2, \ldots, A_n\}$ es una partición del espacio muestral si son mutuamente excluyentes y su unión es el espacio muestral. En ese caso,

$$\mathrm{P}(A_1 \cup A_2 \cup \cdots \cup A_n) = \mathrm{P}(\Omega) = 1.$$

Por lo tanto, si $A_1, A_2, \ldots, A_n$ es una partición del espacio muestral, entonces

$$\mathrm{P}(A_1) + \mathrm{P}(A_2) + \cdots + \mathrm{P}(A_n) = 1.$$



La figura muestra una partición del espacio muestral. En efecto,

$$\bigcup_{i=1}^{12} A_i = \Omega$$

y

$$A_i \cap A_j = \emptyset,\ i \neq j.$$

1.7 Preguntas frecuentes

1. ¿Cuál es la diferencia entre dos eventos independientes y mutuamente excluyentes?
2. ¿Cuándo sumo y cuándo multiplico?

1. Dos eventos son independientes si la ocurrencia de uno no afecta la probabilidad de que ocurra el otro. Dos eventos son mutuamente excluyentes si la ocurrencia de uno impide la ocurrencia del otro.
   De lo anterior se concluye que dos eventos mutuamente excluyentes no pueden ser independientes: la ocurrencia de uno afecta muy directamente la probabilidad de que ocurra el otro, ya que la lleva a 0.
   Por ejemplo, no podemos lanzar una moneda y que salga cara y sello al mismo tiempo. Si sale cara, no puede salir sello. Por lo tanto esos dos eventos son mutuamente excluyentes. Muchas veces los eventos mutuamente excluyentes tienen que ver con la imposibilidad de obtener más de un resultado al realizar una vez un experimento aleatorio. Por ejemplo, al lanzar un dado, no podemos obtener un 1 y un 2 al mismo tiempo.

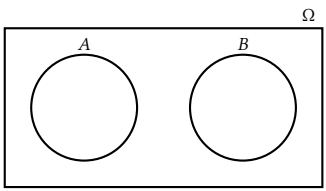


Figura 1.2: Eventos mutuamente excluyentes.

En cambio, dos eventos son independientes porque en realidad no se afectan entre sí. Por ejemplo, al lanzar una moneda dos veces, la moneda no tiene memoria por lo que el resultado del segundo lanzamiento no se ve afectado por el resultado del primero.
Muchas veces los eventos independientes tienen que ver, o bien con la repetición de un experimento aleatorio *de manera que una repetición que no afecte a las siguientes*[4], o bien con la realización simultanea de experimentos aleatorios diferentes *que no se afectan entre sí*[5].

2. Multiplicamos cuando queremos encontrar la probabilidad de que ocurran dos eventos al mismo tiempo. Sumamos cuando queremos encontrar la probabilidad de que ocurra al menos uno de dos eventos.

4: por ejemplo, sacar una pelota de una caja con reposición

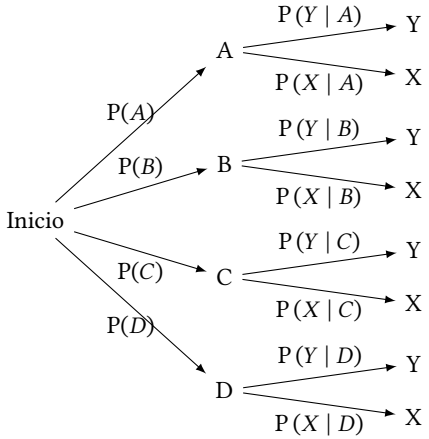
5: por ejemplo, lanzar un dado y lanzar una moneda

1.7.1 Una nota sobre visualización de eventos

Muchas veces representamos eventos usando diagramas de Venn, como en la Figura 1.2. Sin embargo, estos diagramas no son muy útiles para calcular probabilidades.

Una alternativa gráfica más útil son los diagramas de árbol. Usamos uno en la Figura 1.1 para el experimento de sacar dos fichas de la caja. En este caso, cada rama del árbol representa un resultado posible y las probabilidades se escriben al lado de cada rama.

Un diagrama de árbol, combinado con los principios aditivo y multiplicativo, nos permite calcular la probabilidad de cualquier evento que involucre los eventos representados en el diagrama. Por ejemplo, para calcular la probabilidad de que ocurra A y X, podemos seguir la rama que va desde el inicio hasta



A y luego hasta X. La probabilidad de que ocurra ese evento es $\mathrm{P}(A)\cdot\mathrm{P}(X \mid A)$. También podemos calcular la probabilidad de que ocurra Y sumando todos los caminos que llevan a Y:

$$\begin{aligned}\mathrm{P}(Y) = {} & \mathrm{P}(A)\cdot\mathrm{P}(Y \mid A) + \mathrm{P}(B)\cdot\mathrm{P}(Y \mid B) + \\ & + \mathrm{P}(C)\cdot\mathrm{P}(Y \mid C) + \mathrm{P}(D)\cdot\mathrm{P}(Y \mid D)\end{aligned}$$

Otra visualización, no tan gráfica pero igualmente útil es usar una simple tabla. Si tenemos una tabla simple o de doble entrada, podemos dividir por el total de elementos (asumiendo equiprobabilidad de cada resultado) para encontrar la probabilidad de cada evento. Por ejemplo, si clasificamos los estudiantes de un campus por carrera y género, podemos tener una tabla como la siguiente:

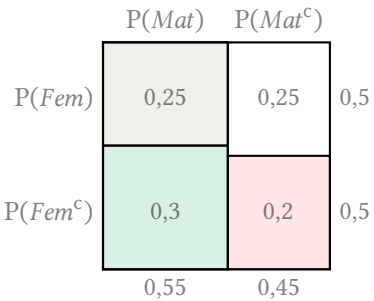
	Matemáticas	Lingüística	Total
Masculino	30	20	50
Femenino	25	25	50
Total	55	45	**100**

Dividiendo por el total obtenemos las probabilidades:

	Matemáticas	Lingüística	Total
Masculino	0,3	0,2	0,5
Femenino	0,25	0,25	0,5
Total	0,55	0,45	**1**

Otra visualización es usar un cuadrado de área 1 para representar el total de estudiantes. Luego, podemos dividir este cuadrado en áreas proporcionales a las probabilidades de cada evento. Por ejemplo, el área correspondiente a los estudiantes masculinos en Matemáticas sería 0,3, en Lingüística 0,2, y así sucesivamente. Esto nos da una representación visual clara de las probabilidades.

si lo hacemos a mano simplemente aproximamos



1.8 Conteo

Hasta ahora, hemos usado ejemplos de eventos sencillos, como sacar una o dos cartas de naipes o lanzar un dado. Si queremos progresar a eventos más complejos, necesitaremos saber contar cuántos resultados tiene nuestro espacio muestral y cuántos de ellos son favorables.

El párrafo anterior lleva un supuesto implícito: que cada resultado es igualmente probable[6]. Esa suposición no es cierta en todos los casos, pero es una buena aproximación. Además, podemos simular situaciones donde se cumple o donde no usando un modelo de cajas apropiado.

6: o, en palabras elegantes, que los resultados son *equiprobables*

Volviendo al tema, el principio básico del conteo es que si tenemos n formas de hacer una cosa y m formas de hacer otra, entonces tenemos $n \cdot m$ formas de hacer ambas cosas. Esto es el principio multiplicativo que vimos antes. En general, podemos extenderlo a un proceso que tenga varias etapas.

Definición 1.8.1 (Principio multiplicativo) *Si una primera etapa de un proceso puede ejecutarse de n_1 formas, una segunda etapa de n_2 formas para cada una de las formas anteriores, y así sucesivamente hasta una k-ésima etapa de n_k formas para cada una de las formas anteriores, entonces el número total de formas de ejecutar el proceso es $n_1 \cdot n_2 \cdots n_k$.*

El ejemplo clásico es contar las patentes posibles de los autos. En Chile, las patentes están compuestas en dos maneras:

- Dos letras y cuatro dígitos,
- Cuatro letras y dos dígitos.

Las letras no incluyen la Ñ, así que hay 26 letras posibles. Los dígitos son $0, 1, 2, \ldots, 9$, así que hay 10 dígitos posibles. Por lo tanto, en el primer caso tenemos

$$26^2 \cdot 10^4 = 6.760.000$$

y en el segundo caso tenemos

$$26^4 \cdot 10^2 = 45.697.600.$$

En total tenemos

$$6.760.000 + 45.697.600 = 52.457.600$$

patentes posibles.[7]

7: En realidad son menos porque hay varias letras que no se usan, como la I y la O, para evitar confusiones con los números 1 y 0.

Notemos que usamos otro principio, el principio aditivo, para sumar los dos casos. En general, si tenemos n casos mutuamente excluyentes, entonces el número total de resultados es la suma de los resultados de cada caso.

1.8.1 Permutaciones

Un caso especial es cuando ordenamos los elementos de un conjunto. Por ejemplo, si queremos ver de cuántas maneras podemos ordenar[8] los elementos de $\{a, b, c, d\}$ es fácil ver que para la primera posición tenemos 4 opciones, para la segunda 3, para la tercera 2 y para la última 1. Por lo tanto, el número total de ordenamientos es $4 \cdot 3 \cdot 2 \cdot 1 = 24 = 4!$.

8: sin repetición

Esta idea de ordenar los elementos de un conjunto se llama *permutación.*

Definición 1.8.2 (Permutación) *Una permutación de un conjunto S es un ordenamiento de todos o algunos de los elementos de S. El número de permutaciones de todos los elementos de un conjunto de n elementos es*

$$n! = n \cdot (n-1) \cdots 2 \cdot 1.$$

Sin embargo, como dice la definición, también podemos ordenar sólo algunos de los elementos de un conjunto. Continuando el ejemplo anterior, si tenemos el conjunto $\{a, b, c, d\}$ y queremos ordenar sólo 2 de sus elementos, entonces tenemos 4 opciones para el primer elemento y 3 para el segundo. Por lo tanto, el número de ordenamientos es $4 \cdot 3 = 12$.

En general, si vamos a ordenar k elementos de un conjunto de n elementos, entonces el número de ordenamientos es

$$\mathrm{P}_k^n = n \cdot (n-1) \cdots (n-k+1).$$

Una forma muy común de escribir esto es reconocer que

$$\begin{aligned} n \cdot (n-1) \cdots (n-k+1) &= \frac{n \cdot (n-1) \cdots (n-k+1) \cdot (n-k) \cdot (n-k-1) \cdots 2 \cdot 1}{(n-k) \cdot (n-k-1) \cdots 2 \cdot 1} \\ &= \frac{n!}{(n-k)!}. \end{aligned}$$

Un ejemplo clásico: Si tenemos un curso con 37 estudiantes y queremos elegir un presidente, un secretario y un tesorero, entonces tenemos 37 opciones para el presidente, 36 para el secretario y 35 para el tesorero. Por lo tanto, el número de maneras de elegir a los tres es

$$\mathrm{P}_3^{37} = \frac{37!}{(37-3)!} = \frac{37!}{34!} = 37 \cdot 36 \cdot 35 = 46.620.$$

1.8.2 Combinaciones

Ahora, una cosa es elegir miembros de un conjunto y otra cosa es elegirlos y ordenarlos. Si no nos importa el orden, entonces estamos hablando de *combinaciones*. Evidentemente, el número de combinaciones es menor que el número de permutaciones, ya que podemos entender una combinación como un conjunto de permutaciones donde el orden no importa.

La pregunta es ¿qué tan menor? Por ejemplo, si escogemos ordenadamente 2 elementos de $\{a, b, c, d\}$, tenemos como resultado

ab	ac	ad	bc	bd	cd
ba	ca	da	cb	db	dc

pero si no nos importa el orden, podemos colapsar cada columna en un solo elemento, obteniendo $\{ab, ac, ad, bc, bd, cd\}$. Por lo tanto, el número de combinaciones es 6 o, en otras palabras, $12/2$.

Definición 1.8.3 (Combinación) *Una combinación de un conjunto S es un subconjunto de S de k elementos, sin importar el orden. El número de combinaciones de k elementos de un conjunto de n elementos es*

$$\mathrm{C}_k^n = \frac{n!}{k!(n-k)!}.$$

Notemos que

$$\mathrm{C}_k^n = \frac{1}{k!}\,\mathrm{P}_k^n.$$

Asimismo, gracias a esta definición, podemos darnos cuenta que

$$\mathrm{C}_k^n = \binom{n}{k},$$

es decir, el número de combinaciones de k elementos de un conjunto de n elementos es el coeficiente binomial $\binom{n}{k}$.

Ejemplo: si en vez de elegir un presidente, un secretario y un tesorero, sólo queremos elegir 3 estudiantes para formar una comisión, entonces el número de maneras de elegir a los 3 es

$$\mathrm{C}_3^{37} = \frac{37!}{3!\,(37-3)!} = \frac{37!}{3!\,34!} = \frac{37 \cdot 36 \cdot 35}{3 \cdot 2 \cdot 1} = 7770.$$

1.8.3 Algunos casos extra

Un caso especial de permutaciones es cuando debemos organizar los elementos alrededor de un círculo. En este caso, no son distinguibles dos permutaciones

si podemos llegar de una a la otra mediante una rotación. Por ejemplo, si tenemos 4 elementos a, b, c, d, entonces las permutaciones (a, b, c, d) y (b, c, d, a) son indistinguibles (Figura 1.3).

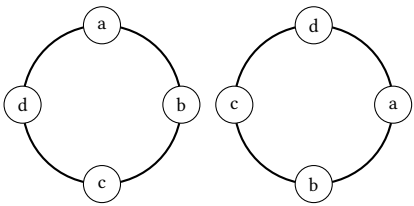


Figura 1.3: Dos permutaciones circulares indistinguibles.

Como podemos hacer n rotaciones, el número de permutaciones es $(n-1)!$.

Otro caso es cuando tenemos n elementos, pero algunos de ellos son iguales. Por ejemplo, si tenemos n letras, pero algunas son iguales, entonces el número de permutaciones es

$$\mathrm{P}^{n}_{k_1,k_2,\ldots,k_m} = \frac{n!}{k_1! \cdot k_2! \cdots k_m!},$$

donde k_i es el número de veces que se repite el elemento i. Esto ocurre porque al contar las permutaciones, cada una de las permutaciones de los elementos iguales se cuenta $k_i!$ veces, así que debemos dividir por ese número para no contar de más.

Ejemplo: contar las permutaciones de la palabra *casada.* Como la palabra tiene 6 letras, en principio tendríamos 6! permutaciones. Sin embargo, los siguientes 6 arreglos son indistinguibles:

$$\begin{array}{ll} ca_1sa_2da_3 & ca_1sa_3da_2 \\ ca_2sa_1da_3 & ca_2sa_3da_1 \\ ca_3sa_1da_2 & ca_3sa_2da_1 \end{array}$$

que son precisamente las permutaciones de los 3 elementos a que hay en la palabra. Por lo tanto, el

número de permutaciones es

$$\frac{6!}{3!} = 120.$$

Probabilidades++ 2

Idea central

¿Cómo debería cambiar lo que creemos cuando aprendemos algo nuevo? El teorema de Bayes responde esta pregunta con consecuencias sorprendentes, incluso para situaciones cotidianas como interpretar el resultado de un examen médico.

2.1 Axiomas de probabilidad

En el capítulo anterior vimos que la probabilidad se define como una función que cumple ciertas condiciones. Definámosla bien de una vez por todas.

Definición 2.1.1 (Probabilidad) *Sea S un espacio muestral y E un evento cualquiera de éste. Se llamará* función de probabilidad *sobre el espacio muestral S a $\mathrm{P}(E)$ si satisface los siguientes axiomas:*

1. $\mathrm{P}(E) \geq 0$
2. $\mathrm{P}(S) = 1$
3. *Si para los eventos $E_1, E_2, \ldots, E_i \cap E_j = \emptyset$ para $i \neq j$, entonces* $\mathrm{P}\left(\bigcup_i E_i\right) = \sum_i \mathrm{P}(E_i)$.

De esta definición se deducen los teoremas que hemos estado usando en la sección anterior. Por ejemplo,

Teorema 2.1.1 $\mathrm{P}(\emptyset) = 0$.

Demostración. $S \cup \emptyset = S$ y $S \cap \emptyset = \emptyset$. Por el axioma

3,

$$\mathrm{P}(S \cup \varnothing) = \mathrm{P}(S) + \mathrm{P}(\varnothing),$$

pero por el axioma 2, $\mathrm{P}(S) = 1$. Por lo tanto,

$$\mathrm{P}(\varnothing) = 0.$$

□

Podemos demostrar los teoremas de probabilidad usando los axiomas de manera similar. Como dicen los libros, queda como ejercicio al lector.

2.2 Teorema de Bayes

Nos han descrito a Esteban de la siguiente manera:

- Es organizado.
- Le gusta el orden.
- Es callado, pero afable.
- Es servicial.

La pregunta es si Esteban será un bibliotecario o un campesino (no hay más opciones). En una de las secciones, aproximadamente el 85 % pensó que Esteban sería un bibliotecario versus un 15 % que pensó que sería un campesino.

Todo eso está muy bien, pero hay una información que no hemos considerado y que, francamente, debiéramos haber tenido en cuenta: hay muchos más campesinos que bibliotecarios. Como ejemplo, podemos asumir que la razón entre bibliotecarios y campesinos es $1 : 20$ (en realidad debe ser algo como $1 : 100$).

¡Hey!

Con esa información, ¿cambia su respuesta sobre si Esteban es bibliotecario? ¿En qué dirección?



Figura 2.1: Muestra de bibliotecarios y campesinos.

Siendo así, podemos tomar una muestra[1] que siga esa proporción (Figura 2.1).

1: más adelante en el curso definiremos qué es eso

Supongamos que aproximadamente un 40 % de los bibliotecaros siguen la descripción de Esteban, pero sólo un 10 % de los campesinos la siguen. Si fuera así, de nuestros 10 bibliotecarios, 4 serían como Esteban y de los 200 campesinos, 20 serían como Esteban (Figura 2.2).



Figura 2.2: Bibliotecarios y campesinos como Esteban.

En este caso, la probabilidad de encontrar un biblio-

tecario dado que es como Esteban es

$$\mathrm{P}(B \mid E) = \frac{4}{4+20} = \frac{4}{24} = \frac{1}{6},$$

mientras que la probabilidad de encontrar un campesino dado que es como Esteban es

$$\mathrm{P}(C \mid E) = \frac{20}{4+20} = \frac{20}{24} = \frac{5}{6}.$$

Es decir, es bastante más probable que Esteban sea un campesino, pese a que entre los campesinos personas con su descripción son más difíciles de encontrar.

Lo que nos muestra este ejemplo es que la llegada de nueva información (en este caso, la razón entre bibliotecarios y campesinos en la población general) nos permite actualizar nuestras creencias, expresadas como una probabilidad.

Podemos desempacar un poco nuestros cálculos. La probabilidad de encontrar un biliotecario entre la gente que es como Esteban era

$$\mathrm{P}(B \mid E) = \frac{4}{4+20}$$

pero esos números representan

$$= \frac{40\,\%\text{ de }10}{40\,\%\text{ de }10 + 10\,\%\text{ de }20}$$
$$= \frac{40\,\%\text{ de }\frac{1}{21}\text{ de }210}{40\,\%\text{ de }\frac{1}{21}\text{ de }210 + 10\,\%\text{ de }\frac{20}{21}\text{ de }210}$$

simplificando los 210

$$= \frac{40\,\%\text{ de }\frac{1}{21}}{40\,\%\text{ de }\frac{1}{21} + 10\,\%\text{ de }\frac{20}{21}}$$
$$= \frac{0{,}4 \cdot \frac{1}{21}}{0{,}4 \cdot \frac{1}{21} + 0{,}1 \cdot \frac{20}{21}}$$

y cada uno de esos números representa una probabilidad

$$= \frac{\mathrm{P}(E \mid B)\,\mathrm{P}(B)}{\mathrm{P}(E \mid B)\,\mathrm{P}(B) + \mathrm{P}(E \mid C)\,\mathrm{P}(C)}$$

en resumen

$$\mathrm{P}(B \mid E) = \frac{\mathrm{P}(E \mid B)\,\mathrm{P}(B)}{\mathrm{P}(E \mid B)\,\mathrm{P}(B) + \mathrm{P}(E \mid C)\,\mathrm{P}(C)}$$

El teorema de Bayes aparece como una derivación bastante inocua del principio multiplicativo.

$$\mathrm{P}(A \cap B) = \mathrm{P}(A)\,\mathrm{P}(B \mid A)$$
$$\mathrm{P}(A \cap B) = \mathrm{P}(B)\,\mathrm{P}(A \mid B)$$

por lo tanto

$$\mathrm{P}(A)\,\mathrm{P}(B \mid A) = \mathrm{P}(B)\,\mathrm{P}(A \mid B)$$
$$\mathrm{P}(B \mid A) = \frac{\mathrm{P}(B)\,\mathrm{P}(A \mid B)}{\mathrm{P}(A)}$$

Teorema 2.2.1 (Teorema de Bayes)

$$\mathrm{P}(B \mid A) = \frac{\mathrm{P}(B)\,\mathrm{P}(A \mid B)}{\mathrm{P}(A)}$$

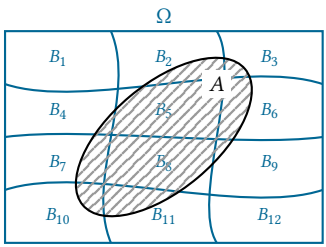
Sin embargo, como el mismo ejemplo de Esteban nos muestra, normalmente la probabilidad de A que encontramos en el denominador no se deja calcular tan directamente. En ese caso, dividimos el denominador en dos partes: los que son bibliotecarios y son como Esteban y los que son campesinos y son como Esteban. En otras palabras usamos una partición.

En un caso general, si tenemos una partición

$$B_1, B_2, \ldots, B_n$$

del espacio muestral Ω, podemos escribir la probabilidad de A como

$$\mathrm{P}(A) = \sum_{i=1}^{n} \mathrm{P}(A \cap B_i) = \sum_{i=1}^{n} \mathrm{P}(A \mid B_i)\,\mathrm{P}(B_i)$$



Esto es conocido como el teorema de la probabilidad total.

Teorema 2.2.2 (Teorema de la probabilidad total) *Si* $\{B_1, B_2, \ldots, B_n\}$ *es una partición del espacio muestral* Ω*, entonces*

$$\mathrm{P}(A) = \sum_{i=1}^{n} \mathrm{P}(A \cap B_i) = \sum_{i=1}^{n} \mathrm{P}\left(A \mid B_i\right)\mathrm{P}(B_i)$$

Como corolario, podemos escribir el teorema de Bayes como

Corolario 2.2.3 *Si* $\{B_i\}_{i=1}^n$ *es una partición del espacio muestral* Ω*, entonces*

$$\mathrm{P}(B_i \mid A) = \frac{\mathrm{P}(B_i)\,\mathrm{P}(A \mid B_i)}{\sum_{j=1}^{n} \mathrm{P}\left(A \mid B_j\right)\mathrm{P}\left(B_j\right)}$$

2.2.1 Enfermedades y exámenes

Un ejemplo importante del teorema de Bayes consiste en su aplicación a enfermedades y exámenes. Además de su importancia práctica, este tipo de ejemplos nos puede mostrar varios detalles interesantes sobre la probabilidad condicional.

Supongamos que hay una enfermedad que afecta a un porcentaje relativamente pequeño de la población, digamos un 1 % (eso es la *prevalencia* de la enfermedad). Tenemos un examen para detectar la enfermedad, que el fabricante nos dice que tiene una eficacia "sobre el 90 %". ¿Cuál será la probabilidad de tener la enfermedad si el examen nos da positivo?

¡Hey!

Antes de calcular: el examen tiene eficacia sobre el 90 % *y la enfermedad afecta al* 1 % *de la población. ¿Su estimación instintiva sería alta (más del* 50 %*) o baja?*

Para poder empezar a resolver este problema, debemos considerar que hay cuatro posibilidades

	E	E^{c}
+	E y +	E^{c} y +
−	E y −	E^{c} y −

Estas posibilidades tienen nombre

Esta idea volverá a aparecer cuando estemos haciendo

	E	E^c
$+$	Verdadero positivo	Falso positivo
$-$	Falso negativo	Verdadero negativo

Además, lo que el fabricante se refería como "tiene una eficacia sobre el 90 %" en realidad son dos números distintos

Sensibilidad La probabilidad que el examen dé positivo dado que el paciente tiene la enfermedad: $\mathrm{P}(+ \mid E)$.

Especificidad La probabilidad que el examen dé negativo dado que el paciente no tiene la enfermedad: $\mathrm{P}(- \mid E^c)$.

En nuestro caso, imaginemos que el examen tiene una sensibilidad de 90 % y una especificidad de 91 %.

Podemos calcular nuestra probabilidad haciendo un muestreo imaginario. De mil personas, con una prevalencia del 1 %, debería haber aproximadamente 10 personas enfermas. De las 10 personas enfermas, como la sensibilidad es un 90 % debería haber 9 personas que den positivo al examen. De las 990 personas que no tienen la enfermedad, como el test tiene una especificidad del 91 %, debería haber $0{,}91 \cdot 990 = 900{,}9 \approx 901$ personas que den negativo. Esto quiere decir que, hay $990 - 901 = 89$ personas que no tienen la enfermedad y dan positivo al test.

En otras palabras, si calculamos la probabilidad $\mathrm{P}(E \mid +)$, necesitamos contar a los enfermos de entre quienes dieron positivo en el examen

una nueva aparición de la probabilidad total, si nos fijamos bien

$$\mathrm{P}(E \mid +) = \frac{9}{9 + 89}$$

Lo ideal en este tipo de cálculo rápido es sacar ideas para hacer el cálculo formal[2]. En este caso, $\mathrm{P}(E \mid +)$

2: que es lo que se va a evaluar

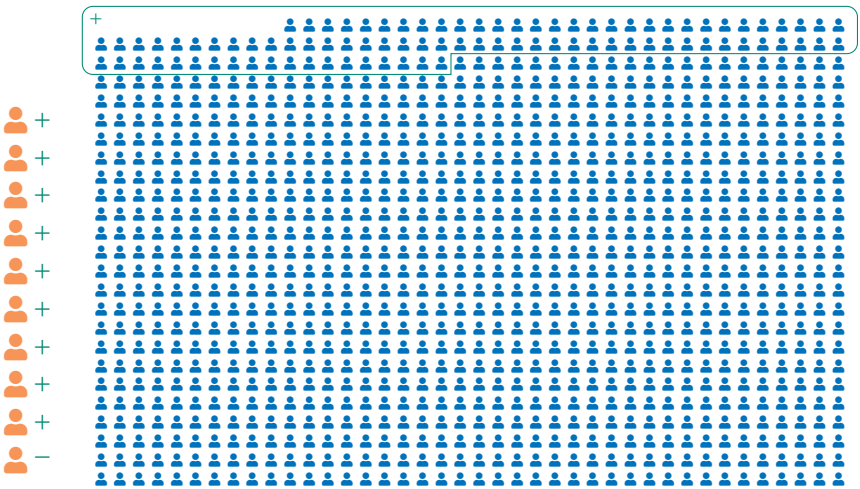


Figura 2.3: Muestra hipotética para el problema

es

$$\begin{aligned}
\mathrm{P}(E \mid +) &= \frac{\mathrm{P}(E \cap +)}{\mathrm{P}(+)} \\
&= \frac{\mathrm{P}(E \cap +)}{\mathrm{P}(E \cap +) + \mathrm{P}(E^{\mathrm{c}} \cap +)} \\
&= \frac{\mathrm{P}(E)\,\mathrm{P}(+ \mid E)}{\mathrm{P}(E)\,\mathrm{P}(+ \mid E) + \mathrm{P}(E^{\mathrm{c}})\,\mathrm{P}(+ \mid E^{\mathrm{c}})} \\
&= \frac{0{,}01 \cdot 0{,}9}{0{,}01 \cdot 0{,}9 + 0{,}99 \cdot 0{,}09} \\
&= 0{,}0917431193 \approx 9\,\%
\end{aligned}$$

2.2.2 Odds

Una versión alternativa de reportar la probabilidad es dar los *odds* de un evento[3]. Esto se define como la razón entre la probabilidad de que un evento ocurra a la probabilidad de que el evento no ocurra. Por supuesto, es fácil convertir entre odds y probabili-

3: francamente, no sé qué traducción podría ser clara *y* técnica.

dades. Por ejemplo

$$1 : 4 \to \frac{1}{1+4} = \frac{1}{5}$$

y viceversa.

En el ejemplo de las enfermedades, como la probabilidad de estar enfermo es 1 %, entonces los odds de estar enfermo son $1 : 99$. Lo que queríamos era la probabilidad de estar enfermo dado que nos dio positivo el test, $\mathrm{P}(E \mid +)$. ¿Cómo se ve eso en términos de odds? Eso debería ser la razón entre la probabilidad de estar enfermo dado que el test nos dio positivo y la probabilidad de estar sano dado que nos dio positivo el test

$$\frac{\mathrm{P}(E \mid +)}{\mathrm{P}(E^{\mathrm{c}} \mid +)}.$$

Podemos reemplazar usando el teorema de Bayes

$$\frac{\mathrm{P}(E \mid +)}{\mathrm{P}(E^{\mathrm{c}} \mid +)} = \frac{\frac{\mathrm{P}(E)\,\mathrm{P}(+ \mid E)}{\mathrm{P}(+)}}{\frac{\mathrm{P}(E^{\mathrm{c}})\,\mathrm{P}(+ \mid D^{\mathrm{c}})}{\mathrm{P}(+)}}$$

La probabilidad de que el test dé positivo se cancela

$$= \frac{\mathrm{P}(E)\,\mathrm{P}(+ \mid E)}{\mathrm{P}(E^{\mathrm{c}})\,\mathrm{P}(+ \mid E^{\mathrm{c}})}$$

Podemos separar la expresión anterior en dos factores

$$\underbrace{\frac{\mathrm{P}(E \mid +)}{\mathrm{P}(E^{\mathrm{c}} \mid +)}}_{\substack{\text{odds de enfermo} \\ \text{dado examen positivo}}} = \underbrace{\frac{\mathrm{P}(E)}{\mathrm{P}(E^{\mathrm{c}})}}_{\substack{\text{odds de estar} \\ \text{enfermo}}} \cdot \underbrace{\frac{\mathrm{P}(+ \mid E)}{\mathrm{P}(+ \mid E^{\mathrm{c}})}}_{\substack{\text{factor de} \\ \text{verosimilitud}}}$$

En otras palabras, el teorema de Bayes tiene una

versión mucho más sencilla cuando lo expresamos en términos de odds

odds a posteriori = odds a priori × factor de verosimilitud.

Este factor de verosimilitud es una especie de factor *de actualización* y es la fracción entre los verdaderos positivos y los falsos positivos. En nuestro caso, el factor de verosimilitud es

$$\frac{\mathrm{P}(+ \mid E)}{\mathrm{P}(+ \mid E^{\mathrm{c}})} = \frac{0{,}9}{0{,}09} = 10$$

lo que significa que cada nuevo test positivo, asumiendo independencia, mejora nuestros odds en 10 veces

$$\underbrace{1 : 99}_{\text{odds originales}} \xrightarrow{\text{test positivo}} 10 : 99 \xrightarrow[\text{independiente}]{\text{otro test positivo}} 100 : 99 \xrightarrow[\text{independiente}]{\text{otro test positivo}} 1000 : 99$$

lo que en probabilidades se ve como

$$1\,\% \to 9{,}2\,\% \to 50{,}25\,\% \to 90{,}99\,\%.$$

¡Resultados! ¡Resultados! ¡Resultados! 3

Idea central

El lenguaje de los eventos es poderoso, pero se vuelve engorroso para problemas (ni tan) complejos. Las variables aleatorias permiten traducir el resultado de cualquier experimento aleatorio a un número, abriendo la puerta al cálculo y a la abstracción.

3.1 Introducción

El lenguaje de eventos que hemos usado hasta ahora nos ha servido bien, pero al mismo tiempo es una limitante. En situaciones pequeñas ya empieza a dejar de ser útil.

Por ejemplo, como vimos en clase, ¿qué pasa si tenemos un jefe que quiere saber la probabilidad de que en una muestra de 4 elementos, dos sean defectuosos? Ya sólo escribir eso como evento es complicado:

o tedioso

$$A = \{(B,B,D,D),\ (B,D,B,D),\ (B,D,D,B),\ (D,B,B,D),\ (D,B,D,B),\ (D,D,B,B)\}$$

y ni hablar de si tuviéramos que escribir lo que pasa con todas las posibilidades.

Y, en realidad, podemos arreglar el problema de forma muy sencilla. Basta con enfocarse en el resultado y escribirlo como número. Es mucho más simple decir "salieron dos malos."

Esa es la idea detrás de una *variable aleatoria.* Una variable aleatoria es codificar el resultado de un experimento como un número. Muchas veces será

directamente un número, como en el caso de lanzar un dado, pero también podemos codificar cosas como las monedas:

$$\{C, S\} \to \{0, 1\}$$
$$C \to 0$$
$$S \to 1$$

pero no cuesta mucho ver que esa misma codificación podría ser mucho más general

$$\text{fracaso} \to 0$$
$$\text{éxito} \to 1$$

y eso es parte de la importancia de las variables aleatorias: nos permiten abstraer la idea de experimento aleatorio.

Sin embargo, es importante reconocer qué significa lo de *aleatoria* en variable aleatoria. La aleatoridad *no* está en la variable aleatoria. Fijémonos en la definición anterior: es completamente uno a uno y determinista. Lo aleatorio en esto está en el experimento.

En términos formales, una variable aleatoria es una función que va del espacio muestral a los reales. Utilizaremos letras mayúsculas para representarlas. Por lo tanto, una variable aleatoria X es

$$X : \Omega \to \mathbb{R}.$$

Por ejemplo, si X representa la cantidad de elementos defectuosos en una muestra de cuatro elementos, lo que el jefe quería saber en el ejemplo anterior es cuando $X = 2$. La probabilidad de que eso ocurra se denota $\mathrm{P}(X = 2)$

Un ejemplo. Supongamos que nuestro experimento aleatorio es sumar las pintas al lanzar dos dados.

Nuestra variable aleatoria es, entonces, algo como lo siguiente

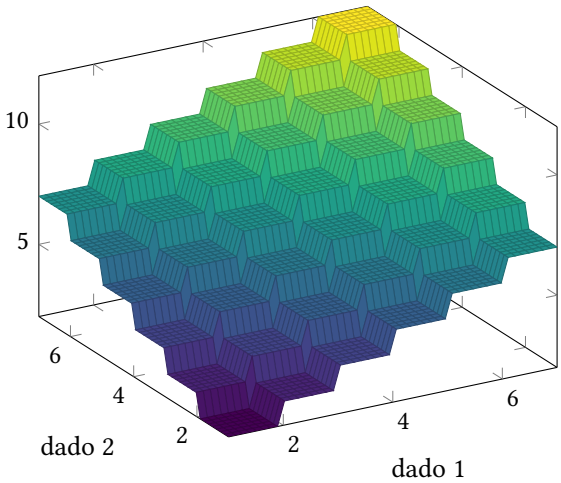
¡Hey!

Antes de ver la tabla: al sumar dos dados, ¿qué valor cree que es más probable? ¿Y cuál es menos probable?

(1,6)	(2,6)	(3,6)	(4,6)	(5,6)	(6,6)	$X = 12$
(1,5)	(2,5)	(3,5)	(4,5)	(5,5)	(6,5)	$X = 11$
(1,4)	(2,4)	(3,4)	(4,4)	(5,4)	(6,4)	$X = 10$
(1,3)	(2,3)	(3,3)	(4,3)	(5,3)	(6,3)	$X = 9$
(1,2)	(2,2)	(3,2)	(4,2)	(5,2)	(6,2)	$X = 8$
(1,1)	(2,1)	(3,1)	(4,1)	(5,1)	(6,1)	
$X = 2$	$X = 3$	$X = 4$	$X = 5$	$X = 6$	$X = 7$	

Notemos que al considerar nuestra variable aleatoria (la suma de los dos dados) hemos hecho una partición del espacio muestral, en este caso marcada con colores. Además, es muy natural llamar a cada conjunto de la partición por el resultado que marca. Así, por ejemplo, $X = 4$ es el evento compuesto por los resultados $(1, 3), (2, 2), (3, 1)$.

Si reconocemos que nuestro espacio muestral es $\{1, 2, 3, 4, 5, 6\} \times \{1, 2, 3, 4, 5, 6\}$ entonces nuestra varia-



ble aleatoria se puede escribir como

$$X : \{1,2,3,4,5,6\} \times \{1,2,3,4,5,6\} \to \{2,\dots,11,12\}$$
$$(\omega_1, \omega_2) \to \omega_1 + \omega_2$$

Ahora bien, como nuestra variable aleatoria divide a nuestro espacio muestral en una partición de eventos, cada uno de ellos tiene una probabilidad asociada. Sin embargo, aquí debemos empezar a hacer una distinción entre dos tipos de variables, las discretas y las continuas.

3.2 Variables aleatorias discretas

Una variable aleatoria discreta es una variable aleatoria cuyo recorrido es un conjunto finito o infinito numerable (típicamente los enteros o un subconjunto de ellos). Hasta ahora, nuestros eventos se pueden identificar con variables aleatorias discretas.

Cuando tenemos una VA[1] discreta X, podemos definir una función $f(x)$ como

$$f(x) = \mathrm{P}(X = x),$$

es decir, la probabilidad de que la VA X tome el valor x. Esta función se conoce como *función de masa de probabilidad* o como función de cuantía.

Un ejemplo. En una librería, la mayoría de la gente que entra no compra libros, supongamos un 70 %, la gente que compra un libro es alrededor del 25 % y los que compran 2 libros son el resto (aproximadamente nadie compra 3 o más libros). Tenemos entonces que

$$X = \text{número de libros comprados}$$

es una variable aleatoria y su función de masa de probabilidad viene dada por

i	0	1	2
$P(X = i)$	0,7	0,25	0,05

La función de masa de probabilidad debe cumplir dos propiedades

1. $f(x) \geq 0$.
2. $\sum_x f(x) = 1$.

También resulta útil calcular la función de probabilidad acumulada, $F(x)$. Esta función viene definida por

$$F(x) = \mathrm{P}(X \leq x) = \sum_{t \leq x} f(t).$$

1: abreviaremos así variable aleatoria

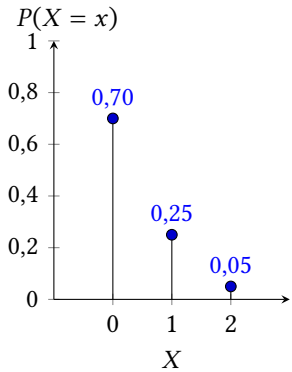


Figura 3.1: Función de masa de probabilidad de X.

3.3 Variables aleatorias continuas

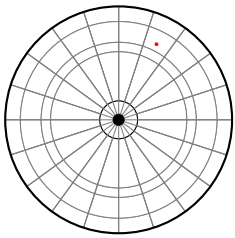


Figura 3.2: La probabilidad de que el dardo caiga *exactamente* en el punto rojo es 0, y sin embargo es posible

Las VA también pueden ser continuas. Una VA es continua si su recorrido es continuo. La gran particularidad de una VA continua es que, si X es una VA continua,

$$\mathrm{P}(X = x_0) = 0$$

para cualquier valor x_0 de la variable.

Esto nos obliga a buscar una manera alternativa de definir la probabilidad. Lo que podemos hacer es darnos cuenta que nos va a interesar obtener la probabilidad en algún tipo de *sección* (un intervalo, un área, una cierta duración, etc). En otras palabras, usaremos una *densidad* de probabilidad.

Definición 3.3.1 *La función de densidad de probabilidad de una VA continua es la función $f(x)$ que cumple con*

$$\mathrm{P}(a \leq x \leq b) = \int_a^b f(t)\,dt$$

Una función de densidad de probabilidad debe cumplir con dos condiciones

1. $f(x) \geq 0,\ \forall x \in \mathbb{R}$.
2. $\int_{-\infty}^{\infty} f(x)\,dx = 1$.

Al igual que en caso discreto, podemos definir la función de probabilidad acumulada como

$$F(x) = P(X \leq x) = \int_{-\infty}^{x} f(t)\,dt$$

3.4 Esperanza y varianza

Aunque una variable aleatoria no es realmente aleatoria, tampoco sabemos exactamente cuál va a ser su resultado. Lo que sí podemos saber (al menos en teoría) es la distribución de probabilidad de la VA. En base a esa información, podemos aspirar a obtener un resultado *esperado* al ocurrir el experimento o proceso que da origen a la VA.

¡Hey!

Si lanzara un dado justo miles de veces y promediara todos los resultados, ¿qué número esperaría obtener?

Ese resultado esperado nos da de alguna manera un *centro* desde el que comenzar a hablar. Es como si entrecerráramos los ojos y viéramos la parte "más importante" de la distribución. Es la señal que nos manda la variable aleatoria junto con su distribución de probabilidad.

Pero el centro no nos cuenta toda la historia. También es importante hablar del *despliegue* de los datos, ver de qué manera se "desparraman" las probabilidades. Pero para esto necesitamos un punto de referencia, el que nos va a proveer el centro.

3.4.1 Definición de la esperanza y sus propiedades

Vamos a definir la *esperanza* de una variable aleatoria como el promedio ponderado de los valores posibles de la variable aleatoria, pero ponderados por la probabilidad de cada uno. En el caso de una

VA discreta,

$$\begin{aligned}\mathrm{E}(X) &= \sum_i x_i \,\mathrm{P}(X = x_i) \\ &= \sum_{\omega\in\Omega} X(\omega)\,\mathrm{P}(\omega)\end{aligned}$$

donde x_i se toma a través de todos los valores de la VA. En el caso de una VA continua,

$$\mathrm{E}(X) = \int_{-\infty}^{\infty} x f(x)\,dx$$

donde $f(x)$ es la densidad de probabilidad de la variable aleatoria.

La esperanza es lineal, es decir si a es una constante y X e Y son dos VA,

$$\mathrm{E}(aX + Y) = a\,\mathrm{E}(X) + \mathrm{E}(Y)\,.$$

La demostración es análoga en los casos discreto y continuo, así que haremos la demostración del caso discreto.

$$\begin{aligned}\mathrm{E}(aX + Y) &= \sum_{\omega\in\Omega} (aX + Y)(\omega)\,\mathrm{P}(\omega) \\ &= \sum_{\omega\in\Omega} (aX(\omega) + Y(\omega))\,\mathrm{P}(\omega) \\ &= \sum_{\omega\in\Omega} aX(\omega)\,\mathrm{P}(\omega) + \sum_{\omega\in\Omega} Y(\omega)\,\mathrm{P}(\omega) \\ &= a\sum_{\omega\in\Omega} X(\omega)\,\mathrm{P}(\omega) + \sum_{\omega\in\Omega} Y(\omega)\,\mathrm{P}(\omega) \\ &= a\,\mathrm{E}(X) + \mathrm{E}(Y)\end{aligned}$$

Otra propiedad de la esperanza es que podemos aplicar funciones a nuesta VA y calcular la esperanza de esta composición

$$\mathrm{E}(g(X)) = \sum_i g(x_i)\,\mathrm{P}(X = x_i).$$

Normalmente, simbolizaremos la esperanza de una variable aleatoria por μ. Si queremos ser específicos, por ejemplo simbolizar que la esperanza se refiere a la VA Z y no a la VA X, podemos poner un subíndice como μ_Z.

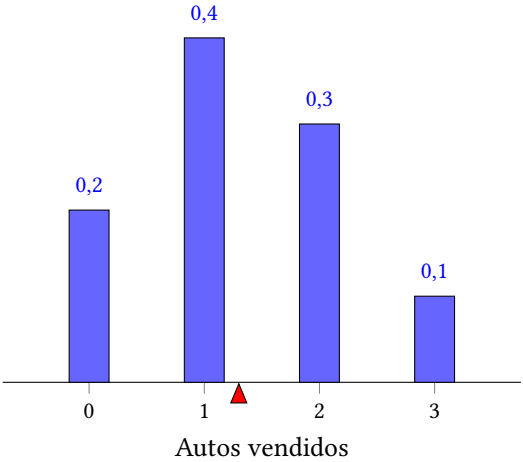
La propiedad más importante de la esperanza, sin embargo, es su significado. La esperanza actúa como el *centro de masa* de la distribución de probabilidad. ¿Qué significa esto? Imaginemos que tenemos una VA que representa la cantidad de autos vendidos por día en una distribuidora con la siguiente distribución de probabilidad

x	0	1	2	3
$P(X = x)$	0,2	0,4	0,3	0,1

La esperanza de esta variable aleatoria nos diría, en promedio, cuántos autos se venden por día. En este caso, podemos calcular la esperanza como

$$\mathrm{E}(X) = \sum_{i=0}^{3} x_i P(X = x_i) = 0{\cdot}0{,}2 + 1{\cdot}0{,}4 + 2{\cdot}0{,}3 + 3{\cdot}0{,}1 = 1{,}3.$$

Si graficamos la función de masa de probabilidad junto con la esperanza, tenemos lo siguiente



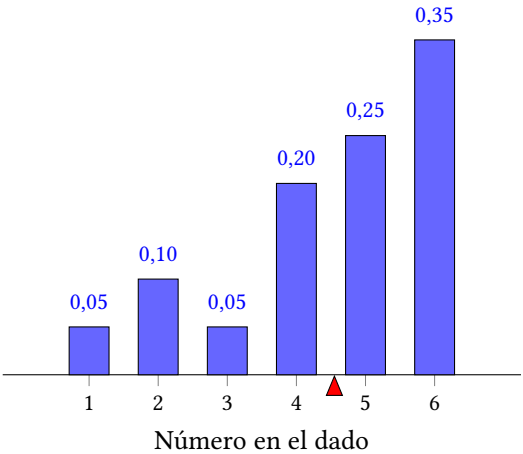
Si ponemos el punto de apoyo de un balancín con esas masa en la esperanza, el balancín estará equilibrado. ¿Qué pasaría si tuviéramos una distribución más "cargada" para un lado?

x	1	2	3	4	5	6
$P(X = x)$	0,05	0,1	0,05	0,2	0,25	0,35

Grafiquemos esta distribución [2] de probabilidad

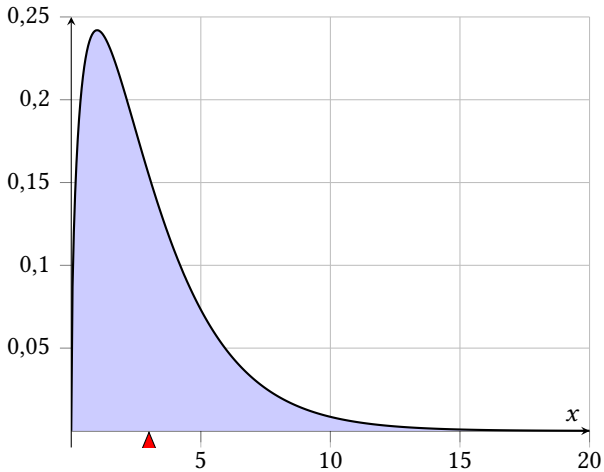
2: La esperanza de esta distribución es

$$1 \cdot 0{,}05 + 2 \cdot 0{,}1 + 3 \cdot 0{,}05 + \\ +4 \cdot 0{,}2 + 5 \cdot 0{,}25 + 6 \cdot 0{,}35 = 4{,}55$$



La esperanza está más cerca de los valores con mayor probabilidad. Estos "pesan" más, pero los valores que pesan menos los equilibran (piense en el torque).

En el caso de una VA continua ocurre básicamente lo mismo. Si graficamos una función de densidad de probabilidad podemos ver que la esperanza "equilibra" la lámina de color que está puesta encima del eje. En este caso, aunque el gráfico termina en $x = 20$ la distribución está definida para $x \in [0, \infty[$.



3.4.2 Definición de la varianza y sus propiedades

La varianza de una VA X se define como

$$\mathrm{Var}\,(X) = \mathrm{E}\left((X-\mu)^2\right)$$

donde $\mu = \mathrm{E}\,(X)$. Se simboliza como $\mathrm{Var}\,(X)$ o bien σ_X^2 (el subíndice se puede omitir si es claro a qué VA nos referimos).

Notemos algunas cosas. Primero, la varianza depende del valor de la esperanza. De hecho, la varianza *es* un tipo de esperanza. El término $(X-\mu)^2$ es una especie de distancia para cada valor de X a la esperanza y al tomar la esperanza de este término, estamos tomando la distancia esperada a la esperanza o, en otras palabras la *distancia promedio* al centro de la distribución.

Hay que considerar algo: ni la esperanza es la única definición posible de centro de una distribución ni la varianza la única definición de dispersión. Sin embargo, son las más útiles, al menos para partir.

Si calculamos la varianza del ejemplo de los autos vendidos que vimos en la esperanza,

x	0	1	2	3
$P(X = x)$	0,2	0,4	0,3	0,1

cuya esperanza era 1,3 entonces podríamos calcular la varianza como

$$\begin{aligned}
\operatorname{Var}(X) &= \operatorname{E}\left((X - 1{,}3)^2\right) \\
&= \sum_{i=0}^{3} (x_i - 1{,}3)^2 \operatorname{P}(X = x_i) \\
&= (0 - 1{,}3)^2 \cdot 0{,}2 + (1 - 1{,}3)^2 \cdot 0{,}4 + (2 - 1{,}3)^2 \cdot 0{,}3 + (3 - 1{,}3)^2 \cdot 0{,}1 \\
&= 1{,}69 \cdot 0{,}2 + 0{,}09 \cdot 0{,}4 + 0{,}49 \cdot 0{,}3 + 2{,}89 \cdot 0{,}1 \\
&= 0{,}338 + 0{,}036 + 0{,}147 + 0{,}289 \\
&= 0{,}81
\end{aligned}$$

Claramente es bastante largo. Sin embargo, hay una forma más sencilla de calcular la varianza. Notemos que

$$\begin{aligned}
\operatorname{Var}(X) &= \operatorname{E}\left((X - \mu)^2\right) \\
&= \operatorname{E}\left(X^2 - 2X\mu + \mu^2\right) \\
&= \operatorname{E}\left(X^2\right) - 2\mu \operatorname{E}(X) + \mu^2 \\
&= \operatorname{E}\left(X^2\right) - \mu^2
\end{aligned}$$

donde $\mu = \operatorname{E}(X)$. En otras palabras, la varianza es también la diferencia entre la esperanza del cuadrado de la variable aleatoria y el cuadrado de la esperanza de la variable aleatoria.

En el ejemplo,

$$0^2 \cdot 0{,}2 + 1^2 \cdot 0{,}4 + 2^2 \cdot 0{,}3 + \\ + 3^2 \cdot 0{,}1 - 1{,}3^2 = 0{,}81$$

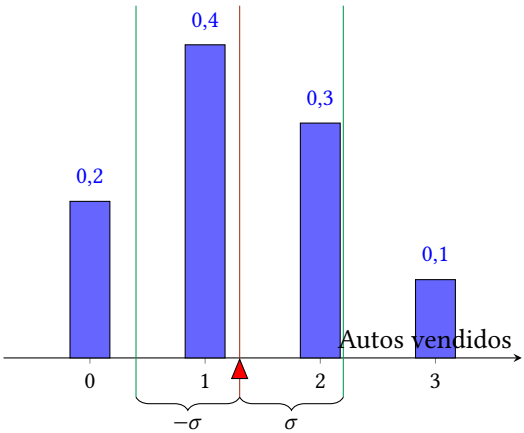
Un problema que tiene la varianza es que la unidad de medida es el cuadrado de la unidad de medida de la variable aleatoria. En nuestro ejemplo, la medida de la variable aleatoria es *autos vendidos*, pero la unidad de medida de la varianza es *autos vendidos al cuadrado*. Para evitar este problema, normalmente trabajamos con la desviación estándar, que es simplemente la raíz cuadrada de la varianza. En nuestro ejemplo, la desviación estándar sería $\sqrt{0{,}81} = 0{,}9$ autos vendidos.

La desviación estándar de una VA X se define como $\sigma_X = \sqrt{\text{Var}(X)}$.

La gran ventaja de la desviación estándar es que está en la misma unidad de medida que la variable aleatoria. Esto permite interpretarla y graficarla. En el ejemplo,

$$\sigma_X = \sqrt{0{,}81} = 0{,}9$$

autos vendidos. Podemos graficar la distribución de probabilidad junto con la esperanza y la desviación estándar.



¿Cómo interpretamos esto? Tenemos que interpretarlo en conjunto. La esperanza es 1,3 y la desviación estándar es 0,9. Esto quiere decir que esperamos vender 1,3 autos por día, pero que la mayoría de los días vamos a vender entre 0,4 y 2,2 autos (es decir, entre $\mu - \sigma$ y $\mu + \sigma$).

Desigualdad de Chebyshev

Una forma muy general para entender la desviación estándar es a través de la desigualdad de Chebyshev. Si tenemos una VA con varianza finita σ^2 (y por lo tanto esperanza finita), la probabilidad de que la variable aleatoria se aleje de su esperanza en más de

k veces la desviación estándar es al menos $1 - 1/k^2$. En otras palabras,

$$\mathrm{P}(\mu - k\sigma < X < \mu + k\sigma) \geq 1 - \frac{1}{k^2}.$$

Esto es *muy general*. Es tan general que, de hecho, cuando $k = 1$ no nos dice nada

$$\mathrm{P}(\mu - \sigma < X < \mu + \sigma) \geq 1 - \frac{1}{1^2} = 0$$

lo que ya... sabíamos. Cuando $k = 2$, la desigualdad nos dice que al menos el 75% de los valores están dentro de dos desviaciones estándar de la media y eso ya es más útil. Sin embargo, cuando conozcamos distribuciones particulares, generalmente podremos decir cosas más precisas.

3.5 ¿Qué significa sumar variables aleatorias? (opcional)

Partimos este capítulo con la variable aleatoria que nace al sumar los puntos de tirar los dados

$$\begin{aligned} X \ &: \{1,2,3,4,5,6\} \times \{1,2,3,4,5,6\} \to \{2,\dots,11,12\} \\ &(\omega_1, \omega_2) \to \omega_1 + \omega_2 \end{aligned}$$

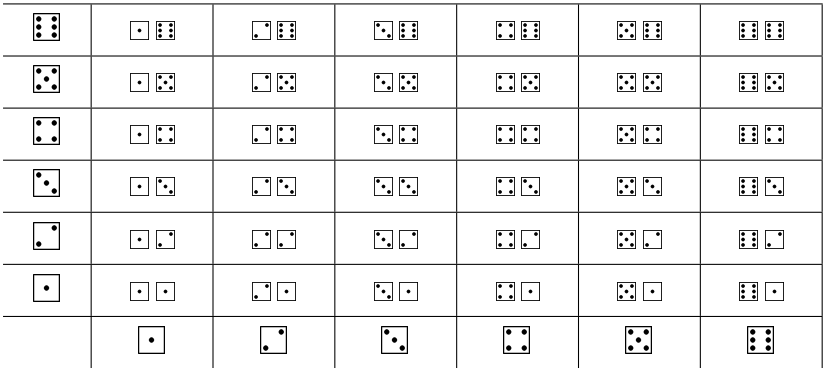
y en algún momento se comentó[3] que podemos entender esta VA como la suma de dos variables aleatorias

3: en clase

$$X = X_1 + X_2$$

donde X_i es el resultado al lanzar el dado i. Sin embargo, cada una de esas variables aleatorias tiene un dominio distinto del de X: el dominio de X_1 es $\{1,2,3,4,5,6\}$. ¿Cómo entonces la suma puede darnos un dominio como $\{1,2,3,4,5,6\} \times \{1,2,3,4,5,6\}$?

Primero, al lanzar los dos dados efectivamente nuestro espacio muestral es $\{1, 2, 3, 4, 5, 6\} \times \{1, 2, 3, 4, 5, 6\}$.

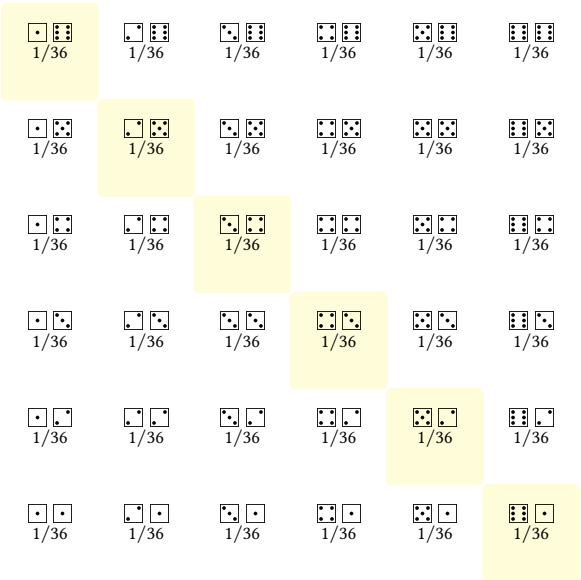


Si los dados son justos y los lanzamientos son independientes, la probabilidad de obtener un resultado cualquiera es $1/36$. Esto podemos obtenerlo, por ejemplo, como

$$\mathrm{P}(\square\square) = \mathrm{P}(4) \cdot \mathrm{P}(3) = \frac{1}{6} \cdot \frac{1}{6}.$$

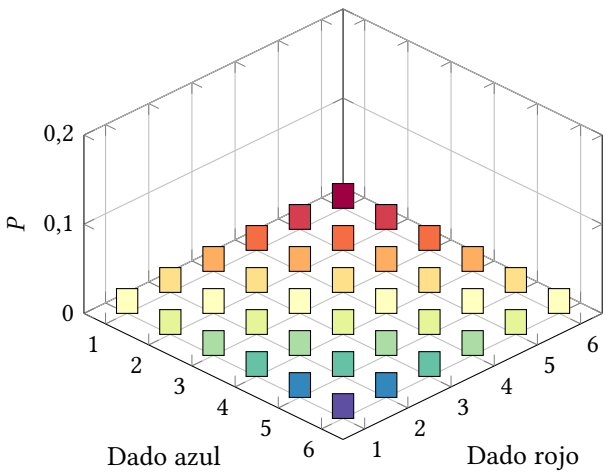
Ahora bien, nuestra variable aleatoria era el resultado de esta operación, y eso tiene distintas probabilidades. En particular, la probabilidad de obtener un resultado va a ser sumar las probabilidades de todas las posibles configuraciones que dan lugar a ese resultado.

La figura muestra la probabilidad de obtener una suma igual a 7

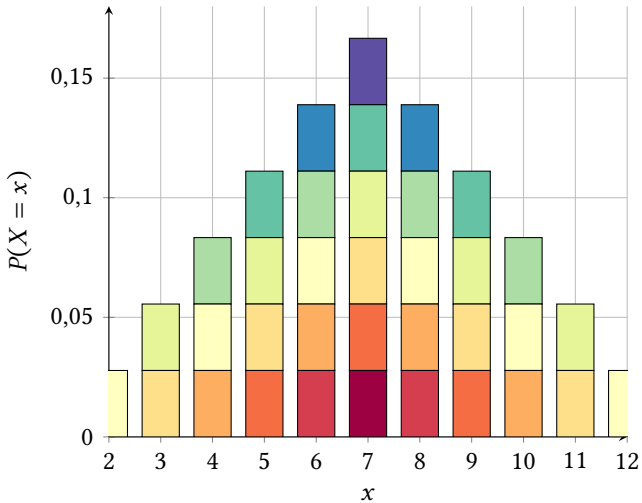


Con eso obtenemos $P(X = 7) = 6/36 = 1/6$.

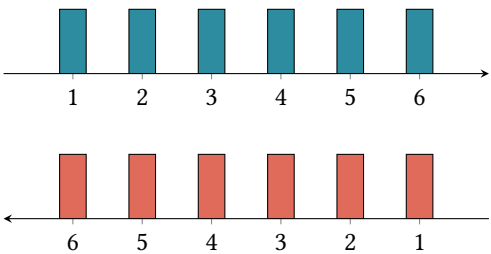
¿Cómo podríamos obtener esa probabilidad a partir de las probabilidades de cada dado?



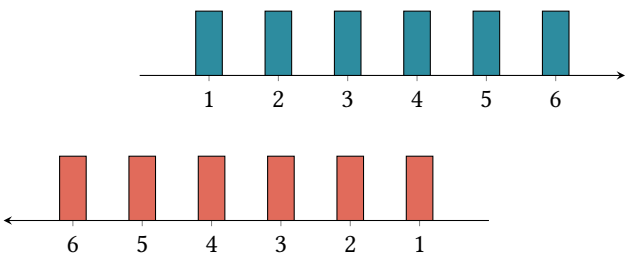
Podemos sumar las probabilidades de cada par de dados para un resultado fijo



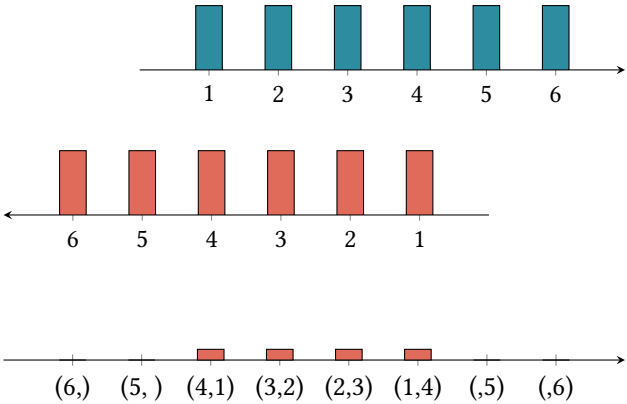
Ahora bien, podemos hacerlo de otra forma que explica mejor el dominio. Imaginemos que tenemos las dos distribuciones, una para cada dado, pero *damos vuelta* una de ellas, digamos la del dado rojo



y ahora corremos los ejes de manera de obtener siempre un valor fijo, por ejemplo $x = 5$.



y multiplicamos la columna de arriba con la de abajo



y ahora sumamos: $4 \cdot \frac{1}{36} = \frac{4}{36}$.

Podemos simbolizar esto que acabamos de hacer como

$$\sum_{i=1}^{6} \mathrm{P}(X = i) \cdot \mathrm{P}(Y = 5 - i) = 4 \cdot \frac{1}{36} = \frac{4}{36}$$

y si variamos el valor fijo 5 por cualquier otro valor x, obtenemos la probabilidad de obtener ese valor x al sumar las dos variables aleatorias X e Y

$$\mathrm{P}(X + Y = x) = \sum_{i=1}^{6} \mathrm{P}(X = i) \cdot \mathrm{P}(Y = x - i)$$

Esta operación se llama *convolución* y es una operación muy importante en probabilidad. En particular, si X e Y son independientes, la probabilidad de la suma es la convolución de las probabilidades individuales.

La convolución de dos funciones es una operación que no sólo se usa en probabilidades, si no que también en otros campos, como procesamiento de imágenes y de señales, procesamiendo digital, etc. Por

ejemplo, un filtro como el de desenfoque de imágenes es una convolución.

El zoológico de las variables aleatorias, parte 1

4

Idea central

En la naturaleza y la ingeniería, ciertos patrones de aleatoriedad discreta aparecen una y otra vez. ¿Cuáles son esos patrones y qué tipo de fenómenos modelan? En este capítulo conocemos las distribuciones discretas más importantes.

En el mundo[1] hay una infinidad y variedad de hechos que podrían estudiarse como variables aleatorias. En principio, deberíamos estudiar cada uno de ellos de manera individual, pero eso sería demasiado difícil. Lo que conviene más es ver si podemos abstraer detalles para quedarnos con los hechos más importantes y generalizar.

1: realidad, naturaleza, universo, cosmos o como quiera llamarlo según su tendencia filosófica

De esta manera podemos llegar a varios *modelos de probabilidad* para estudiar diversas variables aleatorias. En este capítulo estudiaremos varios modelos discretos, bajo qué condiciones se pueden aplicar y qué tipo de VA quieren modelar. En el siguiente capítulo continuaremos nuestro paseo pero por modelos continuos. Si bien estudiaremos varias distribuciones, hay varias más que quedarán fuera del alcance de este curso. Para los y las interesados, eventualmente habrá un apéndice con alguna descripción de estas distribuciones.

4.1 Distribución de Bernoulli

Probablemente el modelo de probabilidad más sencillo, la distribución de Bernoulli (o dicotómica) es una con la que, para ser sinceros, nos encontramos desde la primera clase.

Si tenemos un experimento aleatorio, podemos entender su resultado desde el punto de vista de *éxito* o *fracaso.* El ejemplo clásico es la moneda. Queremos que salga cara y, si sale cara, tenemos un éxito. Si sale sello, tenemos un fracaso.

Pero fenómenos más complejos se pueden reducir a esta perspectiva de éxito-fracaso. Un ejemplo que me dio un estudiante: quiero que mi equipo gane el partido. Si no gana (pierda o empate), eso es un fracaso. Imagínense estudiar eso desde el punto de vista de todos los resultados posibles (0-0, 1-0, 0-1, 1-1, 2-0,...). Sería una locura.

Incluso, este lenguaje de éxito-fracaso puede ser todo lo contrario en la realidad. Puedo definir mi éxito como encontrar un resultado positivo en un examen, lo que seguramente para el paciente sería algo negativo, porque sugeriría[2] que tiene la enfermedad.

2: después del capítulo de Bayes, ya no podemos decir "confirmaría"

En resumen, tenemos algún tipo de evento aleatorio. Ese evento tiene un conjunto de resultados. Definiremos algunos como éxito y el resto como fracaso. De esta manera, definiremos la variable aleatoria

$$X = \begin{cases} 1 & \text{éxito} \\ 0 & \text{fracaso.} \end{cases}$$

Además, la probabilidad de esta variable aleatoria será

$$\mathrm{P}(X = x) = \begin{cases} p & x = 1 \\ 1 - p = q & x = 0. \end{cases}$$

Es muy usual esta notación de $q = 1 - p$ para la probabilidad del fracaso. En el resto del apunte intentaré usarla.

La distribución de Bernoulli en sí misma no es muy interesante, pero la importancia que tiene es que varias distribuciones que sí son interesantes están relacionadas con ella. Pero antes de entrar a eso,

cerremos nuestro estudio de esta distribución y veamos su esperanza y varianza.

La esperanza es muy fácil de calcular

$$\mathrm{E}(X) = \sum_{x=0}^{1} x\,\mathrm{P}(X = x) = 0 \cdot q + 1 \cdot p = p.$$

Es decir, la esperanza de X es p. La varianza es

$$\begin{aligned}
\sigma^2 &= \mathrm{E}\left(X^2\right) - \mathrm{E}(X)^2 \\
&= \sum_{x=0}^{1} x^2\,\mathrm{P}(X = x) - \mathrm{E}(X)^2 \\
&= 0^2 \cdot q + 1^2 \cdot p - p^2 \\
&= p - p^2 \\
&= p(1 - p) = pq
\end{aligned}$$

Estos resultados nos servirán más adelante.

4.2 Variables aleatorias discretas y su relación con VAs Bernoulli

Una VA Bernoulli representa el éxito o fracaso en *una* repetición de un experimento aleatorio. Pero si repetimos el mismo experimento varias veces bajo las siguientes condiciones[3]

1. cada repetición es independiente y
2. la probabilidad de éxito se mantiene constante

tenemos tres tipos de VAs que aparecen naturalmente como respuesta, cada una, a una pregunta distinta.

3: estas condiciones se "inspiran" en procesos reales, por ejemplo fabricar algún tipo de artículo o por ejemplo enviar paquetes de datos y verificar si llegaron bien o no.

Una pregunta que podemos hacernos es, si repito el experimento n veces, ¿cuál es la probabilidad de tener k éxitos? En este caso, podemos entender que

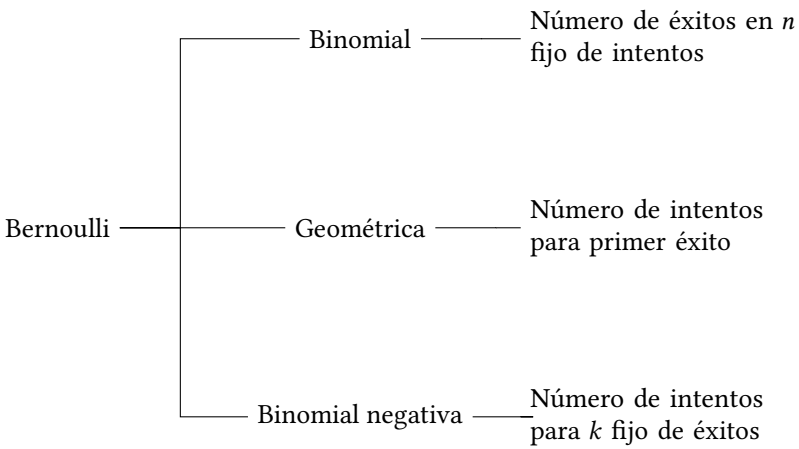


Figura 4.1: Relación entre las variables aleatorias Bernoulli y algunas variables aleatorias discretas.

n es un número fijo y k varía entre 0 y n. Esta pregunta da origen a la distribución de probabilidad *binomial.*

Otra posibilidad es preguntarnos cuántos intentos nos demoraremos en tener nuestro primer éxito. Esta pregunta da origen a la distribución de probabilidad *geométrica.* En este caso n, el número de intentos, es variable y queremos tener un número fijo de éxitos, 1.

Una tercera posibilidad es preguntarnos cuántos intentos nos tomará obtener un cierto número fijo de éxitos. Esta pregunta da origen a la distribución *binomial negativa.* En este caso n, el número de intentos, es variable y el número de éxitos, k, es fijo.

Estas relaciones aparecen resumidas en la Figura 4.1.

Existe otra relación. ¿Qué pasa si relajamos la necesidad de independencia? Podemos imaginar que tenemos el experimento aleatorio de sacar pelotas

de una caja. Con reposición significa que lo hacemos con independencia, porque las probabilidades vuelven a ser las mismas. Pero si lo hacemos sin reposición, las probabilidades van cambiando. En este caso, la distribución de probabilidad que surge al preguntarnos cuál es la probabilidad de tener k éxitos en n intentos *sin independencia* es la distribución *hipergeométrica.*

Una última relación que podemos establecer es cuando tenemos una cantidad promedio fija de eventos independientes que ocurren en una unidad de tiempo (o espacio, área, volumen, etc.). Por ejemplo, si siempre me llegan en promedio 10 correos de spam por hora, podría calcular la probabilidad de que me lleguen 40 en un día. O, si revuelvo de manera suficientemente buena mi masa, la probabilidad de que la galleta que me voy a comer tenga 5 chips de chocolate si en promedio tienen 3. Eventos de este tipo se modelan con una distribución de *Poisson.*

¡Hey!

¿Qué cree que le ocurre a una distribución binomial cuando n crece mucho y p se achica de manera proporcional, de modo que np permanece constante?

Hay una relación entre la distribución binomial y la de Poisson. Si hacemos muchos intentos ($n \to \infty$) y la probabilidad de éxito de cada uno es pequeña ($p \to 0$) pero de manera que $np = \lambda$ sea constante, entonces la distribución de Poisson aparece como un límite de la distribución binomial.

Con eso, entremos más en detalle en cada una de ellas.

4.3 Distribución binomial

Como se dijo en la sección anterior, la distribución binomial modela la probabilidad de obtener k éxitos en n repeticiones independientes de un experimento, donde cada intento tiene probabilidad de éxito p. En este caso, n es un número fijo que se asume sabido de antemano. p también es un número sabido de antemano. Decimos entonces que n y p son *parámetros*[4] de nuestra distribución.

4: la mejor definición de parámetro se la escuché a un físico: una constante que varía

Pensemos qué significa esto. Si tenemos n intentos y queremos obtener k éxitos, tendremos $n-k$ fracasos. La probabilidad que esto ocurra, sabiendo que cada repetición es independiente es, por lo tanto,

$$p^k q^{n-k}.$$

Sin embargo, ¿de cuántas maneras podemos tener esa cantidad de éxitos y fracasos? Recordando lo que aprendimos en la sección 1.8 (Conteo), esto es equivalente a obtener k elementos de un conjunto con n elementos sin que nos importe el orden

$$\binom{n}{k}.$$

Con esto, entonces, si X es una variable aleatoria con distribución de probabilidad binomial, la probabilidad de obtener k éxitos en n lanzamientos viene dada por

$$\mathrm{P}(X = k) = \binom{n}{k} p^k q^{n-k}.$$

Además, simbolizaremos la idea de que la distribución de probabilidad de X es binomial con parámetros n, k como

$$X \sim \mathrm{Bin}(n, p).$$

el símbolo $\sim$ significa que la variable aleatoria se distribuye como dice la función de la derecha

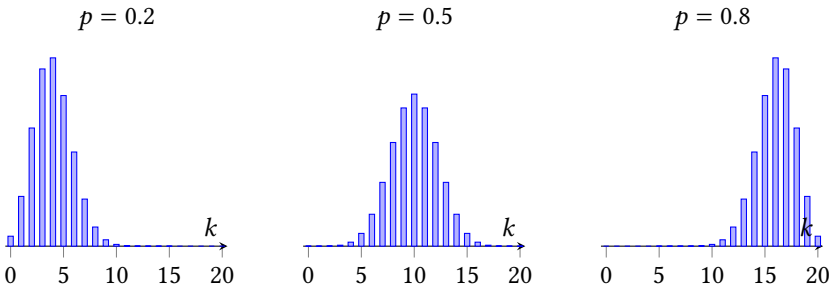


Figura 4.2: Distribución binomial con $n = 20$ y distintos p.

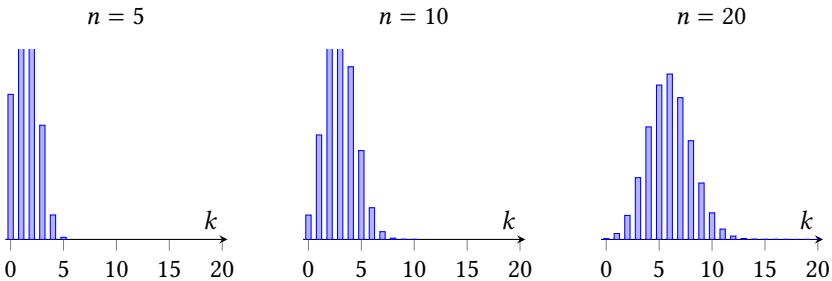


Figura 4.3: Distribución binomial con $p = 0.3$ y distintos n.

Exploremos algunos gráficos para entender cómo se ve esta distribución. En la Figura 4.2 vemos la distribución binomial para $n = 20$ y varios valores de p. Vemos que, para p pequeño, la distribución está "cargada" a la izquierda. Para p grande, está "cargada" a la derecha. Y para $p = 0.5$, es simétrica.

Por otra parte, en la Figura 4.3 vemos la distribución binomial para $p = 0.3$ y varios valores de n. La distribución, al aumentar n se va "expandiendo".

¡Hey!

Si en un experimento binomial $n = 10$ y $p = 0{,}3$, ¿cuántos éxitos esperaría obtener en promedio? ¿Cómo llegaría a ese número intuitivamente?

Para calcular la esperanza y varianza de una binomial, basta pensar que si $X \sim \text{Bin}(n, k)$, entonces

$$X = X_1 + X_2 + \cdots + X_n,$$

con cada X_i una variable aleatoria con distribución de Bernoulli con probabilidad p.

Por lo tanto,

$$\text{E}(X) = \text{E}\left(\sum_{i=1}^{n} X_i\right) = \sum_{i=1}^{n} \text{E}(X_i) = \sum_{i=1}^{n} p = np$$

La varianza sigue un desarrollo parecido. Como cada repetición del experimento es independiente de las otras, entonces

$$\text{Var}(X) = \text{Var}\left(\sum_{i=1}^{n} X_i\right) = \sum_{i=1}^{n} \text{Var}(X_i) = \sum_{i=1}^{n} pq = npq$$

Hagamos un ejemplo. Se estima que un 30% del total de bicicletas nuevas en una tienda presentan algún defecto de fábrica. Para obtener más información sobre la magnitud del problema, se determina que debe realizarse algún tipo de inspección. Como es muy costoso revisar todas las bicicletas disponibles, se eligen 10 al azar para someterlas a revisión.

1. Si se utiliza la distribución binomial, ¿cuál es la probabilidad de que exactamente 3 bicicletas tengan defectos, considerando que la estimación es correcta?
2. ¿Cuál es la probabilidad de que más de 3 bicicletas tengan defectos?

En este caso, nuestro n es 10, la probabilidad de éxito (que es que una bicicleta esté mala) es 0,3. Por lo tanto,

1. Queremos encontrar $\mathrm{P}(X = 3)$.

$$\begin{aligned}\mathrm{P}(X = 3) &= \binom{10}{3} 0{,}3^3 \cdot 0{,}7^7 \\ &= 0{,}266828\end{aligned}$$

2. Lamentablemente, la función de probabilidad acumulada de una binomial no tiene una forma cerrada, es decir, no se puede escribir como una expresión finita de operaciones o funciones simples. Sin embargo, podemos sumar directamente. En este caso, como es más corto sumar desde 0 a 3 (4 sumandos) versus sumar desde 4 a 10 (7 sumandos), usaremos el complemento.

$$\begin{aligned}\mathrm{P}(X > 3) &= 1 - \mathrm{P}(X \leq 3) \\ &= 1 - \sum_{i=0}^{3} \binom{10}{i} 0{,}3^i \cdot 0{,}7^{10-i} \\ &= 1 - (0{,}0282475 + 0{,}121061 + 0{,}233474 + 0{,}266828) \\ &= 1 - 0{,}649611 \\ &= 0{,}350389\end{aligned}$$

Por otra parte, la idea de que el 30 % de las bicicletas nuevas presentan defectos es solo una estimación del encargado de calidad de la tienda. Supongamos que se eligen 10 bicicletas de forma aleatoria y resulta que 6 presentan defectos. ¿Qué implica esto respecto de la estimación inicial?

La pregunta que debemos hacernos es: ¿es consistente con la estimación de que el 30 % de las bicicletas presentan defectos? Para responder, podemos calcular la probabilidad de obtener al menos 6 defectuosas en 10 bicicletas, bajo la suposición de que

la proporción real es de 30 %.

$$\begin{aligned} \mathrm{P}(X \geq 6 \mid p = 0{,}3) &= \sum_{i=6}^{10} \binom{10}{i} 0{,}3^i \cdot 0{,}7^{10-i} \\ &= 0{,}0367569 + 0{,}00900169 + 0{,}0014467 + \\ &\quad + 0{,}000137781 + 5{,}9049 \times 10^{-6} \\ &= 0{,}047349 \approx 5\,\% \end{aligned}$$

Es poco probable que encontremos 6 bicicletas malas dado que la conjetura es cierta, es decir, que el 30 % de las bicicletas están malas. Esto sugiere que el problema es más grave.[5]

5: exploraremos más esta idea en estadística inferencial

4.4 Distribución geométrica

Como vimos antes, la distribución geométrica modela la probabilidad de obtener el primer éxito en el intento número n. Tenemos que tener ojo aquí: la variable aleatoria ahora es el número de intentos, lo que en la binomial estaba fijo.

No cuesta mucho encontrar la función de masa. Si nuestro primer intento exitoso es el intento n, eso quiere decir que los primeros $n - 1$ intentos fueron fracasos. Es decir, tenemos $n - 1$ intentos seguidos y *un* éxito justo al final. Por lo tanto, si $X \sim \mathrm{Geom}(n, p)$, entonces

$$\mathrm{P}(X = n) = pq^{n-1}.$$

También podemos calcular la probabilidad acumulada

$$\begin{aligned} P(X \leq n) &= \sum_{i=1}^{n} pq^{i-1} \\ &= p \sum_{i=1}^{n} q^{i-1} \\ &= p \sum_{i=0}^{n-1} q^{i} \\ &= p \frac{q^n - 1}{q - 1} \\ &= p \frac{(1-p)^n - 1}{(1-p) - 1} \\ &= 1 - (1-p)^n \\ &= 1 - q^n \end{aligned}$$

aunque en vez de haber calculado, podríamos haber pensado en lo siguiente: la probabilidad de obtener el primer éxito al menos en el intento n es

$$q^{n-1}$$

porque no hubo ningún éxito en los primeros $n-1$ intentos. Por lo tanto

$$\mathrm{P}(X \geq n) = q^{n-1}$$

y entonces

$$\mathrm{P}(X \leq n) = 1 - \mathrm{P}(X \geq n+1) = 1 - q^n.$$

Podemos calcular la esperanza usando un truco ro-

bado de las series

$$\begin{aligned}\mathrm{E}(X) &= \sum_{n=1}^{\infty} npq^{n-1} \\ &= p\sum_{n=1}^{\infty} n(1-p)^{n-1} \\ &= p\left(1(1-p)^0 + 2(1-p)^1 + 3(1-p)^2 + \cdots\right)\end{aligned}$$

multiplicando a ambos lados por $1-p$

$$(1-p)\,\mathrm{E}(X) = p\left(1(1-p)^1 + 2(1-p)^2 + 3(1-p)^3 + \cdots\right)$$

restando

$$\begin{aligned}\mathrm{E}(X) - (1-p)\,\mathrm{E}(X) &= p\left(1 + (1-p)^1 + (1-p)^2 + (1-p)^3 + \cdots\right) \\ p\,\mathrm{E}(X) &= p\left(1 + (1-p)^1 + (1-p)^2 + (1-p)^3 + \cdots\right) \\ \mathrm{E}(X) &= \left(1 + (1-p)^1 + (1-p)^2 + (1-p)^3 + \cdots\right)\end{aligned}$$

pero el lado derecho es la serie geométrica, que converge si la razón está entre 0 y 1, como es el caso, por ser p una probabilidad

$$\begin{aligned}\mathrm{E}(X) &= \frac{1}{1-(1-p)} \\ \mathrm{E}(X) &= \frac{1}{p}\end{aligned}$$

La varianza de una distribución geométrica es

$$\mathrm{Var}(X) = \frac{1-p}{p^2}.$$

¿Cómo se ve la distribución geométrica? Hagamos el mismo ejercicio de antes, con algunos parámetros distintos. En la Figura 4.4 vemos la distribución geométrica para varios valores de p. Vemos que, a medida que p aumenta, la distribución se concentra más en los primeros valores de k, es decir, la

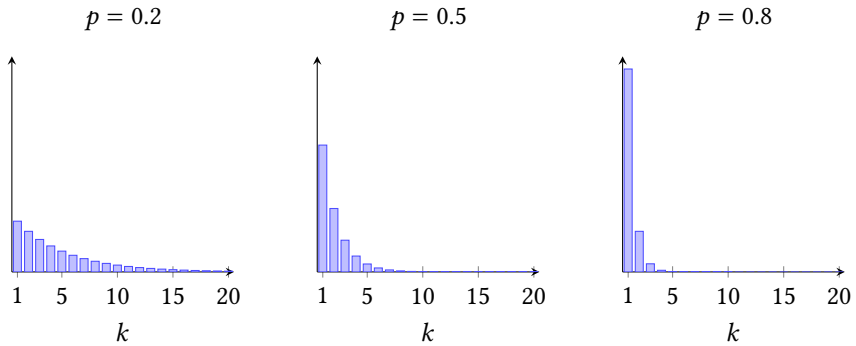


Figura 4.4: Distribución geométrica con distintos p.

probabilidad de obtener un primer éxito "rápido" es mayor.

Además, no cuesta mucho notar la similaridad de este gráfico con los de funciones del estilo a/b^x. De ahí viene el nombre de geométrica.

4.4.1 Otra forma de escribir la distribución geométrica

Hay autores que definen la distribución geométrica no como el número de intentos para el primer éxito (es decir, contando los fracasos y el éxito final), si no como el número de fracasos antes del primer éxito (es decir, sin el éxito final).

Ambas definiciones son equivalentes, pero hay algunas diferencias en lo técnico: usando la definición del número total de intentos, la VA está definida para $x = 1, 2, 3, \ldots$; con la definición del número de fracasos, la VA está definida para $x = 0, 1, 2, \ldots$. Por ejemplo, lograr el éxito en el primer intento es equivalente a tener 0 fracasos, lograr el éxito en el segundo intento es equivalente a tener 1 fracaso, y así sucesivamente.

Hagamos una tabla de comparación entre ambas maneras de definir una VA geométrica:

	Total de intentos	Total de fracasos
Notación	$X \sim \text{Geom}(p)$	$Y \sim \text{Geom}(p)$
Dominio	$x = 1, 2, 3, \ldots$	$y = 0, 1, 2, \ldots$
Función de masa	$P(X = x) = pq^{x-1}$	$P(Y = y) = pq^y$
Función acumulada	$P(X \leq x) = 1 - q^x$	$P(Y \leq y) = 1 - q^{y+1}$
Esperanza	$E[X] = \frac{1}{p}$	$E[Y] = \frac{1-p}{p} = \frac{q}{p}$
Varianza	$\text{Var}(X) = \frac{q}{p^2}$	$\text{Var}(Y) = \frac{q}{p^2}$
Relación	$X = Y + 1$	$Y = X - 1$

Se ven distintos? Sí. Pero son lo mismo. Lo más recomendable es hacerse un pequeño ejemplito para darse cuenta.

En el software, Python con la librería NumPy usa la definición que usamos nosotros (es decir, el total de intentos), mientras que R y Mathematica usan la definición con el número de fracasos. Es conveniente chequear primero antes de usar el software.

4.5 Distribución binomial negativa

Una distribución binomial negativa es una generalización de la distribución geométrica. La diferencia es que, en vez de esperar el primer éxito, esperamos obtener un número k de éxitos. A diferencia de la binomial, donde el número de intentos era fijo, aquí repetiremos los experimentos hasta obtener el número deseado de intentos. La distribución geométrica, por lo tanto, es un caso particular cuando $k = 1$.

Al igual que la geométrica, podemos definirla de una forma alternativa: como el número de fracasos antes de obtener k éxitos. Nos quedaremos en este texto con la definición del párrafo anterior.

Para encontrar la función de masa de probabilidad, pensemos que nuestro número de éxitos k y la probabilidad de éxito de cada intento son parámetros de nuestra distribución. Si tuvimos que hacer n intentos, entonces la probabilidad de obtener k éxitos *de una forma particular* es

$$p^k q^{n-k}.$$

Pero, además, tenemos que obtener el último de nuestros k éxitos en el intento n. Por lo tanto, podemos repartir $k-1$ éxitos en $n-1$ intentos. Como no importa el orden, tenemos

$$\binom{n-1}{k-1}$$

maneras de hacerlo. Por lo tanto, si $X \sim \text{NegBin}(k, p)$ tenemos

$$P(X = n) = \binom{n-1}{k-1} p^k q^{n-k}.$$

Podemos entender la distribución binomial negativa como una suma de distribuciones geométricas independientes. En efecto, nuestra situación es algo como

$$\underbrace{FFFFE}_{\text{geom}}\underbrace{FFFFFFFE}_{\text{geom}} \underbrace{\cdots E}_{\text{geoms}} \underbrace{FFE}_{\text{geom}}$$

por lo que si $X \sim \text{NegBin}(k, p)$ entonces

$$X = X_1 + X_2 + \cdots + X_k$$

con cada $X_i \sim \text{Geom}(p)$. Esto hace muy fácil el cálcu-

lo de la esperanza y la varianza:

$$\mathrm{E}(X) = k\frac{1}{p}$$
$$\mathrm{Var}(X) = k\frac{q}{p^2}$$

Por ejemplo, un encuestador telefónico puede terminar su jornada cuando ha completado veinte encuestas. El problema es que la probabilidad que alguien complete la encuesta es baja, digamos 0,2. ¿Cuál será la probabilidad que logre completar sus encuestas cuando ha llamado a 50 personas?

Tenemos aquí que X, el número de intentos para completar 20 encuestas, sigue una distribución binomial negativa,

$$X \sim \mathrm{NegBin}(20; 0{,}2).$$

Queremos encontrar

$$P(X = 50)$$

y para eso no necesitamos hacer nada más que

$$P(X = 50) = \binom{49}{19} 0{,}2^{20} \cdot 0{,}8^{30} = 0{,}000245$$

lo que es bastante bajo. ¿Por qué? Si calculamos la esperanza,

$$E(X) = 20\,\frac{1}{0,2} = 100.$$

Parece que el encuestador va a tener que hacer muchas llamadas antes de poder terminar la jornada.

4.6 Distribución hipergeométrica

Así como la distribución binomial representa la probabilidad de obtener k éxitos en n intentos *con independencia entre cada intento,* podemos calcular pero sin suponer independencia. En otras palabras, la distribución binomial saca pelotas de cajas *con reposición* y ahora vamos a sacar las pelotas de la caja *sin reposición.*

Volvamos un poco a nuestra infancia y supongamos que luego de una piñata, nos quedamos con 9 dulces, de los que 4 son con sabor a manzana. Los papás nos dejan sacar 3 dulces a la vez. ¿Cuál será la probabilidad de sacar exactamente 2 dulces de manzana?

Para sacar 3 dulces de 9 tenemos $\binom{9}{3}$ formas y necesitamos 2 dulces de manzana de 4, lo que da $\binom{4}{2}$ formas, mientras que de los otros cinco dulces, necesitamos uno de ellos, que podemos escoger de $\binom{5}{1}$ formas. Por lo tanto,

$$\mathrm{P}(X = 2) = \frac{\binom{4}{2}\binom{5}{1}}{\binom{9}{3}}$$

Extrapolando de este ejemplo, diremos que la VA X, la cantidad de éxitos que obtenemos al sacar n elementos de una bolsa con N elementos, de los que r son éxitos y lo hacemos sin reemplazo sigue una distribución de probabilidad hipergeométrica: $X \sim \mathrm{Hip}(N, r, n)$ cuya función de masa viene dada por

$$\mathrm{P}(X = x) = \frac{\binom{r}{x}\binom{N-r}{n-x}}{\binom{N}{n}},\ 0 \leq x \leq r,\ 0 \leq n - x \leq N - r.$$

La esperanza de esta distribución viene dada por

$$\mathrm{E}(X) = n\frac{r}{N}.$$

mientras que la varianza viene dada por

$$\mathrm{Var}(X) = n\frac{r}{N}\frac{N-r}{N-1}.$$

4.7 Distribución de Poisson

La distribución de Poisson es una de esas ideas que, siendo simple en la superficie, tiene conexiones profundas con otras áreas. Una manera de llegar a ella es definiendo un *proceso de Poisson*. Un proceso de Poisson es un proceso estocástico (una sucesión de variables aleatorias) indexadas por $t \in \mathbb{R}_0^+$, de manera que $X(t)$ es la cantidad de sucesos que ocurre en el intervalo $[0, t]$ que cumple las siguientes condiciones:

1. Los eventos ocurren de manera independiente entre sí.
2. La tasa promedio de ocurrencia de eventos es constante en el tiempo.
3. La probabilidad de que ocurran dos o más eventos en un intervalo de tiempo infinitesimal es despreciable.
4. En el tiempo 0, no ha ocurrido ningún evento: $X(0) = 0$.

De un proceso de este tipo emergen dos VAs, el tiempo entre eventos (que estudiaremos más adelante) y la cantidad de eventos en un periodo dado. Esta última VA sigue una distribución de probabilidad de Poisson.

El punto 2 es importante: si la tasa de eventos es constante en el tiempo, ese será nuestro parámetro. Es un parámetro un poco exótico, si lo pensamos bien. Por ejemplo, una tasa constante en el tiempo

es 5 eventos *por hora*. Es decir, hay un espacio de tiempo en que estos eventos ocurren.[6]

6: un ejercicio favorito es decir "si ocurren en promedio 5 eventos por hora, ¿cuál es la probabilidad de que ocurran 100 en un día?" lo que implica ajustar el parámetro.

La función de masa de probabilidad se puede derivar desde la de la distribución binomial (!). En efecto, un proceso de Poisson corresponde al límite cuando mantenemos una relación constante entre n, el número de eventos, y p, la probabilidad de éxito. Si $\lambda = np$, tomando el límite

$$\lim_{n\to\infty} \text{Bin}\left(n, \frac{\lambda}{n}\right)$$

obtenemos una nueva distribución. Esta es la distribución de Poisson con parámetro λ

$$X \sim \text{Poi}(\lambda).$$

La función de masa de probabilidad viene dada por

$$\text{P}(X = x) = \frac{\lambda^x}{x!} e^{-\lambda}.$$

Su esperanza es λ y su varianza también es λ.

Podemos calcular la esperanza como sigue

$$\begin{aligned}
\text{E}(X) &= \sum_{x=0}^{\infty} x \frac{\lambda^x}{x!} e^{-\lambda} \\
&= \sum_{x=1}^{\infty} \frac{\lambda^x}{(x-1)!} e^{-\lambda} \\
&= \sum_{x=1}^{\infty} \lambda \frac{\lambda^{x-1}}{(x-1)!} e^{-\lambda} \\
&= \lambda \sum_{x=1}^{\infty} \frac{\lambda^{x-1}}{(x-1)!} e^{-\lambda}
\end{aligned}$$

pero esta última expresión no es más que reescribir la suma de la función de masa a través de todo el dominio

$$= \lambda \cdot 1 = \lambda$$

Para calcular la varianza, podemos notar que

$$\mathrm{E}\left(X^2\right) = \mathrm{E}\left(X(X-1)\right) + \mathrm{E}\left(X\right)$$

por la linealidad de la esperanza. Además,

$$\begin{aligned}\mathrm{E}\left(X(X-1)\right) &= \sum_{x=0}^{\infty} x(x-1)\frac{\lambda^x}{x!}e^{\lambda} \\ &= \sum_{x=2}^{\infty} \frac{\lambda^x}{(x-2)!}e^{\lambda} \\ &= \lambda^2 \sum_{x=2}^{\infty} \frac{\lambda^{x-2}}{(x-2)!}e^{\lambda}\end{aligned}$$

pero por el mismo argumento anterior

$$= \lambda^2$$

Por lo tanto, $\mathrm{E}\left(X(X-1)\right) + \mathrm{E}\left(X\right) = \lambda^2 + \lambda$ y entonces

$$\mathrm{Var}\left(X\right) = \mathrm{E}\left(X^2\right) - \mathrm{E}\left(X\right)^2 = \mathrm{E}\left(X(X-1)\right) + \mathrm{E}\left(X\right) - \mathrm{E}\left(X\right)^2 = \lambda^2 + \lambda - \lambda^2 = \lambda$$

Supongamos que en Santiago nacen dos guaguas cada media hora. ¿Cuál será la cantidad esperada de guaguas que nazcan en un día? ¿Y qué probabilidad habrá de que en una hora nazcan 6?

Para responder la primera pregunta, debemos encontrar *el parámetro que corresponde.* En principio λ es 2, pero eso es *cada media hora.* Por lo tanto,

$$\frac{2 \text{ nacimientos}}{1 \text{ media hora}} \cdot \frac{48 \text{ medias horas}}{1 \text{ día}} = 96 \frac{\text{nacimientos}}{\text{día}},$$

por lo que esperamos 96 nacimientos en un día.

Del mismo modo, no cuesta ver que $\lambda = 4$ nacimientos por hora. Por lo tanto, la probabilidad de que en una hora nazcan 6 guaguas es

$$P(X = 6) = \frac{4^6}{6!}e^{-4} = \frac{4096}{720}0{,}0183156389 = 5{,}6888888889 \cdot 0{,}0183156389 = 0{,}1041956346.$$

Casi que por definición, si tenemos dos variables aleatorias independientes X e Y que siguen una distribución de Poisson

$$X \sim \text{Poi}(\lambda_1), \quad Y \sim \text{Poi}(\lambda_2)$$

entonces su suma también seguirá una distribución de Poisson

$$X + Y \sim \text{Poi}(\lambda_1 + \lambda_2).$$

Por ejemplo, si X es el número de guaguas nacidas en Santiago, con $\lambda_1 = 4$ guaguas por hora, e Y es el número de guaguas nacidas en Curicó, con $\lambda_2 = 1$ guagua por hora, es relativamente fácil imaginar que esperamos 5 guaguas nacidas por hora entre Santiago y Curicó.

Un proceso de Poisson no solamente ocurre a través del tiempo. Podemos imaginarlo también en extensiones de largo, de área, etc. Por ejemplo, podríamos pensar en fallas a través de una tubería, con un número promedio constante de fallas por kilómetro o mutaciones a lo largo de un cromosoma. También podríamos pensar en píxeles muertos en una pantalla o impactos de granito por metro cuadrado en un techo. Habría que verificar si estos ejemplos se originan de un proceso de Poisson, pero al menos intuitivamente pareciera que sí.

El zoológico de las variables aleatorias, parte 2

5

Idea central

La vida no es sólo contar cosas, si no también medirlas. ¿Qué podremos medir?

5.1 Distribución uniforme

Como reintroducción a las variables continuas, recordemos que a diferencia de las variables discretas, no podemos asignar una probabilidad *a un valor particular* de la variable. En lugar de eso, sólo tiene sentido asignar una probabilidad a un *intervalo*. Esto tiene como consecuencia que no podamos describir una función de probabilidad, como antes, si no que una función de *densidad* de probabilidad.

Una función de densidad de probabilidad nos describirá cómo funcionará la probabilidad en un intervalo a través de su integral. Es decir, si $f(x)$ es una función de densidad de probabilidad, entonces

$$\mathrm{P}\left(a \leq X \leq b\right) = \int_a^b f(x)\, dx.$$

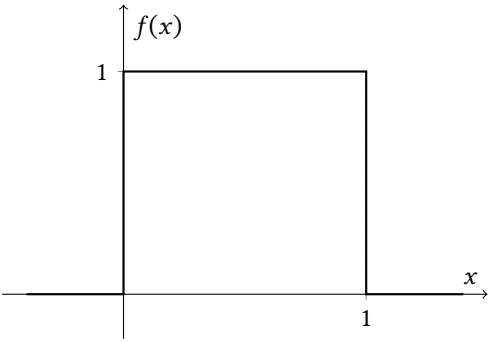
Esto tiene algunas implicancias para f, en particular

1. $f(x) \geq 0$ para todo x en el dominio.
2. $\int_{-\infty}^{\infty} f(x)\, dx = 1$.

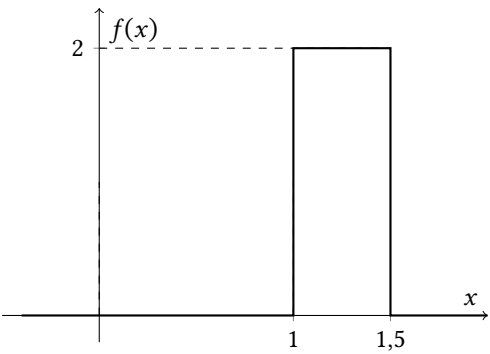
Un caso muy sencillo de variable aleatoria continua es la distribución uniforme. ¿Qué significa que sea uniforme? Significa que si tengo dos intervalos del mismo largo dentro de su dominio, su probabilidad es la misma. Esto implica que si un intervalo es el

doble del largo del otro, su probabilidad es el doble y así en general.

El caso más simple de esta variable es la uniforme entre 0 y 1. No cuesta mucho ver que el gráfico de esta distribución es



y que, por ejemplo, el gráfico de una distribución uniforme entre 1 y 1,5 es



¡Hey!

¿Qué pasó en ese gráfico? ¿Por qué da una función de densidad con valores más grandes que 1*?*

Recordemos que en la página anterior mencionábamos que la integral de esta función debe ser 1 en

todo su dominio. Si integramos la función del último gráfico, vemos que el área bajo la curva es

$$2 \cdot (1{,}5 - 1) = 2 \cdot 0{,}5 = 1.$$

Aquí es importante recordar que la función de densidad de probabilidad representa algo como *probabilidad por unidad de largo*. Es decir, si el eje x hubiera estado en centímetros, podríamos haber interpretado el cálculo anterior como

$$2\,\text{prob/cm} \cdot 0{,}5\,\text{cm} = 1\,\text{prob}$$

con una unidad de probabilidad inventada.

En general, si tenemos una VA X que sigue una distribución de probabilidad uniforme en el intervalo $[a, b]$, su función de densidad vendrá dada por

$$\frac{1}{b-a}.$$

Para encontrar la esperanza podemos hacer la integral

$$\begin{aligned}
\mathrm{E}(X) &= \int_a^b x \frac{1}{b-a}\, dx \\
&= \frac{1}{b-a} \left.\frac{x^2}{2}\right|_a^b \\
&= \frac{1}{b-a} \frac{b^2 - a^2}{2} \\
&= \frac{b+a}{2}
\end{aligned}$$

Por otra parte, para calcular la varianza,

$$\begin{aligned}\mathrm{E}\left(X^2\right) &= \int_a^b x^2 \frac{1}{b-a}\,dx \\ &= \frac{1}{b-a}\,\frac{x^3}{3}\Big|_a^b \\ &= \frac{1}{b-a}\,\frac{b^3-a^3}{3}\end{aligned}$$

simplificando esas expresiones

$$= \frac{a^2+ab+b^2}{3}$$

y por lo tanto, calculando la varianza

$$\begin{aligned}\mathrm{Var}\,(X) = \mathrm{E}\left(X^2\right) - \mathrm{E}\,(X)^2 &= \frac{a^2+ab+b^2}{3} - \left(\frac{b+a}{2}\right)^2 \\ &= \frac{a^2+ab+b^2}{3} - \frac{b^2+2ab+a^2}{4} \\ &= \frac{(b-a)^2}{12}\end{aligned}$$

5.2 Distribución exponencial

La distribución exponencial es otra distribución derivada del proceso de Poisson (ver sección 4.7 (Distribución de Poisson)). A diferencia de la distribución de Poisson, que contaba la cantidad de eventos en un intervalo, la distribución exponencial mide el tiempo entre eventos que se originan por un proceso de Poisson.

La relación entre ambas distribuciones es la siguiente. Si N_t representa el número de sucesos en un intervalo t y X_t el tiempo que se demora que ocurra otro suceso asumiendo que en el tiempo t ocurrió un suceso, entonces los dos siguientes sucesos son

equivalentes

$$X_t > x \quad \text{y} \quad N_t = N_{t+x}.$$

El evento de la izquierda significa que no ha ocurrido ningún suceso en el intervalo $[t, t + x]$. El evento de la derecha significa que el número de eventos ocurridos en el tiempo t es el mismo que el número de eventos ocurridos en el tiempo $t + x$.

Usando la regla del complemento obtenemos

$$\mathrm{P}(X_t \leq x) = 1 - \mathrm{P}(X_t > x)$$

pero esto es equivalente a

$$= 1 - \mathrm{P}(N_{t+x} - N_t = 0)$$

pero, por otra parte,

$$\mathrm{P}(N_{t+x} - N_t = 0) = \mathrm{P}(N_x = 0) = e^{-\lambda x}$$

sustituyendo en nuestra ecuación original

$$\mathrm{P}(X_t \leq x) = 1 - e^{-\lambda x}$$

que es la distribución acumulada de probabilidad de una distribución exponencial. Al derivar obtenemos la función de densidad de probabilidad

$$f(x) = \lambda e^{-\lambda x}.$$

Podemos calcular la esperanza mediante la integral

apropiada.

$$\begin{aligned}
\mathrm{E}(X) &= \int_0^\infty x\lambda e^{-\lambda x}\,dx \\
&= \lambda \int_0^\infty x e^{-\lambda x}\,dx \\
&= \lambda \left[-\frac{x e^{-\lambda x}}{\lambda}\right]_0^\infty + \lambda \int_0^\infty \frac{e^{-\lambda x}}{\lambda}\,dx \\
&= \lambda \cdot 0 + \int_0^\infty e^{-\lambda x}\,dx \\
&= \left[-\frac{e^{-\lambda x}}{\lambda}\right]_0^\infty \\
&= 0 - \left(-\frac{1}{\lambda}\right) \\
&= \frac{1}{\lambda}
\end{aligned}$$

Para calcular la varianza, obtenemos $\mathrm{E}\left(X^2\right)$

$$\begin{aligned}
\mathrm{E}\left(X^2\right) &= \int_0^\infty x^2\lambda e^{-\lambda x}\,dx \\
&= \lambda \left[-\frac{x^2 e^{-\lambda x}}{\lambda}\right]_0^\infty + \lambda \int_0^\infty \frac{2x e^{-\lambda x}}{\lambda}\,dx \\
&= 0 + 2\int_0^\infty x e^{-\lambda x}\,dx \\
&= 2 \cdot \frac{1}{\lambda} \cdot \frac{1}{\lambda} \\
&= \frac{2}{\lambda^2}
\end{aligned}$$

y por lo tanto

$$\begin{aligned}
\mathrm{Var}(X) &= \mathrm{E}\left(X^2\right) - \mathrm{E}(X)^2 \\
&= \frac{2}{\lambda^2} - \frac{1}{\lambda^2} \\
&= \frac{1}{\lambda^2}
\end{aligned}$$

Esta es una de las presentaciones de la distribución exponencial. Sin embargo, usaremos una presentación equivalente, según la cual la función de densidad de probabilidad es

$$f(x) = \frac{1}{\lambda} e^{-\frac{x}{\lambda}}$$

porque de esta forma obtenemos

$$\mathrm{E}(X) = \lambda, \quad \mathrm{Var}(X) = \lambda^2.$$

La función de densidad es fácil de integrar. En efecto,

$$\begin{aligned}\int_0^t \frac{1}{\lambda} e^{-\frac{x}{\lambda}}\, dx &= -e^{-\frac{x}{\lambda}}\Big|_0^t \\ &= e^{-\frac{x}{\lambda}}\Big|_t^0 \\ &= e^0 - e^{-\frac{t}{\lambda}} \\ &= 1 - e^{-\frac{t}{\lambda}}\end{aligned}$$

Una propiedad notable de la distribución exponencial es la llamada *propiedad de falta de memoria*. Supongamos que modelamos con una exponencial el tiempo de espera hasta que ocurra un evento (por ejemplo, el tiempo hasta que llegue el próximo bus). La propiedad dice que

$$\mathrm{P}(X > t + s \mid X > t) = \mathrm{P}(X > s),$$

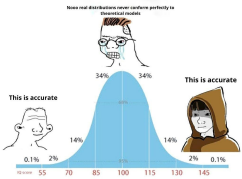
es decir, saber que ya esperamos t minutos no cambia la probabilidad de esperar s minutos más.

La verificación es directa:

$$\mathrm{P}(X > t+s \mid X > t) = \frac{\mathrm{P}(X > t + s)}{\mathrm{P}(X > t)} = \frac{e^{-(t+s)/\lambda}}{e^{-t/\lambda}} = e^{-s/\lambda} = \mathrm{P}(X > s).$$

En cierto sentido, la distribución exponencial "no recuerda" el tiempo ya transcurrido.

5.3 Distribución normal

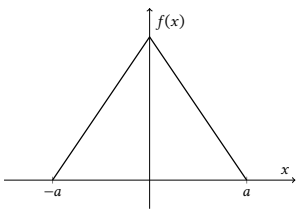


La distribución normal es usada y sobreusada por estadísticos y no-estadísticos. La vemos aparecer en cosas tan diversas como memes y el censo. Es natural (por no decir normal) que eso ocurra: aunque nace en un contexto acotado, resulta que aparece en todas las áreas de la estadística. Y si no aparece directamente, aparece aproximadamente.

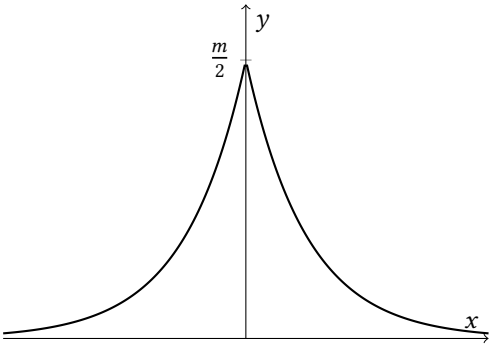
El origen de la distribución normal tiene que ver con la teoría de errores. En el renacimiento, ya Galileo se daba cuenta que al hacer experimentos, por más que los repitamos con cuidado, no obtendremos los mismos valores. La pregunta es entonces cuál es el valor verdadero. A lo largo de la historia, ha habido varias respuestas. Galileo recomendaba la mediana de las mediciones, mientras que Daniel Bernoulli daba cuenta de la práctica más común de la época, la media.

Sin embargo es claro que los errores, en principio, tienden a aparecer en torno al valor verdadero de lo medido. En ese contexto, y en base a distintas ideas matemáticas, Thomas Simpson[1] propuso una familia de distribuciones de error, una de ellas una función que hoy diríamos triangular.

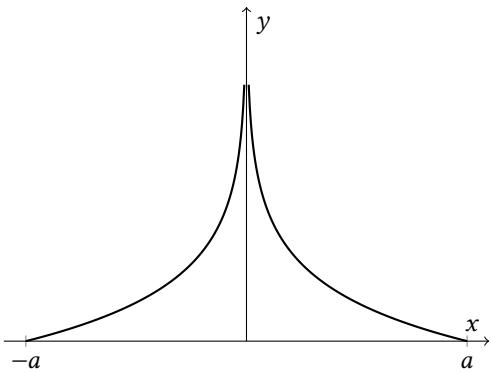
1: el de la regla de Simpson



Por otra parte, Pierre-Simon Laplace propuso un par de funciones, $\phi(x) = \frac{m}{2}e^{-m|x|}$



(aparentemente no le molestó que no fuera diferenciable en 0) y $y = \frac{1}{2a} \ln\left(\frac{a}{|x|}\right)$



(aparentemente no le molestó que no fuera acotada). Al parecer, Laplace se interesó más en la derivación matemática que en la aplicación.

Eventualmente, Gauss propone el criterio de los mínimos cuadrados y lo usa para identificar con exactitud la posición del recién descubierto asteroide Ceres, luego que se ocultara tras el Sol (y otros matemáticos y astrónomos predijeran que aparecería por otra parte del cielo). Ese método lleva ciertas suposiciones sobre los errores:

1. Los errores pequeños son más probables que los grandes.
2. Para cualquier número real ε la probabilidad de tener errores de magnitudes ε y $-\varepsilon$ es igual.
3. Cuando hay varias mediciones de la misma cantidad, el valor más probable de la cantidad medida es el promedio.

En base a estas suposiciones, Gauss dedujo que la curva del error (es decir, la función de densidad de probabilidad de los errores) viene dada por

$$\phi(x) = \frac{h}{\sqrt{\pi}} e^{-h^2 x^2}$$

con h una constante positiva que Gauss llamó "la precisión del proceso de medición". Hoy la reconocemos como una curva normal con media 0 y desviación estándar $1/\sqrt{2}h$.

Gauss hizo esta derivación a principios del siglo XIX. Aproximadamente 40 años después, Adolphe Quetelet,[2] quien empezó su carrera como astrónomo pero luego se cambió a ciencias sociales, realizó una observación importantísima: algunas medidas corporales realizadas a soldados escoceses parecían seguir una distribución normal. Si bien al realizar un test estadístico[3] se demuestra que Quetelet estaba equivocado, la idea no dejaba de ser tentadora.

2: él inventó la frase "el hombre promedio"

3: test que no se conocía en la época de Quetelet

Más que tentadora, además, justificada por el teorema del límite central. Pero de eso nos ocuparemos más tarde.

5.3.1 Trabajando con la distribución normal

La distribución normal tiene una de las funciones de densidad de probabilidad más famosas

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

y también una de las más inútiles. No es por un problema en sí misma, si no que porque la función f no es integrable en términos de funciones elementales.

Nuestro estudio de la función, entonces, debe ir en otros términos. Lo primero que debemos notar a partir del exponente de la exponencial

$$-\frac{(x-\mu)^2}{2\sigma^2}$$

es que la función es decreciente y simétrica alrededor del valor μ. Además, el término $2\sigma^2$ está haciendo la función de escalar horizontalmente la curva. Por otra parte, el término $1/\sqrt{2\pi\sigma^2}$ está escalando la curva verticalmente de manera que la integral sobre todos los reales dé 1.

El escalamiento horizontal es el más importante. Por terrible que parezca, derivar dos veces la función f no es complicado y resolver la ecuación $f''(x) = 0$ nos muestra que tenemos dos puntos de inflexión, $\mu - \sigma$ y $\mu + \sigma$.

Juntando toda la información anterior, podemos hacer un gráfico de la función (Figura 5.1). Este gráfico nos muestra la famosa campana de Gauss. Sin embargo, como se dijo en la introducción histórica, personas como Quetelet pensaban que muchas variables siguen una distribución normal y, si uno las grafica, encuentra curvas similares pero que *no*

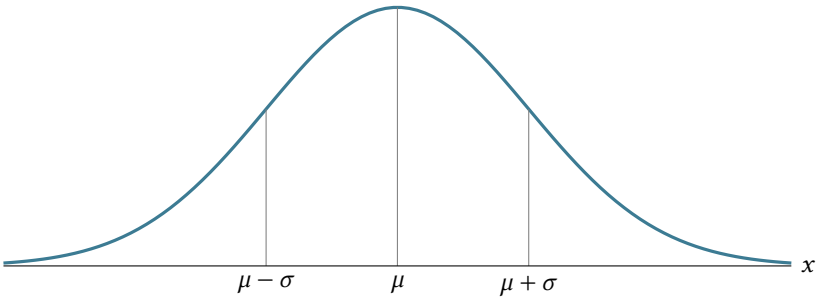


Figura 5.1: Gráfico de la función de densidad de una distribución normal con media μ y varianza σ^2.

siguen una distribución normal. ¿Cuál es la diferencia?

La respuesta es que la curva normal tiene ciertas características especiales. La primera es que ser completamente simétrica en torno a la media implica que la media es al mismo tiempo la mediana. Además, también es el valor máximo (absoluto) de la función, por lo que representa la moda.

Otra característica es que cualquier distribución normal, sin importar los parámetros, cumple con la llamada *regla empírica,* que dice cómo se distribuye la probabilidad en ciertos intervalos (Figura 5.2).

La regla empírica nos permite hacer una prueba rápida de la normalidad de la distribución de algún fenómeno. Viceversa, si conocemos (o asumimos) que una distribución es normal, nos permite saber la significancia de un fenómeno. Por ejemplo, en ciencias sociales se asume que un resultado es significativo si su nivel de confianza[4] está más allá de 2σ o bien 95 %. En física, se esperan resultados con confianza de 5σ o 99,99994 %.

4: que veremos un par de capítulos más adelante

Finalmente, una propiedad importante de la distribución normal es que la suma de una constante, multiplicar por una constante o sumar otra distribución normal dan siempre una distribución normal.

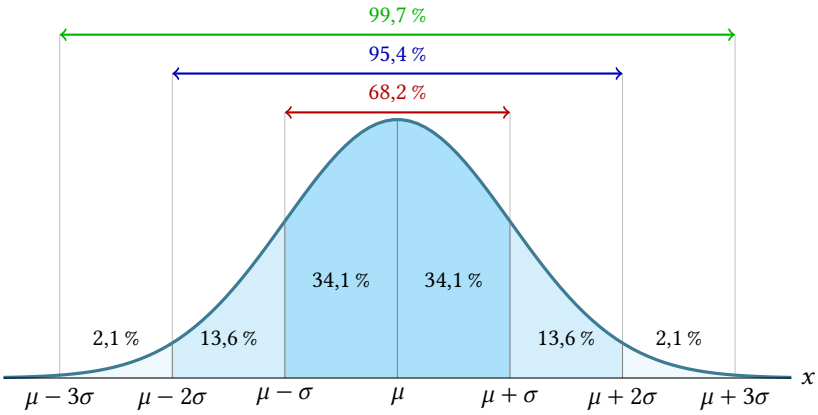


Figura 5.2: Regla empírica

En otras palabras, si $X_1 \sim \mathcal{N}\left(\mu_1, \sigma_1^2\right)$ y $X_2 \sim \mathcal{N}\left(\mu_2, \sigma_2^2\right)$, X_1, X_2 independientes y $a, b \in \mathbb{R}$,

1. $(aX_1 + b) \sim \mathcal{N}\left(a\mu_1 + b, a^2\sigma_1^2\right)$.
2. $(X_1 + X_2) \sim \mathcal{N}\left(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2\right)$

Esto tiene consecuencias interesantes. Una de ellas es que siempre podemos transformar cualquier normal en la *normal estándar*. Una distribución normal estándar es aquella que tiene media 0 y varianza 1. Otra es más teórica: si sumar normales independientes da otra distribución normal y multiplicar (y por lo tanto dividir) por un número da otra normal, entonces sacar el promedio de muchas distribuciones normales da una nueva distribución normal. Esto no suena a mucho pero es una idea que vale la pena tener en mente, pues significa que la distribución normal es, de alguna manera, un límite o un punto fijo de las distribuciones. Por ejemplo, no es cierto que la suma de dos distribuciones de un cierto tipo siempre sea del mismo tipo.

Antes de pasar a la normal estándar, es importante ver algunas distribuciones normales para entender cómo se comporta. La Figura 5.3 muestra tres distri-

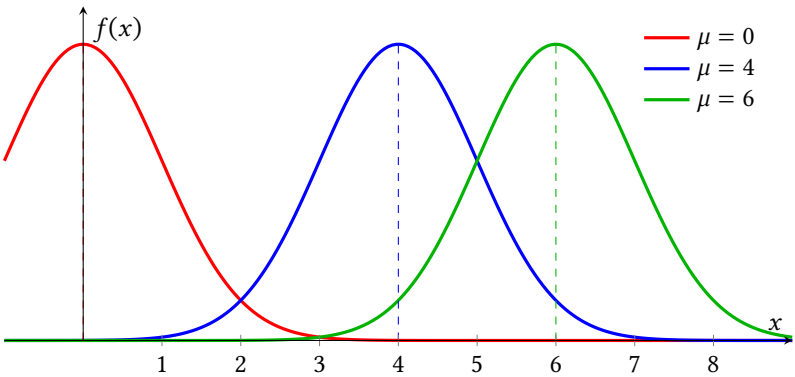


Figura 5.3: Tres distribuciones normales con la misma desviación estándar ($\sigma = 1$) pero diferentes medias

buciones normales con la misma desviación estándar pero diferentes medias. La Figura 5.4 muestra tres distribuciones normales con la misma media pero diferentes desviaciones estándar.

Para estandarizar una variable aleatoria X que sigue una distribución normal $X \sim \mathcal{N}(\mu, \sigma^2)$, simplemente creamos una nueva variable

$$Z = \frac{X - \mu}{\sigma}.$$

Esta nueva variable, por lo dicho anteriormente, tiene media 0 y varianza 1.

5.3.2 Tablas para la distribución normal estándar

Las siguientes tablas siempre dan la probabilidad acumulada de una distribución normal estándar, es decir,

$$P(Z \leq x),$$

para $Z \sim \mathcal{N}(0, 1)$. En otras palabras, el área bajo la curva desde $-\infty$ hasta x, como se muestra en la

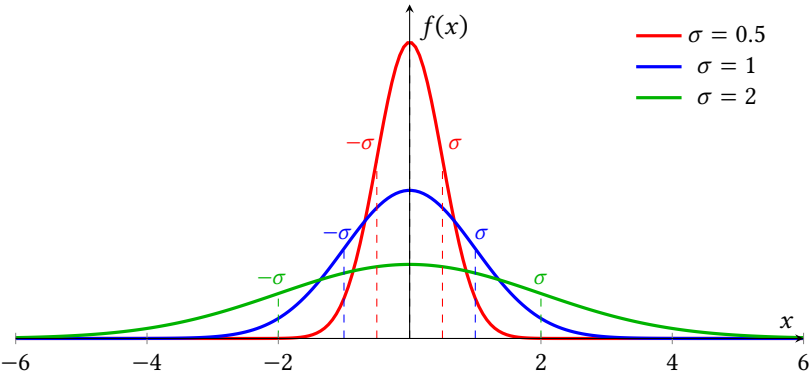


Figura 5.4: Tres distribuciones normales con la misma media ($\mu = 0$) pero diferentes desviaciones estándar

figura.

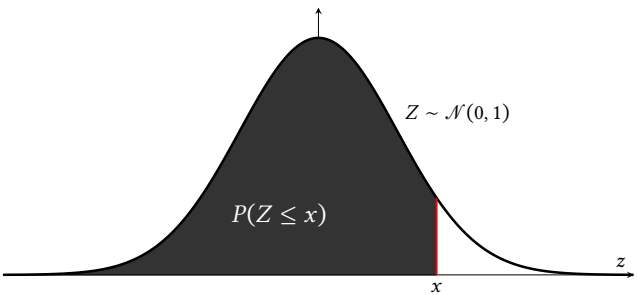


Tabla 5.1: Tabla de la distribución normal estándar, $x \leq 0$

x	0,00	0,01	0,02	0,03	0,04	0,05	0,06	0,07	0,08	0,09
−4,0	0,0000	0,0000	0,0000	0,0000	0,0000	0,0000	0,0000	0,0000	0,0000	0,0000
−3,9	0,0000	0,0000	0,0000	0,0000	0,0000	0,0000	0,0000	0,0000	0,0000	0,0000
−3,8	0,0001	0,0001	0,0001	0,0001	0,0001	0,0001	0,0001	0,0001	0,0001	0,0001
−3,7	0,0001	0,0001	0,0001	0,0001	0,0001	0,0001	0,0001	0,0001	0,0001	0,0001
−3,6	0,0002	0,0002	0,0001	0,0001	0,0001	0,0001	0,0001	0,0001	0,0001	0,0001
−3,5	0,0002	0,0002	0,0002	0,0002	0,0002	0,0002	0,0002	0,0002	0,0002	0,0002
−3,4	0,0003	0,0003	0,0003	0,0003	0,0003	0,0003	0,0003	0,0003	0,0003	0,0002
−3,3	0,0005	0,0005	0,0005	0,0004	0,0004	0,0004	0,0004	0,0004	0,0004	0,0003
−3,2	0,0007	0,0007	0,0006	0,0006	0,0006	0,0006	0,0006	0,0005	0,0005	0,0005
−3,1	0,0010	0,0009	0,0009	0,0009	0,0008	0,0008	0,0008	0,0008	0,0007	0,0007
−3,0	0,0013	0,0013	0,0013	0,0012	0,0012	0,0011	0,0011	0,0011	0,0010	0,0010
−2,9	0,0019	0,0018	0,0018	0,0017	0,0016	0,0016	0,0015	0,0015	0,0014	0,0014
−2,8	0,0026	0,0025	0,0024	0,0023	0,0023	0,0022	0,0021	0,0021	0,0020	0,0019
−2,7	0,0035	0,0034	0,0033	0,0032	0,0031	0,0030	0,0029	0,0028	0,0027	0,0026
−2,6	0,0047	0,0045	0,0044	0,0043	0,0041	0,0040	0,0039	0,0038	0,0037	0,0036
−2,5	0,0062	0,0060	0,0059	0,0057	0,0055	0,0054	0,0052	0,0051	0,0049	0,0048
−2,4	0,0082	0,0080	0,0078	0,0075	0,0073	0,0071	0,0069	0,0068	0,0066	0,0064
−2,3	0,0107	0,0104	0,0102	0,0099	0,0096	0,0094	0,0091	0,0089	0,0087	0,0084
−2,2	0,0139	0,0136	0,0132	0,0129	0,0125	0,0122	0,0119	0,0116	0,0113	0,0110
−2,1	0,0179	0,0174	0,0170	0,0166	0,0162	0,0158	0,0154	0,0150	0,0146	0,0143
−2,0	0,0228	0,0222	0,0217	0,0212	0,0207	0,0202	0,0197	0,0192	0,0188	0,0183
−1,9	0,0287	0,0281	0,0274	0,0268	0,0262	0,0256	0,0250	0,0244	0,0239	0,0233
−1,8	0,0359	0,0351	0,0344	0,0336	0,0329	0,0322	0,0314	0,0307	0,0301	0,0294
−1,7	0,0446	0,0436	0,0427	0,0418	0,0409	0,0401	0,0392	0,0384	0,0375	0,0367
−1,6	0,0548	0,0537	0,0526	0,0516	0,0505	0,0495	0,0485	0,0475	0,0465	0,0455
−1,5	0,0668	0,0655	0,0643	0,0630	0,0618	0,0606	0,0594	0,0582	0,0571	0,0559
−1,4	0,0808	0,0793	0,0778	0,0764	0,0749	0,0735	0,0721	0,0708	0,0694	0,0681
−1,3	0,0968	0,0951	0,0934	0,0918	0,0901	0,0885	0,0869	0,0853	0,0838	0,0823
−1,2	0,1151	0,1131	0,1112	0,1093	0,1075	0,1056	0,1038	0,1020	0,1003	0,0985
−1,1	0,1357	0,1335	0,1314	0,1292	0,1271	0,1251	0,1230	0,1210	0,1190	0,1170
−1,0	0,1587	0,1562	0,1539	0,1515	0,1492	0,1469	0,1446	0,1423	0,1401	0,1379
−0,9	0,1841	0,1814	0,1788	0,1762	0,1736	0,1711	0,1685	0,1660	0,1635	0,1611
−0,8	0,2119	0,2090	0,2061	0,2033	0,2005	0,1977	0,1949	0,1922	0,1894	0,1867
−0,7	0,2420	0,2389	0,2358	0,2327	0,2296	0,2266	0,2236	0,2206	0,2177	0,2148
−0,6	0,2743	0,2709	0,2676	0,2643	0,2611	0,2578	0,2546	0,2514	0,2483	0,2451
−0,5	0,3085	0,3050	0,3015	0,2981	0,2946	0,2912	0,2877	0,2843	0,2810	0,2776
−0,4	0,3446	0,3409	0,3372	0,3336	0,3300	0,3264	0,3228	0,3192	0,3156	0,3121
−0,3	0,3821	0,3783	0,3745	0,3707	0,3669	0,3632	0,3594	0,3557	0,3520	0,3483
−0,2	0,4207	0,4168	0,4129	0,4090	0,4052	0,4013	0,3974	0,3936	0,3897	0,3859
−0,1	0,4602	0,4562	0,4522	0,4483	0,4443	0,4404	0,4364	0,4325	0,4286	0,4247
−0,0	0,5000	0,4960	0,4920	0,4880	0,4840	0,4801	0,4761	0,4721	0,4681	0,4641

Tabla 5.2: Tabla de la distribución normal estándar, $x \geq 0$

x	0,00	0,01	0,02	0,03	0,04	0,05	0,06	0,07	0,08	0,09
0,0	0,5000	0,5040	0,5080	0,5120	0,5160	0,5199	0,5239	0,5279	0,5319	0,5359
0,1	0,5398	0,5438	0,5478	0,5517	0,5557	0,5596	0,5636	0,5675	0,5714	0,5753
0,2	0,5793	0,5832	0,5871	0,5910	0,5948	0,5987	0,6026	0,6064	0,6103	0,6141
0,3	0,6179	0,6217	0,6255	0,6293	0,6331	0,6368	0,6406	0,6443	0,6480	0,6517
0,4	0,6554	0,6591	0,6628	0,6664	0,6700	0,6736	0,6772	0,6808	0,6844	0,6879
0,5	0,6915	0,6950	0,6985	0,7019	0,7054	0,7088	0,7123	0,7157	0,7190	0,7224
0,6	0,7257	0,7291	0,7324	0,7357	0,7389	0,7422	0,7454	0,7486	0,7517	0,7549
0,7	0,7580	0,7611	0,7642	0,7673	0,7704	0,7734	0,7764	0,7794	0,7823	0,7852
0,8	0,7881	0,7910	0,7939	0,7967	0,7995	0,8023	0,8051	0,8078	0,8106	0,8133
0,9	0,8159	0,8186	0,8212	0,8238	0,8264	0,8289	0,8315	0,8340	0,8365	0,8389
1,0	0,8413	0,8438	0,8461	0,8485	0,8508	0,8531	0,8554	0,8577	0,8599	0,8621
1,1	0,8643	0,8665	0,8686	0,8708	0,8729	0,8749	0,8770	0,8790	0,8810	0,8830
1,2	0,8849	0,8869	0,8888	0,8907	0,8925	0,8944	0,8962	0,8980	0,8997	0,9015
1,3	0,9032	0,9049	0,9066	0,9082	0,9099	0,9115	0,9131	0,9147	0,9162	0,9177
1,4	0,9192	0,9207	0,9222	0,9236	0,9251	0,9265	0,9279	0,9292	0,9306	0,9319
1,5	0,9332	0,9345	0,9357	0,9370	0,9382	0,9394	0,9406	0,9418	0,9429	0,9441
1,6	0,9452	0,9463	0,9474	0,9484	0,9495	0,9505	0,9515	0,9525	0,9535	0,9545
1,7	0,9554	0,9564	0,9573	0,9582	0,9591	0,9599	0,9608	0,9616	0,9625	0,9633
1,8	0,9641	0,9649	0,9656	0,9664	0,9671	0,9678	0,9686	0,9693	0,9699	0,9706
1,9	0,9713	0,9719	0,9726	0,9732	0,9738	0,9744	0,9750	0,9756	0,9761	0,9767
2,0	0,9772	0,9778	0,9783	0,9788	0,9793	0,9798	0,9803	0,9808	0,9812	0,9817
2,1	0,9821	0,9826	0,9830	0,9834	0,9838	0,9842	0,9846	0,9850	0,9854	0,9857
2,2	0,9861	0,9864	0,9868	0,9871	0,9875	0,9878	0,9881	0,9884	0,9887	0,9890
2,3	0,9893	0,9896	0,9898	0,9901	0,9904	0,9906	0,9909	0,9911	0,9913	0,9916
2,4	0,9918	0,9920	0,9922	0,9925	0,9927	0,9929	0,9931	0,9932	0,9934	0,9936
2,5	0,9938	0,9940	0,9941	0,9943	0,9945	0,9946	0,9948	0,9949	0,9951	0,9952
2,6	0,9953	0,9955	0,9956	0,9957	0,9959	0,9960	0,9961	0,9962	0,9963	0,9964
2,7	0,9965	0,9966	0,9967	0,9968	0,9969	0,9970	0,9971	0,9972	0,9973	0,9974
2,8	0,9974	0,9975	0,9976	0,9977	0,9977	0,9978	0,9979	0,9979	0,9980	0,9981
2,9	0,9981	0,9982	0,9982	0,9983	0,9984	0,9984	0,9985	0,9985	0,9986	0,9986
3,0	0,9987	0,9987	0,9987	0,9988	0,9988	0,9989	0,9989	0,9989	0,9990	0,9990
3,1	0,9990	0,9991	0,9991	0,9991	0,9992	0,9992	0,9992	0,9992	0,9993	0,9993
3,2	0,9993	0,9993	0,9994	0,9994	0,9994	0,9994	0,9994	0,9995	0,9995	0,9995
3,3	0,9995	0,9995	0,9995	0,9996	0,9996	0,9996	0,9996	0,9996	0,9996	0,9997
3,4	0,9997	0,9997	0,9997	0,9997	0,9997	0,9997	0,9997	0,9997	0,9997	0,9998
3,5	0,9998	0,9998	0,9998	0,9998	0,9998	0,9998	0,9998	0,9998	0,9998	0,9998
3,6	0,9998	0,9998	0,9999	0,9999	0,9999	0,9999	0,9999	0,9999	0,9999	0,9999
3,7	0,9999	0,9999	0,9999	0,9999	0,9999	0,9999	0,9999	0,9999	0,9999	0,9999
3,8	0,9999	0,9999	0,9999	0,9999	0,9999	0,9999	0,9999	0,9999	0,9999	0,9999
3,9	1,0000	1,0000	1,0000	1,0000	1,0000	1,0000	1,0000	1,0000	1,0000	1,0000
4,0	1,0000	1,0000	1,0000	1,0000	1,0000	1,0000	1,0000	1,0000	1,0000	1,0000

5.4 Distribución χ^2

La distribución χ^2 nace un poco no para describir fenómenos naturales, si no que para ayudar con la estadística misma.[5] Para comenzar a describirla, lo más sencillo es decir que, si $X \sim \mathcal{N}(0,1)$, es decir una normal estándar, ¿cómo podríamos describir su varianza?

5: lo que no es 100 % cierto: como todas las cosas interesantes, la χ^2 nace a partir de varios orígenes que se van entretejiendo

— ¿Cómo? ¿Describir la varianza? Pero si es uno.

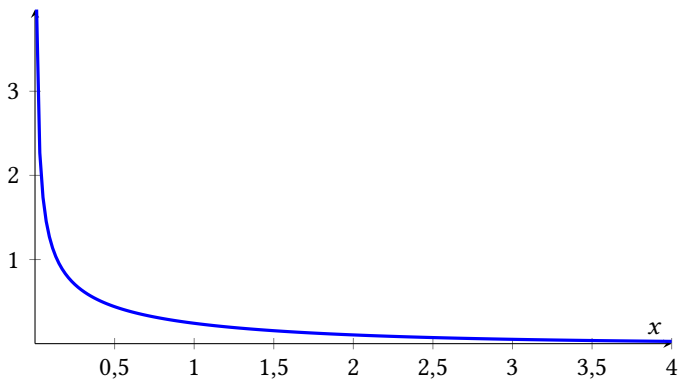
— Sí, perdón, me refería a cómo saber la varianza si no la supiéramos.

— Pero la sabemos.

— Ok, ok. En realidad esa pregunta es para próximos capítulos.

Una idea relacionada con la varianza es la de *elevar algo al cuadrado*. La varianza incluye el elevar al cuadrado la diferencia entre un dato y la media de los datos. Aprovechando que la media en una normal estándar es cero, si elevamos al cuadrado la distribución X se ve como en el siguiente gráfico.

¡No acotado!

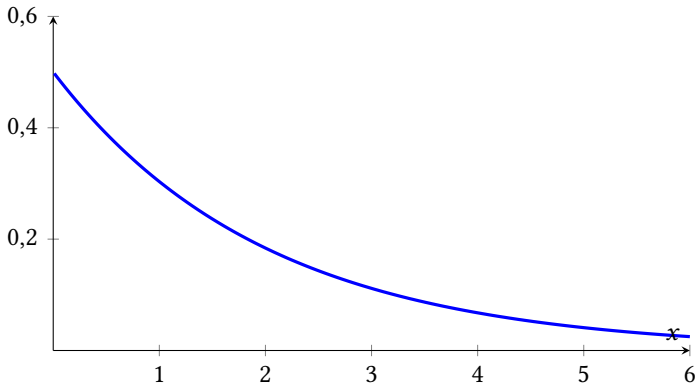


¿Qué pasaría si tuviéramos dos datos obtenidos independientemente? Como son independientes, la

varianza total es la suma de las varianzas. Eso nos lleva a pensar que podemos sumar

$$(\mathcal{N}(1,0))^2 + (\mathcal{N}(1,0))^2$$

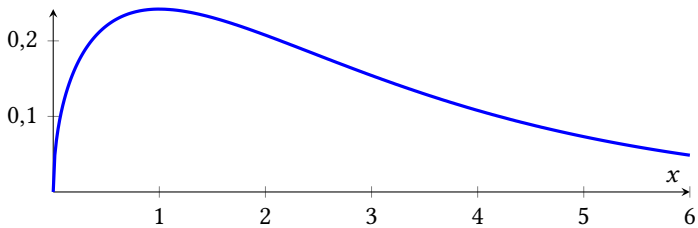
y obtendríamos la siguiente distribución



Podemos repetir el procedimiento pero obtendremos un resultado muy distinto. Cuando sumamos tres normales estándar al cuadrado

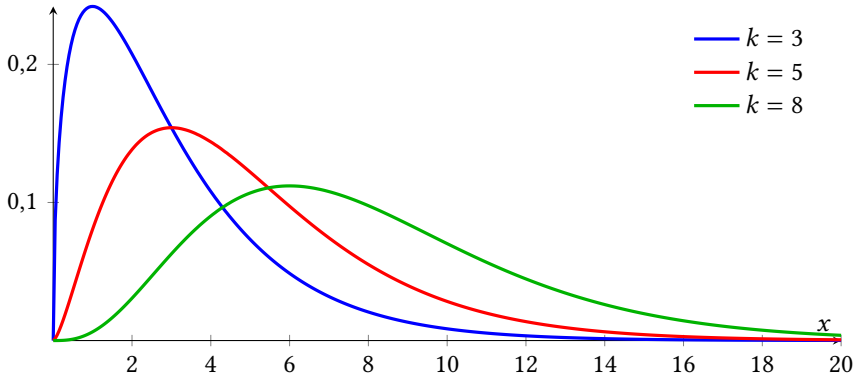
$$(\mathcal{N}(1,0))^2 + (\mathcal{N}(1,0))^2 + (\mathcal{N}(1,0))^2$$

obtenemos



En general, podemos repetir este proceso cuantas veces queramos. Si sumamos k cuadrados de normales estándar, obtendremos una distribución de

probabilidad llamada χ^2 con k grados de libertad. Hasta ahora hemos graficado las χ^2 con 1, 2 y 3 grados de libertad. Desde $k = 3$ en adelante, las curvas se parecen más entre sí.



En general, si $k \geq 3$, la curva presenta un máximo (y, por lo tanto, la moda) en $k - 2$. Podemos ver eso reflejado en el gráfico anterior. La media viene dada por k y la varianza viene dada por $2k$.

5.5 Distribución *t*

En un mundo ideal, siempre sabríamos lo que pasa con una población completa. En el mundo en que vivimos eso es prácticamente imposible, por lo que nos vemos obligados a tomar muestras. Al tomar muestras, la intuición nos dice que mientras más, mejor, y en realidad eso pasa pero, como el mundo no es ideal, no siempre podemos tomar muestras grandes.

¿Qué podemos hacer entonces? La solución fue estudiada en 1908 por William Sealy Gosset, pero nadie conoce al autor por ese nombre, si no que por Student. Nuestro buen William trabajaba en Guiness y

la compañía no permitía que los trabajadores publicaran bajo su nombre[6]. La distribución que encontró, llamada t, se hace cargo de dos problemas:

1. En una muestra no conocemos la media de la población.
2. En una muestra no conocemos la varianza de la población.

6: según una de las versiones de la historia. Otra versión dice que Guiness sugería no publicar con nombre para evitar que la competencia se enterara de secretos. Hay más versiones, por supuesto

Con esto, lo mejor que podemos intentar es hacer una estimación. Para la media de la población, podemos estimarla mediante $\overline{x}$, la media muestral. La varianza de la población puede estimarse mediante la varianza de la muestra

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \overline{x})^2$$

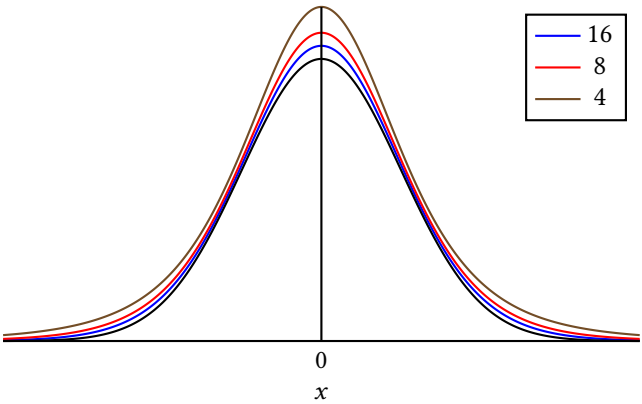
donde n es el tamaño de la muestra.

Con esto, finalmente consideremos la siguiente variable

$$t = \frac{\overline{x_n} - \mu}{s/\sqrt{n}}.$$

Esta variable se dice que sigue una distribución t con n grados de libertad. En el caso de tener n datos, tenemos $n-1$ grados de libertad para la distribución t.

La distribución t tiene un gráfico muy similar al de la distribución normal, pero con colas más anchas (reflejando nuestra mayor incerteza). A medida que n aumenta, se acerca cada vez más a la normal estándar. Su media siempre es 0 y su varianza es $\frac{n}{n-2}$ cuando $n > 2$. El siguiente gráfico muestra algunas distribuciones para distintos valores de n, junto con una normal estándar.


16
8
4
0
x

¿Qué dicen los datos? 6

Idea central

Tenemos datos. ¿Qué podemos decir de ellos de manera honesta y útil? La estadística descriptiva busca resumir lo esencial de un conjunto de datos, distinguiendo la señal del ruido, sin distorsionar lo que realmente muestran.

Con este capítulo salimos de la parte puramente probabilística del curso para entrar en la parte estadística. ¿Cuál es la diferencia? Simplificando, probabilidad es un estudio matemático del azar, mientras que la estadística nace anclada en la realidad. Por supuesto, a lo largo del tiempo la estadística y la matemática se han nutrido e influenciado, pero no son necesariamente lo mismo y la manera de pensarlas tampoco.

En particular, el problema de la estadística descriptiva es uno muy simple: ¿Qué puedo decir de un montón de datos? Como dice el nombre, ¿cómo puedo describir lo que les pasa?

Como paréntesis antes de empezar, en un trabajo real de estadística tendríamos que *limpiar* los datos. Nuestras bases de datos, incluso si las recogemos nosotros mismos, nunca serán perfectas. Siempre habrá datos faltantes, datos en formato incorrecto, etc. Limpiar los datos quiere decir tomar decisiones sobre qué hacer con los datos "erróneos" o problemáticos que tenemos. Si bien es parte importante del proceso, por ahora nos concentraremos en datos ya limpios.

6.1 Señal versus ruido

Una interpretación fundamental que podemos hacer de los datos es la de *señal versus ruido.* Muchas veces nuestros datos vienen generados por un proceso, por ejemplo el testeo del tiempo de vida útil de un material, el tiempo de llegada de paquetes en una red, etc. A partir de esos resultados, nos gustaría saber *cuál es la señal,* es decir, cuál es el patrón que está detrás de esos datos. Al mismo tiempo, también hay un cierto *ruido,* es decir las diferencias de nuestra supuesta señal real con los resultados que obtenemos.

Por ejemplo, podemos pesar diez veces una pelotita y obtenemos los siguientes resultados

24,83	24,91	24,78	24,86	24,94
24,80	24,88	24,76	24,92	24,85

Tabla 6.1: Mediciones del peso de una pelotita de goma

Es claro que la pelota tiene siempre la misma masa: esa es la señal. El problema es que cada resultado que obtenemos es una combinación de esa señal junto con un cierto nivel de ruido. Tenemos que aceptar que nunca lograremos saber la masa real de la pelota, pero tampoco lo necesitamos: nos basta una buena aproximación.

6.2 Encontrando señales: las medidas de tendencia central

Una idea relativamente razonable es que la señal se encuentra "al medio" de los datos. La pregunta es cómo encontrar ese medio. Algunas alternativas:

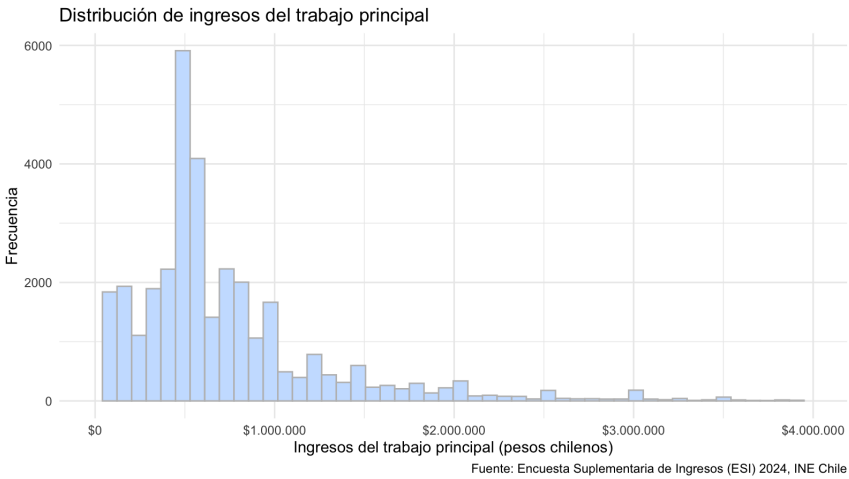


Figura 6.1: Distribución del ingreso.

Media aritmética También conocida como promedio. Todos lo conocemos.

Mediana Ordenando los datos de menor a mayor, el dato que queda al medio.

Moda El dato más frecuente.

Esas tres alternativas son las clásicas. No son las únicas y cada una de ellas tiene pros y contras. Para entenderlos, veamos un caso real.

El gráfico (Figura 6.1) muestra una parte de la distribución de los ingresos en Chile. Antes de intentar hacer algún cálculo, podemos notar algunas cosas. Por ejemplo, la mayor parte de la gente gana menos de $1.000.000. Asimismo, hay gente que gana *mucha* plata.

Ahora marquemos la media (aritmética), la mediana y la moda (Figura 6.2).

¿Cuáles son las diferencias? Podemos observar que la media se separa de las otras dos medidas. La razón es que la media es sensible a valores extremos. Las pocas personas que ganan muchos millones de

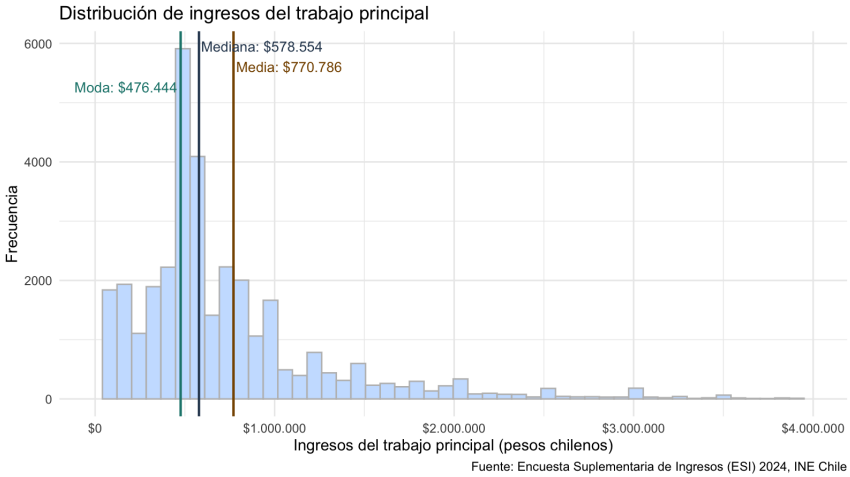


Figura 6.2: Distribución del ingreso anotada.

pesos "se llevan" la media hacia la derecha, aunque sean una minoría. La mediana, en cambio, no se ve afectada por las personas muy millonarias: solo le importa quién queda al medio de la distribución. La moda, por otra parte, sólo se preocupa de quién se repite más.

Por otra parte, la media necesita un cálculo realmente fácil y además,

$$\frac{x_1 + x_2 + x_3 + \cdots + x_n}{n}$$

es derivable para cada x_i. Por otra parte, ¿cuál es la fórmula (general) para la mediana? Suena a difícil. Lo mismo con la moda. Además, la mediana y la moda no tienen realmente en cuenta a todos los datos, como la media.

Como norma general, conviene escoger la media para describir. La excepción es una distribución que presente una gran asimetría, lo que se puede calcular con una medida como el *coeficiente de asimetría* (aptly named) o mediante inspección de un gráfico.

El caso de los sueldos es ilustrativo de un conjunto de datos *muy* asimétrico. En casos como estos, es más honesto usar la mediana. La moda, como norma general, presenta menos interés. La Tabla 6.2 muestra un resumen de los pros y contras de cada medida.

Nótese que el párrafo anterior dice "más *honesto* usar la mediana." No es una obligación, si no que una medida que representa mejor los datos. Podemos imaginar a un corredor de propiedades un poco tramposo que nos quiera convencer que el vecindario donde estamos viendo un departamento es muy bueno diciendo "el promedio de los sueldos es de 2 millones de pesos." Para desarmarlo, habría que contrapreguntar "¿y la mediana?"

Por otra parte, hay que hacer una diferencia entre *qué es* la media, mediana o moda y *cómo se calculan*. La media es el número que, si lo reemplazo en cada dato, me da el mismo resultado al sumar. En otras palabras, si reemplazo cada dato por la media, la suma total no cambia.

La mediana no funciona así. Una diferencia entre la media y la mediana es que la media aparece como un objeto algebraico mientras que la mediana aparece como un objeto de orden. En ese sentido, lo que conserva la mediana es el orden. Técnicamente, la media es el valor c que minimiza

$$\sum_{i=1}^{n} (x_i - c)^2$$

mientras que la mediana es el valor c que minimiza

$$\sum_{i=1}^{n} |x_i - c|.$$

Tabla 6.2: Comparación de medidas de tendencia central

	Pros	Contras
Media	Usa toda la información de los datos. Fácil de calcular y de trabajar matemáticamente.	Sensible a valores extremos (*outliers*); puede dar una imagen distorsionada en distribuciones asimétricas.
Mediana	Robusta ante valores extremos. Representa bien el valor "típico" en distribuciones asimétricas.	Ignora la magnitud de los datos fuera del centro. No tiene una fórmula cerrada simple.
Moda	Funciona con datos categóricos. Útil cuando interesa el valor más frecuente.	Puede no ser única (distribuciones multimodales). Poco informativa en datos continuos.

6.3 Midiendo el ruido: las medidas de dispersión

Supongamos que somos ayudantes de dos secciones y nos toca revisar un control. En una sección los puntajes tuvieron un promedio de 55 puntos y los puntajes estuvieron todos entre 50 y 60 puntos. En la otra, el promedio fue también 55 puntos, pero resulta que los alumnos sacaron o bien 10 puntos o bien 100 puntos.

¡Hey!

¿Cuál de las dos secciones les da más tranquilidad como ayudantes?

Naturalmente, las dos secciones para el promedio son exactamente iguales: 55 puntos. Sin embargo, nuestra intuición nos dice que las dos secciones probablemente son muy distintas.

Volviendo a la idea de señal versus ruido, la señal "general" ya fue capturada. Ahora necesitamos capturar a donde nos lleva el ruido. En otras palabras, necesitamos medir cómo varían los datos. Para medir esa variación es conveniente que establezcamos alguna referencia. Como veremos, la primera medida nos muestra que no es obligatorio, pero tampoco nos cuenta mucho.

6.3.1 El rango

La medida más sencilla es el rango. El rango mide cuánto "espacio" ocupan nuestros datos.

Definición 6.3.1 (Rango) *Si $x_1, x_2, \ldots, x_n$ es un conjunto de datos, entonces el rango es*

$$\max_i x_i - \min_i x_i$$

El rango es muy fácil de calcular y además nos da una idea tremendamente rápida sobre cómo se portan nuestros datos. Por ejemplo, en el ejemplo de los puntajes el primer grupo tiene un rango de 10 puntos y el segundo grupo tiene un rango de 90 puntos.

Sin embargo, tampoco es muy descriptivo. Además, entra la idea de *outliers*. Por ejemplo si hubiera otro grupo donde todo el mundo sacó 40 puntos *excepto* un estudiante, que sacó 60, el rango sería 20 puntos, pero no parece que eso describa muy bien al grupo.

¿Por qué no es muy descriptivo el rango? Un problema conectado, pero más profundo que el de los outliers, es que en realidad el rango sólo considera *dos* datos: el máximo y el mínimo. Los otros datos son como el arroz del almuerzo: sólo acompañamiento.

6.3.2 La desviación media absoluta

Una idea para solventar el problema anterior es que consideremos todos los datos. Para hacer eso, debemos pensar en un estándar para la desviación. Este estándar podría ser cualquier número, por ejemplo alguna de nuestras medidas de centro, la media, mediana o moda. La moda, como podría no existir o haber más de una, suele dejarse de lado. Se puede hacer una estadística muy interesante con la mediana, pero es *bastante* más difícil. La media funciona suficientemente bien y es fácil de calcular y es fácil calcular cosas alrededor de la media.

Uno de los problemas de la media, sin embargo, es que su centralidad viene de considerar *todos* los datos de manera que queda, por así decirlo, igualmente separada de todos. Explicándolo mejor, la media fue

construida dando igual peso a cada dato. Por lo tanto, si yo considero las desviaciones de la media a cada dato

$$x_i - \mu$$

y las agregamos todas

$$\sum_{i=1}^{n}(x_i - \mu)$$

nos encontramos con que

$$\sum_{i=1}^{n}(x_i - \mu) = \sum_{i=1}^{n} x_i - n\mu$$

pero $n\mu$ es $x_1 + x_2 + \cdots + x_n$

$$= \sum_{i=1}^{n} x_i - (x_1 + x_2 + \cdots + x_n)$$
$$= 0$$

¡Hey!

¿Cómo podemos solventar ese problema?

Una forma de solventar el problema es tomar el valor absoluto de la diferencia entre cada dato y la media. De esta manera, cada valor es no negativo.

Definición 6.3.2 (Desviación media absoluta) *Podemos solventar el problema usando la desviación media absoluta*

$$DMA = \frac{\sum |x_i - \mu|}{n}$$

pero no es necesariamente la mejor manera de solventar el problema. Just saying.

En la Tabla 6.3 podemos ver dos conjuntos de datos. Ambos tienen el mismo rango, pero no cuesta mucho ver (Figura 6.3) que el conjunto B tiene una distribución mucho más concentrada, salvo dos puntos extremos. El rango no refleja eso, pero la desviación media absoluta sí.

Tabla 6.3: Dos conjuntos con igual rango y media, pero distinta dispersión.

Observación	Conjunto A	Conjunto B
1	2	2
2	18	44
3	27	46
4	35	48
5	44	50
6	56	50
7	65	52
8	73	54
9	82	56
10	98	98
Rango	96	96
Media	50	50
DMA	24,8	12,0

¿Entonces por qué no se usa más? Un gran problema: algebraicamente es incómodo. En particular, al aparecer un valor absoluto inmediatamente deja de ser derivable en 0. Además, no hay una buena relación con la suma de variables aleatorias. ¿Qué hacer?

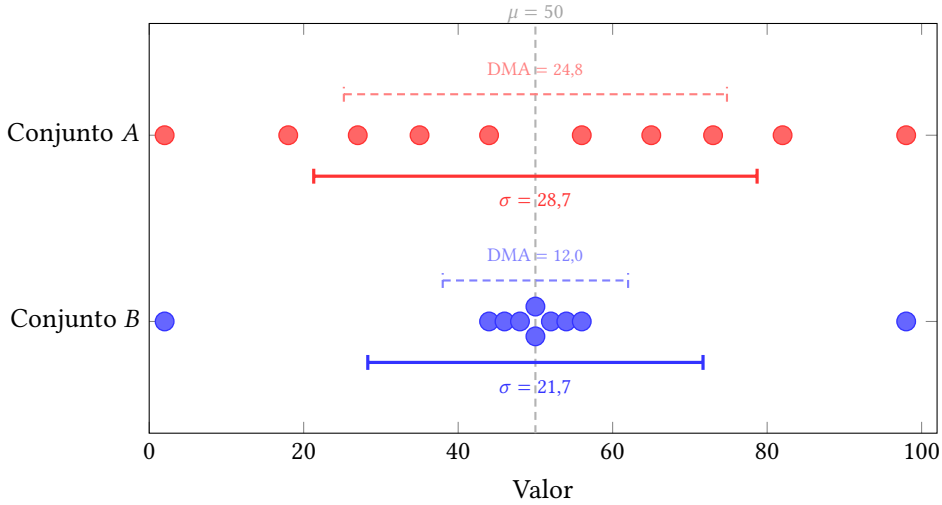


Figura 6.3: Dos conjuntos con igual rango y media ($\mu = 50,\ R = 96$) pero distinta dispersión. Encima de cada conjunto: $\mu \pm$ DMA (discontinuo). Debajo: $\mu \pm \sigma$ (sólido).

6.3.3 La varianza y la desviación estándar

En vez de usar los valores absolutos de las diferencias, podemos *elevar al cuadrado*. Por supuesto, esto es la varianza, al igual que lo vimos en VAS. Al hacer esto ganamos inmediatamente dos ventajas. Por un lado, podemos derivar en todos los reales y por otro, mantemenos la propiedad de separación de variables aleatorias independientes.

Hay una diferencia con el DMA un poco más sutil. La varianza, por decirlo así, *da más énfasis* más los datos lejanos. ¿Qué quiere decir esto? Un dato que está a 2 unidades de la media contribuye 4 a la suma; uno que está a 4 unidades contribuye 16.

Al igual que vimos antes, la varianza considera las unidades de la variable *al cuadrado*. La solución, como antes, es tomar la raíz cuadrada. Eso nos da

la *desviación estándar,* que vuelve a estar en las mismas unidades que los datos originales y es, por eso mismo, la medida que más se usa en la práctica.

Definición 6.3.3 (Varianza poblacional) *Si $x_1, x_2, \ldots, x_N$ es una población completa con media μ, la varianza poblacional es*

$$\sigma^2 = \frac{1}{N}\sum_{i=1}^{N}(x_i - \mu)^2.$$

Definición 6.3.4 (Desviación estándar poblacional) *La desviación estándar poblacional es la raíz cuadrada de la varianza poblacional,*

$$\sigma = \sqrt{\sigma^2} = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(x_i - \mu)^2}.$$

Sus unidades son las mismas que las de los datos originales.

Volvamos a los dos grupos del comienzo de la sección (Tabla 6.3). Ya sabíamos que son muy distintos aunque compartan media y rango, pero ahora calculemos la varianza y la desviación estándar.

Dividiendo por $= 10n$ obtenemos

$$\sigma_A^2 = \frac{8236}{10} = 823{,}6 \qquad \sigma_A \approx 28{,}7$$

$$\sigma_B^2 = \frac{4720}{10} = 472{,}0 \qquad \sigma_B \approx 21{,}7$$

El conjunto A tiene una desviación estándar casi un 32 % mayor que el conjunto B. Nótese que ambos grupos comparten los mismos valores extremos (2 y 98), así que el cuadrado los penaliza por igual en ambos lados. La diferencia viene del interior: en B los ocho datos del centro están muy cerca de 50,

Conjunto A			Conjunto B		
x_i	$x_i - \mu$	$(x_i - \mu)^2$	x_i	$x_i - \mu$	$(x_i - \mu)^2$
2	-48	2304	2	-48	2304
18	-32	1024	44	-6	36
27	-23	529	46	-4	16
35	-15	225	48	-2	4
44	-6	36	50	0	0
56	6	36	50	0	0
65	15	225	52	2	4
73	23	529	54	4	16
82	32	1024	56	6	36
98	48	2304	98	48	2304
	Total	8236		Total	4720

Tabla 6.4: Cálculo paso a paso de la varianza poblacional ($\mu = 50$ en ambos casos).

mientras que en A están más esparcidos por todo el rango.

¿Qué significa la desviación estándar? Si lo pensamos, la varianza

$$\frac{\sum_{i=1}^{n} (x_i - \mu)^2}{n}$$

es un promedio: el promedio de $(x_i - \mu)^2$, la distancia al cuadrado. Lo que hace la raíz es devolvernos a la variable sin cuadrado. Por lo tanto, la desviación estándar funciona como una esperanza: el valor esperado de la distancia del dato "típico" a la media. Como es una distancia, eso significa que el intervalo desde $\mu - \sigma$ a $\mu + \sigma$ tiene una importancia singular para los datos.

Observación 6.3.1 La desviación estándar poblacional σ mide cuánto se alejan en promedio los datos de la media μ. Un dato a más de 2σ de la media es menos común y uno a más de 3σ es ya directamente raro, al menos si la distribución de los datos es relativamente común[1].

1: quería usar la palabra "normal" pero tiene un significado demasiado cargado en este curso

6.3.4 Comparando dos grupos

Si queremos comparar la variación entre dos grupos, es muy fácil ser injusto. Por ejemplo, los elefantes y los saltamontes tienen pesos variados, pero los elefantes varían en toneladas y los saltamontes varían en gramos. ¿Será justo decir que los elefantes varían más?

Una manera de comparar la variación entre dos grupos es usar el coeficiente de variación.

$$\mathrm{CV} = \frac{\sigma}{\mu} \times 100\%.$$

El CV expresa la desviación estándar como porcentaje de la media, lo que permite hacer comparaciones.

En clase usamos los pesos (inventados) de cinco saltamontes (en gramos) y cinco elefantes (en toneladas) de la Tabla 6.5. ¿Cuál de las dos especies es más variable?

Calculando:

$$\mu_S = 9{,}9\,\mathrm{g} \qquad \sigma_S \approx 1{,}19\,\mathrm{g} \qquad \mathrm{CV}_S \approx 12{,}0\,\%$$

$$\mu_E = 4{,}954\,\mathrm{t} \qquad \sigma_E = 0{,}108\,\mathrm{t} \qquad \mathrm{CV}_E \approx 2{,}2\,\%$$

En términos absolutos, $\sigma_E = 0{,}108\,\mathrm{t} = 108\,\mathrm{kg}$ y $\sigma_S \approx 1{,}19\,\mathrm{g}$. Los elefantes varían muchísimo más que los saltamontes *en términos absolutos,* pero varían

Saltamontes (g)	Elefantes (t)
10,5	4,90
9,8	5,10
11,2	4,80
7,7	5,05
10,3	4,92

Tabla 6.5: Pesos de saltamontes (g) y elefantes (t).

menos que los saltamontes *en relación a la media* porque $\mathrm{CV}_E = 2{,}2\,\%$ mientras que $\mathrm{CV}_S = 12{,}0\,\%$. Si comparamos, sería injusto calificar a los elefantes como más variados.

6.4 Medidas de posición: orden y progreso

Las medidas de posición son entretenidas porque requieren que ordenemos. Básicamente, existe sólo un tipo de medida de posición, el *cuantil*. Todo lo otro es un cuantil con otro nombre.[2]

2: mediana: dividir los datos en 2,
cuartil: dividir los datos en 4,
quintil: dividir los datos en 5,
percentil: dividir los datos en 100 partes iguales.

Un cuantil x_q es aquel valor tal que la proporción de datos menores o iguales que x_q es q.

El cuantil de orden $q \in (0, 1)$ se define como

$$x_q = \inf\{x \in \mathbb{R} \,/\, \hat{F}_n(x) \geq q\},$$

donde $\hat{F}_n$ es la función de distribución empírica. En otras palabras, x_q es el menor valor tal que al menos una proporción q de los datos es menor o igual a x_q. Esta precisión es necesaria porque, con un número finito de datos, puede no existir ningún valor donde la proporción sea exactamente q.

$\hat{F}_n$, la función de distribución empírica, se define como

$$\hat{F}_n(x) = \frac{1}{n}\sum_{i=1}^{n} \mathbf{1}(x_i \leq x),$$

donde $\mathbf{1}$ es la función indicadora

$$\mathbf{1}(\text{condición}) = \begin{cases} 1 & \text{si la condición se cumple} \\ 0 & \text{si la condición no se cumple} \end{cases}$$

y n es el número de datos.

Lo que hay que considerar es que la idea de "ordenar" ya no es algo que viva en los naturales, si no generalmente en los reales. Por lo tanto, nuestra distribución de los datos da lugar necesariamente a una distribución de probabilidad (sobre todo si tenemos muchos datos). Viceversa, si tenemos una distribución de probabilidad podremos tomar sus cuantiles. En ese caso, el cuantil q es el valor x_q tal que

$$\mathrm{P}(X \leq x_q) = q.$$

Entre las medidas de dispersión está el *rango intercuartílico.* La idea es cuanto mide el 50 % central, contenido entre P_{25} y P_{75}.

Para terminar, hay una relación entre los cuantiles y la media (un poco como la desigualdad de Chebyshev). Si x_q es el cuantil q, entonces

$$\mu - \sigma\sqrt{\frac{q}{1-q}} \leq x_q \leq \mu + \sigma\sqrt{\frac{q}{1-q}}.$$

En particular, si q es $1/2$ (y el cuantil es la mediana) encontramos que

$$\mu - \sigma \leq Me \leq \mu + \sigma,$$

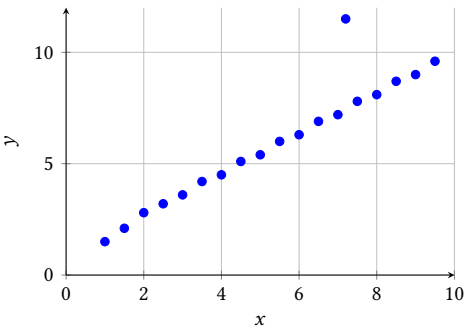
es decir, la mediana nunca está más allá de una desviación estándar de la media.

6.5 Gráficos

El dicho dice "una imagen vale más que mil palabras." Sin embargo, habría que agregar que una imagen *buena* es lo que vale más que mil palabras. Entonces, ¿qué hace que un gráfico sea bueno?

Mostrar datos en un gráfico nos permite hacer más que simplemente mostrar sus resúmenes. Un buen gráfico nos muestra relaciones, puntos de interés, datos extraños y en general información que no queda capturada en un simple cálculo. Un ejemplo es el conjunto de datos llamado *Datasaurus dozen,* (Figura 6.4) donde doce conjuntos de datos tienen las mismas medidas pero se ven muy distintos al graficar (link a un gif con las medidas).

El dato que salta probablemente no se vería capturado por alguna de nuestras medidas usuales, media y desviación estándar (aunque sí por otra, ¿cuál?).



El lado malo de los gráficos es que nos permiten mentir. De hecho, un gráfico mentiroso es *muy* fácil de hacer y, lamentablemente, muy común en reportajes, artículos periodísticos, etc. Esto es lo que Edward Tufte[3] llama "la mentira gráfica." Por ejemplo, gráficos cuyo eje Y no comienza en 0 se usan para enfatizar diferencias que...probablemente no están ahí. También entran los gráficos de torta, en particular si son 3D, como muestra la Figura 6.5.



Figura 6.4: Datasaurus dozen

3: si quiere encontrar la felicidad, lea en algún momento el libro *The visual display of quantitative information* de Tufte. Está en la biblioteca.

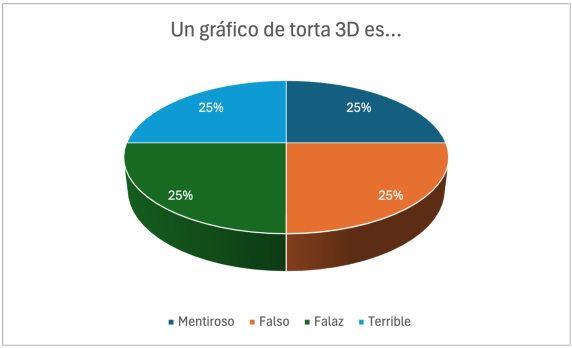


Figura 6.5: Cada vez que alguien hace un gráfico de torta dios mata un gatito.

Entonces, ¿qué hace que un gráfico sea bueno? Es más arte que ciencia, pero uno de los elementos más importantes es lo que Tufte llama *data-ink ratio,* la razón entre la tinta que se usa para representar datos versus la que se usa en total en el gráfico (donde dice tinta lea pixeles). En otras palabras, un buen gráfico tiene poco ruido.

Los elementos decorativos, como tramas, efectos 3D, ilustraciones, etc., si no muestran datos, son lo que Tufte llama *chartjunk,* básicamente el equivalente a la comida chatarra. Evítelos.

En vez de hacer un gráfico apilado o hacer una animación, es mejor trabajar usando *múltiplos pequeños.* Esto significa hacer muchos gráficos pequeños utilizando la misma escala.

Un gráfico bien hecho puede manejar una gran densidad de datos. Si se elimina algo, se elimina porque es superfluo, no porque sea complejo. De hecho, una de las grandes gracias de un gráfico es que nos permite mostrar información compleja de manera "fácil."

Un buen gráfico responde a una pregunta, esencialmente una comparación. Si no hay una pregunta comparativa, puede que otra herramienta sea mejor que un gráfico.

6.6 Software

En el año de nuestro Señor de 2026 todavía hay escuelas, colegios, liceos e incluso universidades que se dan el lujo de enseñar estadística *sin* considerar en ningún momento el uso de un computador. Esto no sólo es retrógrado, si no que es irrisorio. No hay estadístico en el planeta que no use un computador con algún tipo de software estadístico.

Dicho lo anterior, el software es una herramienta más y todos son más o menos parecidos en el fondo, pero adecuados a distintas necesidades y tipos de persona. Si usted usa Excel, estoy seguro que más de alguien arriscará la nariz pero mientras sus análisis sean de calidad, da lo mismo.

Personalmente, creo que siempre es mejor mantener los datos y lo que uno hace para trabajar con los datos en formatos abiertos (porque es lo único que uno está seguro que podrá leer eternamente) y no hay formato más abierto que el que está basado en texto plano. Los archivos de código R o Python y los archivos de datos en CSV cumplen con esas características. También hay formatos abiertos (aunque ya no de texto plano) que permiten comprimir datos demasiado grandes (por ejemplo los resultados del censo).

Use el software (R, Python + librerías, SPSS, Excel, PowerBI, etc) que más le guste. Sólo aprenda a usarlo bien. Tomás de Aquino dijo *hominem unius libri timeo:* le temo al hombre que sabe (perfectamente) un solo libro.

La muestra y la población 7

Idea central

Una muestra es una fracción del todo. ¿Qué podemos inferir de la población a partir de unos pocos datos? La respuesta depende de entender cómo se comportan, como variables aleatorias, los estadísticos que calculamos a partir de muestras.

7.1 La ley de los grandes números

En la clase hicimos un pequeño experimento tirando una moneda diez veces. No recuerdo los resultados, pero aquí lo hice unas cuantas veces

Número de Caras	Frecuencia	Proporción
1	1	0,05
2	1	0,05
3	1	0,05
4	6	0,30
5	7	0,35
6	3	0,15
7	1	0,05

La mayoría de los resultados están dentro del intervalo $[4, 6]$, lo que es más o menos esperable. Si nos metemos en el intervalo $[3, 7]$ ya están casi todos los resultados: sólo faltan dos.

Sin embargo, si hacíamos el experimento 1000, 5000 o más veces la intuición nos decía que esa diferencia tenía que irse achicando, ¿no?

¡Hey!

¿Está de acuerdo? Al repetir más veces el experimento, ¿se acercaría más la proporción observada a $\frac{1}{2}$?

NO.

Nuestra intuición no está tan errada, pero hay que afinarla. En general, cuando tenemos una suma (o promedio o conteo) tendremos que

$$\text{suma} = \text{valor esperado} + \text{error aleatorio}.$$

La pregunta es qué tan grande es ese error aleatorio. Hay una fórmula que nos permite establecer el tamaño de este error, llamado *error estándar*. Cuando contabilicemos la suma de las extracciones de una caja, con reposición, el error estándar de la suma es

$$\sqrt{\text{número de extracciones}} \cdot (\text{desviación estándar de la caja})$$

En otras palabras, el error *aumenta* a medida que repetimos nuestro experimento, de manera proporcional a la raíz del número de repeticiones. En ese sentido, nuestra intuición estaba completamente incorrecta. Sin embargo, si consideramos el promedio

$$\frac{\sqrt{\text{número de extracciones}} \cdot (\text{SD de la caja})}{\text{número de extracciones}} = \frac{\text{SD de la caja}}{\sqrt{\text{número de extracciones}}}$$

y cuando el número de extracciones crece, el error estándar decrece.

Esta idea está representada en la *ley de los grandes números*. Hay varias versiones de esta ley, pero todas

son teoremas que hablan de la convergencia de una serie de variables aleatorias.

Si $X_1, X_2, \cdots, X_n$ son variables aleatorias independientes e idénticamente distribuidas, con esperanza μ y varianza σ^2 finitas, entonces la variable $\overline{X} = \sum_{i=1}^{n} X_i/n$ cumple que para todo $\varepsilon > 0$,

$$\lim_{n\to\infty} \mathrm{P}\left(|\overline{X} - \mu| \leq \varepsilon\right) = 1$$

Lo que dice este teorema es que, efectivamente, el promedio muestral converge hacia el promedio poblacional a medida que aumenta el tamaño de la muestra. Es posible que esa convergencia no ocurra, pero si la muestra es realmente azarosa, es lo que ocurrirá la mayor, muy mayor, parte del tiempo[1].

1: tan mayor que en realidad casi nunca no ocurre

7.2 Teorema del límite central

El teorema del límite central (o teorema central del límite) es quizás el resultado más importante en probabilidad. En cierta manera, es una continuación de la ley de los grandes números.

¡Hey!

Si tomara muchas muestras distintas de la misma población y calculara la media de cada una, ¿qué distribución cree que seguirían esas medias?

Si $X_1, X_2, \cdots, X_n$ son variables aleatorias independientes e idénticamente distribuidas, con esperanza μ y varianza σ^2 finitas (y la varianza mayor que 0), entonces la VA

$$Z_n = \frac{\overline{X} - \mu}{\sigma/\sqrt{n}}$$

converge en distribución a la normal estándar cuando n se va a infinito, es decir,

$$\lim_{n\to\infty} P(Z_n \leq x) = P(Z \leq x)$$

donde $Z \sim \mathcal{N}(0, 1)$.

Hay algunas cosas que decir. La primera es una observación menor. Si nos fijamos, la variable Z_n nos está diciendo el comportamiento de la media muestral. Mediante un truco algebraico bien conocido (amplificar por n) obtenemos lo siguiente

$$Z_n = \frac{\overline{X} - \mu}{\sigma/\sqrt{n}} = \frac{\sum_{i=1}^{n} X_i - n\mu}{\sqrt{n}\sigma}$$

y por lo tanto el teorema también nos cuenta acerca de la suma de las variables, lo que puede ser de utilidad.

Una segunda cosa es que si

$$\lim_{n\to\infty} Z_n = \mathcal{N}(0, 1)$$

(usando una notación un poco liberal), y recordamos qué es estandarizar una distribución normal, descubriremos que otra forma de enunciar el teorema es

$$\overline{X_n} \approx \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$$

(usando una idea todavía más liberal, porque estamos obviando el límite).

Un tercer punto es que, y esto es lo más increíble, el teorema no puso *ninguna* restricción a la distribución que siguen los X_i, salvo que tuvieran media y varianza finitas y varianza no nula además.

Por ejemplo, los X_i podrían provenir de una distribución de Bernoulli (éxito con probabilidad p, fracaso con probabilidad $1 - p$, como tirar una moneda). Si es así, $\mathrm{E}(X_i) = p$ y $\mathrm{Var}(X_i) = p(1 - p)$. Además, la variable

$$Y_n = X_1 + X_2 + \cdots + X_n$$

sigue una distribución binomial

$$Y_n \sim \mathrm{Bin}(n, p).$$

Por lo tanto,

$$Z_n = \frac{Yn - np}{\sqrt{np(1-p)}}$$

converge hacia una normal estándar.

7.3 Distribuciones muestrales

Las secciones anteriores nos llevan a un resultado: las distribuciones muestrales de la media muestral, la varianza muestral y la proporción muestral.

7.3.1 Distribución muestral de la media muestral

Básicamente, esta sección es reiterar lo dicho en la anterior. Gracias al teorema del límite central, sabemos que la media muestral sigue una distribución normal con media μ y desviación estándar $\sigma/\sqrt{n}$

$$\overline{X} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$$

o, equivalentemente, la variable

$$Z = \frac{\overline{X} - \mu}{\sigma/\sqrt{n}}$$

sigue una distribución normal estándar.

7.3.2 Distribución muestral de la proporción muestral

El teorema del límite central nos dice que la variable puede seguir, básicamente, cualquier distribución.

En particular, podría seguir la distribución binomial.

Recordemos que la distribución binomial cuenta la cantidad de *éxitos* registrados dentro de n intentos. Por ejemplo, si estamos si alguien es zurdo o diestro, podemos usar la distribución binomial para ver la probabilidad de que 5 personas en nuestro curso de 37 sean zurdas.

Pero una forma equivalente es preguntarnos por la probabilidad de que la proporción de personas zurdas sea 5/37. En otras palabras, al dividir por la cantidad total obtenemos una nueva distribución binomial, pero esta vez con esperanza p y varianza pq.

En otras palabras, la proporción muestral $\hat{p}$ se distribuye según una distribución normal

$$\hat{p} \sim \mathcal{N}\left(p, \frac{pq}{n}\right)$$

o lo que es lo mismo, la variable

$$Z = \frac{\hat{p} - p}{\sqrt{pq/n}}$$

sigue una distribución normal estándar.

7.3.3 La distribución muestral de la media muestral para poblaciones de varianza desconocida

Volviendo a la media, hasta ahora hemos asumido algo un poco extraño: la varianza poblacional es conocida[2]. Esto es raro porque, si conocemos la media y la varianza poblacional, no tiene sentido que nos preocupemos por las muestras. Sin embargo, es donde estamos y pronto ya no conoceremos ninguna de las dos.

2: y que la media poblacional también es conocida

Por lo pronto, ¿qué pasa si no conocemos la varianza poblacional, es decir, si sólo tenemos la varianza muestral? Podemos aproximar la distribución de la media muestral, pero no podremos aproximarla mediante una normal.

Ese fue (parte d)el problema que trató de resolver William Sealy Gosset mientras trabajaba en la cervecería Guiness. En particular, le interesaba ver cómo podía resolver el problema de trabajar con muestras pequeñas. Su trabajo junto con Ronald Fisher[3] los llevó a postular la distribución t.

3: básicamente el padre de la estadística moderna

La distribución t_ν es una distribución que depende sólo de un parámetro: los grados de libertad (ν). La media siempre es 0 y la varianza es $\nu/(\nu-2)$ cuando $\nu > 2$.

Para trabajar con esta distribución debemos calcular el score T, de manera análoga a como lo hacíamos con la distribución normal

$$T = \frac{\overline{x} - \mu}{s/\sqrt{n}}$$

donde $\overline{x}$ es la media muestral, μ es la media poblacional, n es la cantidad de observaciones de la muestra y s es la desviación estándar muestral definida por

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \overline{x}).$$

Este score T sigue entonces una distribución t con $n-1$ grados de libertad

$$T \sim \mathrm{t}_{n-1}\,.$$

7.3.4 Distribución muestral de la varianza muestral

Lamentablemente, el teorema del límite central no nos ayuda con la varianza en general. El TLC está de-

finido para el promedio y se puede extender a otras ideas relacionadas con el promedio, como sumar o contar, pero la varianza con su suma de diferencias cuadradas no se presta bien para ser adoptada por el TLC. Por si acaso, recordemos que la varianza muestral viene dada por

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \overline{x})$$

Sin embargo, hay un caso especial y es cuando sabemos que la muestra proviene de una distribución normal. Supongamos que tenemos una muestra $X_1, X_2, \ldots, X_n$, es decir, n variables aleatorias independientes e idénticamente distribuidas según una distribución normal $\mathcal{N}\left(\mu, \sigma^2\right)$. Para cada X_i podemos estandarizarla y obtener $Z_i = (X_i - \mu)/\sigma$ y por lo tanto

$$\sum_{i=1}^{n}\left(\frac{X_i - \mu}{\sigma}\right)^2 = \sum_{i=1}^{n} Z_i^2 \sim \chi_n^2$$

por definición de la distribución χ_n^2.

¿Cómo podemos relacionar la media y varianza muestrales? Partamos por

$$\sum_{i=1}^{n}\left(\frac{X_i - \mu}{\sigma}\right)^2 = \sum_{i=1}^{n}\left(\frac{\left(X_i - \overline{X}\right) + \left(\overline{X} - \mu\right)}{\sigma}\right)^2$$

consideremos el numerador

$$\sum_{i=1}^{n}\left(\left(X_i - \overline{X}\right) + \left(\overline{X} - \mu\right)\right)^2$$

expandamos el cuadrado

$$= \sum_{i=1}^{n} \left(\left(X_i - \overline{X} \right)^2 + 2 \left(X_i - \overline{X} \right) \left(\overline{X} - \mu \right) + \left(\overline{X} - \mu \right)^2 \right)$$
$$= \sum_{i=1}^{n} \left(X_i - \overline{X} \right)^2 + 2 \left(\overline{X} - \mu \right) \sum_{i=1}^{n} \left(X_i - \overline{X} \right) + n \left(\overline{X} - \mu \right)^2$$

consideremos la segunda sumatoria: como es la suma de las diferencias en torno a la media, por propiedades de ésta se hace 0

$$= \sum_{i=1}^{n} \left(X_i - \overline{X} \right)^2 + 2 \left(\overline{X} - \mu \right) \cdot 0 + n \left(\overline{X} - \mu \right)^2$$
$$= \sum_{i=1}^{n} \left(X_i - \overline{X} \right)^2 + n \left(\overline{X} - \mu \right)^2$$

y considerando la sumatoria restante, podemos ver que es s^2 multiplicado por $n - 1$

$$= (n-1)\, s^2 + n \left(\overline{X} - \mu \right)^2$$

para volver a lo original, debemos dividir por σ^2

$$\sum_{i=1}^{n} \left(\frac{X_i - \mu}{\sigma} \right)^2 = \frac{(n-1)\, s^2}{\sigma^2} + \frac{n \left(\overline{X} - \mu \right)^2}{\sigma^2}$$

observemos el término de la derecha

$$\frac{n \left(\overline{X} - \mu \right)^2}{\sigma^2} = \frac{\left(\sqrt{n} \right)^2 \left(\overline{X} - \mu \right)^2}{\sigma^2} = \left(\frac{\overline{X} - \mu}{\sigma / \sqrt{n}} \right)^2$$

por el TLC lo que está dentro del cuadrado sigue una distribución normal estándar y, al estar al cuadrado obtenemos

$$\left(\frac{\overline{X} - \mu}{\sigma / \sqrt{n}} \right)^2 \sim \chi_1^2$$

como resumen, tenemos lo siguiente

$$\sum_{i=1}^{n}\left(\frac{X_i-\mu}{\sigma}\right)^2=\frac{(n-1)\,s^2}{\sigma^2}+\frac{n\left(\overline{X}-\mu\right)^2}{\sigma^2}$$

el término de la izquierda sigue una distribución χ^2_n mientras que el último sumando de la derecha sigue una distribución χ^2_1

$$\sum_{i=1}^{n}\left(\frac{X_i-\mu}{\sigma}\right)^2\sim\chi^2_n \qquad \frac{n\left(\overline{X}-\mu\right)^2}{\sigma^2}\sim\chi^2_1$$

aquí tendremos que hacer un pequeño salto de fe: las distribuciones de la suma son independientes. Si esto es cierto (y lo es), entonces tenemos

$$\chi^2_n=\frac{(n-1)\,s^2}{\sigma^2}+\chi^2_1$$

y esto obliga a que

$$\frac{(n-1)\,s^2}{\sigma^2}\sim\chi^2_{n-1}$$

El arte de estimar 8

Idea central

No podemos medir directamente los parámetros que nos interesan —como la media o la varianza poblacional— pero podemos estimarlos a partir de una muestra. ¿Qué distingue a un buen estimador de uno malo?

Como ha venido quedando claro en el capítulo anterior, es un poco raro hablar de la media muestral, varianza muestral o proporción muestral *si conocemos la media, varianza o proporción poblacional.* Sin embargo, básicamente estamos usando el mismo truco que cuando nos enseñaron por primera vez álgebra: usted tiene algo que no conoce, pero haga como que lo conoce y póngale por nombre x.

Lo que haremos será intentar encontrar un buen[1] valor para los parámetros poblacionales a partir de una muestra. Teóricamente, podríamos usar cualquier receta que se nos ocurra. Podríamos decir que vamos a estimar la media tomando el promedio de los datos que salieron en orden impar, o que vamos a estimar la varianza elevando cada dato al cuadrado, sumando y dividiendo por n^3. A veces una receta loca puede tener cierto sentido. Sin embargo, primero necesitamos definir cómo vamos a medir la calidad de un estimador.

1: para alguna definición de bueno

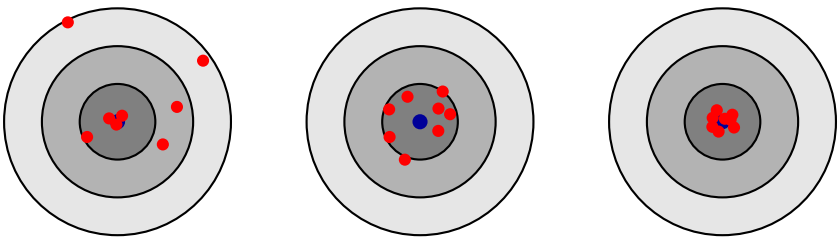
Un punto importante a tener en cuenta: ningún estimador es perfecto. Todos los estimadores dependen de la muestra y, por azar, podemos sacar justo la muestra en que todas las personas miden 170 cm de una población cuyas estaturas se distribuyen normalmente, con media 168 cm y desviación estándar 5 cm. ¿Poco probable? Sí, pero no imposible. Un ejemplo menos extremo podría ser más claro, en que sacamos 4 personas que miden más de 170 cm

y una que mide 168 cm. Sería difícil achuntarle a que la media poblacional es 168. Además, incluso si resultara con esa muestra, usando la misma manera de estimar con otra muestra puede que dé otro valor. En resumen, un estimador puntual difícilmente nos dará el valor exacto del parámetro que estima, pero idealmente debería estar relativamente cercano para la mayoría de las muestras.

¡Hey!

Antes de ver cómo se evalúan los estimadores: ¿qué propiedades le gustaría que tuviera uno? Intente listar dos o tres características que le parezcan deseables.

Una forma de entender los estimadores es imaginar que son tiradores de dardos.



Tirador 1 Tirador 2 Tirador 3

¡Hey!

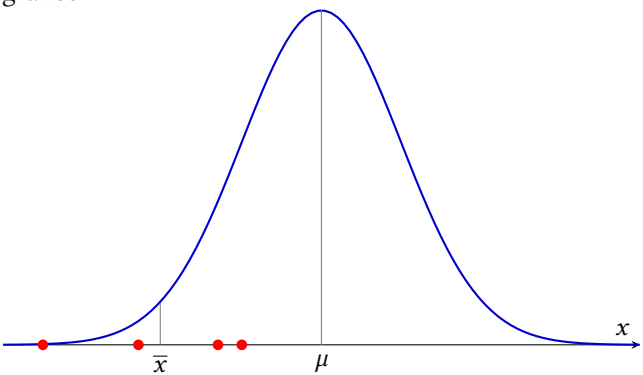
De los tiradores que ve en la figura, ¿cuál preferiría tener? ¿El que en promedio apunta al centro pero con mucha dispersión, o el que se aleja un poco del centro pero con muy poca dispersión?

Cada tirador está tratando de dar en el blanco. Sin embargo, hay varias formas en que se puede fallar y sólo una en que se puede ser perfectamente exitoso *siempre*. En nuestro caso, un estimador está tratando de dar en el blanco. El blanco es algún parámetro de nuestra población. Generalmente, consideraremos la media o varianza, pero podría ser cualquier cosa:

mediana, curtosis, simetría, etc. Nuestro ideal sería encontrar un estimador que

1. En general esté cerca del parámetro. Es imposible que siempre esté cerca, pero ojalá la mayor parte de las veces.
2. En general no sea muy disperso. Es imposible que no tenga dispersión, pero si esa dispersión es de alguna forma pequeña, sirve.

¿Por qué es imposible pedir el estimador perfecto? Un estimador es un cálculo que se puede hacer para todas las muestras posibles. Eso quiere decir que, incluso en el mejor de los estimadores posibles, como la media muestral $\overline{x}$ para estimar μ de una población normal, podríamos tener una situación como la del gráfico



donde el estimador $\overline{x}$, aplicado a esa muestra, no da cerca del parámetro μ.[2]

Nuestro plan será

1. Definir qué hace que un estimador sea bueno.
2. Definir estrategias razonables para encontrar estimadores.

2: en general, denotaremos un estimador de un parámetro θ por $\hat{\theta}$, salvo en casos como la media, donde solemos usar $\overline{x}$.

8.1 ¿Qué hace que un estimador sea bueno? Error cuadrático medio y amigos

Si $\hat{\theta}$ es un estimador de un parámetro θ, ambos son cosas distintas. Por un lado θ es un número que calculamos a partir de la *población* y, por lo tanto, es fijo.[3] Por otra parte, $\hat{\theta}$ es un número distinto para cada muestra y, como la muestra se supone aleatoria, eso significa que un estimador es una variable aleatoria. Esto tiene como consecuencia que un estimador tiene todas las cosas que una variable aleatoria tiene, como una distribución de probabilidad, esperanza, varianza, etc.

3: la población *no* cambia

Para este estimador, podemos calcular la diferencia entre el valor que dio para una muestra y el valor que quiere estimar

$$\hat{\theta} - \theta$$

pero igual es mala idea así, porque si para una muestra nos da un valor y para otra nos da justo el opuesto, cuando juntemos a través de todas las muestras, capaz que nos dé injustificadamente 0. Usemos la técnica que hemos usado a través del curso y elevemos al cuadrado

$$\left(\hat{\theta} - \theta\right)^2.$$

¿Cómo juntamos el "a través de todas las muestras" que aparece mencionado en el párrafo anterior como si fuera tan fácil? Bueno, no es difícil. ¿Qué tal esto?

$$\mathrm{E}\left(\left(\hat{\theta} - \theta\right)^2\right)$$

Precisamente lo que queremos: el valor esperado de las diferencias, pero al cuadrado para evadir los problemas de signo.

Definiremos como el *error cuadrático medio* de un estimador $\hat{\theta}$ de un parámetro θ al valor

$$\mathrm{ECM}\left(\hat{\theta}\right) = \mathrm{E}\left(\left(\hat{\theta} - \theta\right)^2\right)$$

El ECM es poco práctico de esa manera, pero además no nos dice mucho (más allá de que parezca razonable). Hay una manera en que podemos calcularlo más fácilmente y además tiene una interpretación transparente.

$$\begin{aligned}\mathrm{ECM}\left(\hat{\theta}\right) &= \mathrm{E}\left(\left(\hat{\theta} - \theta\right)^2\right) \\ &= \mathrm{E}\left(\hat{\theta}^2 - 2\hat{\theta}\theta + \theta^2\right)\end{aligned}$$

θ es un número

$$= \mathrm{E}\left(\hat{\theta}^2\right) - 2\theta\,\mathrm{E}\left(\hat{\theta}\right) + \theta^2$$

por otra parte, despejando $\mathrm{E}\left(\hat{\theta}^2\right)$ de $\mathrm{Var}\left(\hat{\theta}\right) = \mathrm{E}\left(\hat{\theta}^2\right) - \mathrm{E}\left(\hat{\theta}\right)^2$

$$= \mathrm{Var}\left(\hat{\theta}\right) + \mathrm{E}\left(\hat{\theta}\right)^2 - 2\theta\,\mathrm{E}\left(\hat{\theta}\right) + \theta^2$$

pero los tres últimos términos hacen un cuadrado de binomio

$$\mathrm{ECM}\left(\hat{\theta}\right) = \mathrm{Var}\left(\hat{\theta}\right) + \left(\mathrm{E}\left(\hat{\theta}\right) - \theta\right)^2$$

Esta forma del ECM es más práctica pero además nos muestra que el error cuadrático medio está compuesto de dos partes: la varianza del estimador y la diferencia entre el valor esperado del estimador y el verdadero valor del parámetro.

La segunda parte, la diferencia (sin el cuadrado) en-

tre el valor esperado del estimador y el verdadero parámetro se conoce como *sesgo.* Idealmente, un estimador debería tener sesgo 0, es decir, la esperanza del estimador debería ser el parámetro que estima. Cuando esto ocurre, se dice que el estimador es *insesgado.*

La varianza del estimador, por otra parte, se considera como su *eficiencia.* El estimador $\hat{\theta}_1$ es más eficiente que el estimador $\hat{\theta}_2$ si

$$\text{Var}\left(\hat{\theta}_1\right) < \text{Var}\left(\hat{\theta}_2\right).$$

Mientras más eficiente un estimador, sus estimaciones estarán más concentradas. *Adonde* estén concentradas tiene que ver con el sesgo del estimador.

8.1.1 Cota de Cramér-Rao

El estimador perfecto sería insesgado y con varianza 0. Ese estimador no existe.

Hay una cota inferior de las varianzas de los posibles estimadores: la cota de Cramér-Rao.

¿Qué tan seguros estamos? 9

Idea central

Un número puntual no captura la incertidumbre de nuestra estimación. ¿Cómo podemos expresar, de manera precisa, qué tan confiados estamos en nuestro resultado y qué rango de valores es plausible?