Apuntes de Probabilidad y Estadística

Álvaro Mattus Donaire

20 de octubre de 2025

Notas personales

Índice general

Índice general **ii**

1 ¿Qué probabilidad hay? 1
1.1 Introducción . . . 1
1.2 Eventos, espacios muestrales y probabilidad . . . 3
1.3 Probabilidad condicional . . . 4
1.4 Principio multiplicativo . . . 4
1.5 Independencia . . . 7
1.6 Principio aditivo . . . 9
1.7 Preguntas frecuentes . . . 13
1.7.1 Una nota sobre visualización de eventos . . . 14
1.8 Conteo . . . 16
1.8.1 Permutaciones . . . 18
1.8.2 Combinaciones . . . 19
1.8.3 Algunos casos extra . . . 20

2 Probabilidades++ 22
2.1 Axiomas de probabilidad . . . 22
2.2 Teorema de Bayes . . . 23
2.2.1 Enfermedades y exámenes . . . 27
2.2.2 Odds . . . 30

3 Variables aleatorias 33
3.1 Introducción . . . 33
3.2 Variables aleatorias discretas . . . 36
3.3 Variables aleatorias continuas . . . 37
3.4 Esperanza y varianza . . . 38
3.4.1 Definición de la esperanza y sus propiedades . . . 38
3.4.2 Definición de la varianza y sus propiedades . . . 42
3.5 ¿Qué significa sumar variables aleatorias? (opcional) . . . 45

4 El zoológico de las variables aleatorias, parte 1 51
4.1 Distribución de Bernoulli . . . 51
4.2 Variables aleatorias discretas y su relación con VAs Bernoulli 53
4.3 Distribución binomial . . . 55
4.4 Distribución geométrica . . . 59

4.5 Distribución binomial negativa 62
4.6 Distribución hipergeométrica 65
4.7 Distribución de Poisson 66

5 El zoológico de variables aleatorias, parte 2 70
5.1 Distribución uniforme 70
5.2 Distribución normal 72
5.2.1 Trabajando con la distribución normal 75
5.2.2 Tablas para la distribución normal estándar 78
5.3 Distribución χ^2 82
5.4 Distribución t 84

6 Estadística descriptiva y análisis exploratorio de datos 87
6.1 Señal versus ruido 87

7 Distribuciones muestrales 88
7.1 La ley de los grandes números 88
7.2 Teorema del límite central 90
7.3 Distribuciones muestrales 91
7.3.1 Distribución muestral de la media muestral 92
7.3.2 Distribución muestral de la proporción muestral . . 92
7.3.3 La distribución muestral de la media muestral para poblaciones de varianza desconocida 93

Distribuciones muestrales 7

7.1 La ley de los grandes números

En la clase hicimos un pequeño experimento tirando una moneda diez veces. No recuerdo los resultados, pero aquí lo hice unas cuantas veces

Número de Caras	Frecuencia	Proporción
1	1	0,05
2	1	0,05
3	1	0,05
4	6	0,30
5	7	0,35
6	3	0,15
7	1	0,05

La mayoría de los resultados están dentro del intervalo $[4, 6]$, lo que es más o menos esperable. Si nos metemos en el intervalo $[3, 7]$ ya están casi todos los resultados: sólo faltan dos.

Sin embargo, si hacíamos el experimento 1000, 5000 o más veces la intuición nos decía que esa diferencia tenía que irse achicando, ¿no? NO.

Nuestra intuición no está tan errada, pero hay que afinarla. En general, cuando tenemos una suma (o promedio o conteo) tendremos que

$$\text{suma} = \text{valor esperado} + \text{error aleatorio}.$$

La pregunta es qué tan grande es ese error aleatorio. Hay una fórmula que nos permite establecer el tamaño de este error, llamado *error estándar*. Cuando contabilicemos la suma de las extracciones de una

caja, con reposición, el error estándar de la suma es

$$\sqrt{\text{número de extracciones}} \cdot (\text{desviación estándar de la caja})$$

En otras palabras, el error *aumenta* a medida que repetimos nuestro experimento, de manera proporcional a la raíz del número de repeticiones. En ese sentido, nuestra intuición estaba completamente incorrecta. Sin embargo, si consideramos el promedio

$$\frac{\sqrt{\text{número de extracciones}} \cdot (\text{SD de la caja})}{\text{número de extracciones}} = \frac{\text{SD de la caja}}{\sqrt{\text{número de extracciones}}}$$

y cuando el número de extracciones crece, el error estándar decrece.

Esta idea está representada en la *ley de los grandes números*. Hay varias versiones de esta ley, pero todas son teoremas que hablan de la convergencia de una serie de variables aleatorias.

Si $X_1, X_2, \cdots, X_n$ son variables aleatorias independientes e idénticamente distribuidas, con esperanza μ y varianza σ^2 finitas, entonces la variable $\overline{X} = \sum_{i=1}^{n} X_i/n$ cumple que para todo $\varepsilon > 0$,

$$\lim_{n\to\infty} \mathrm{P}\left(|\overline{X} - \mu| \leq \varepsilon\right) = 0$$

Lo que dice este teorema es que, efectivamente, el promedio muestral converge hacia el promedio poblacional a medida que aumenta el tamaño de la muestra. Es posible que esa convergencia no ocurra, pero si la muestra es realmente azarosa, es lo que ocurrirá la mayor, muy mayor, parte del tiempo[1].

1: tan mayor que en realidad casi nunca no ocurre

7.2 Teorema del límite central

El teorema del límite central (o teorema central del límite) es quizás el resultado más importante en probabilidad. En cierta manera, es una continuación de la ley de los grandes números.

Si $X_1, X_2, \cdots, X_n$ son variables aleatorias independientes e idénticamente distribuidas, con esperanza μ y varianza σ^2 finitas (y la varianza mayor que 0), entonces la VA

$$Z_n = \frac{\overline{X} - \mu}{\sigma/\sqrt{n}}$$

converge en distribución a la normal estándar cuando n se va a infinito, es decir,

$$\lim_{n\to\infty} P(Z_n \leq x) = P(Z \leq x)$$

donde $Z \sim \mathcal{N}(0, 1)$.

Hay algunas cosas que decir. La primera es una observación menor. Si nos fijamos, la variable Z_n nos está diciendo el comportamiento de la media muestral. Mediante un truco algebraico bien conocido (amplificar por n) obtenemos lo siguiente

$$Z_n = \frac{\overline{X} - \mu}{\sigma/\sqrt{n}} = \frac{\sum_{i=1}^{n} X_i - n\mu}{\sqrt{n}\sigma}$$

y por lo tanto el teorema también nos cuenta acerca de la suma de las variables, lo que puede ser de utilidad.

Una segunda cosa es que si

$$\lim_{n\to\infty} Z_n = \mathcal{N}(0, 1)$$

(usando una notación un poco liberal), y recordamos qué es estandarizar una distribución normal, descubriremos que otra forma de enunciar el teorema

es

$$\overline{X_n} \approx \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$$

(usando una idea todavía más liberal, porque estamos obviando el límite).

Un tercer punto es que, y esto es lo más increíble, el teorema no puso *ninguna* restricción a la distribución que siguen los X_i, salvo que tuvieran media y varianza finitas y varianza no nula además.

Por ejemplo, los X_i podrían provenir de una distribución de Bernoulli (éxito con probabilidad p, fracaso con probabilidad $1 - p$, como tirar una moneda). Si es así, $\mathrm{E}(X_i) = p$ y $\mathrm{Var}(X_i) = p(1 - p)$. Además, la variable

$$Y_n = X_1 + X_2 + \cdots + X_n$$

sigue una distribución binomial

$$Y_n \sim \mathrm{Bin}(n, p).$$

Por lo tanto,

$$Z_n = \frac{Yn - np}{\sqrt{np(1-p)}}$$

converge hacia una normal estándar.

7.3 Distribuciones muestrales

Las secciones anteriores nos llevan a un resultado: las distribuciones muestrales de la media muestral, la varianza muestral y la proporción muestral.

7.3.1 Distribución muestral de la media muestral

Básicamente, esta sección es reiterar lo dicho en la anterior. Gracias al teorema del límite central, sabemos que la media muestral sigue una distribución normal con media μ y desviación estándar $\sigma/\sqrt{n}$

$$\overline{X} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$$

o, equivalentemente, la variable

$$Z = \frac{\overline{X} - \mu}{\sigma/\sqrt{n}}$$

sigue una distribución normal estándar.

7.3.2 Distribución muestral de la proporción muestral

El teorema del límite central nos dice que la variable puede seguir, básicamente, cualquier distribución. En particular, podría seguir la distribución binomial.

Recordemos que la distribución binomial cuenta la cantidad de *éxitos* registrados dentro de n intentos. Por ejemplo, si estamos si alguien es zurdo o diestro, podemos usar la distribución binomial para ver la probabilidad de que 5 personas en nuestro curso de 37 sean zurdas.

Pero una forma equivalente es preguntarnos por la probabilidad de que la proporción de personas zurdas sea 5/37. En otras palabras, al dividir por la cantidad total obtenemos una nueva distribución binomial, pero esta vez con esperanza p y varianza pq.

En otras palabras, la proporción muestral $\hat{p}$ se distribuye según una distribución normal

$$\hat{p} \sim \mathcal{N}\left(p, \frac{pq}{n}\right)$$

o lo que es lo mismo, la variable

$$Z = \frac{\hat{p} - p}{\sqrt{pq/n}}$$

sigue una distribución normal estándar.

7.3.3 La distribución muestral de la media muestral para poblaciones de varianza desconocida

Volviendo a la media, hasta ahora hemos asumido algo un poco extraño: la varianza poblacional es conocida[2]. Esto es raro porque, si conocemos la media y la varianza poblacional, no tiene sentido que nos preocupemos por las muestras. Sin embargo, es donde estamos y pronto ya no conoceremos ninguna de las dos.

2: y que la media poblacional también es conocida

Por lo pronto, ¿qué pasa si no conocemos la varianza poblacional, es decir, si sólo tenemos la varianza muestral? Podemos aproximar la distribución de la media muestral, pero no podremos aproximarla mediante una normal.

Ese fue (parte d)el problema que trató de resolver William Sealy Gosset mientras trabajaba en la cervecería Guiness. En particular, le interesaba ver cómo podía resolver el problema de trabajar con muestras pequeñas. Su trabajo junto con Ronald Fisher[3] los llevó a postular la distribución t.

3: básicamente el padre de la estadística moderna

La distribución t_ν es una distribución que depende sólo de un parámetro: los grados de libertad (ν). La

media siempre es 0 y la varianza es $\nu/(\nu-2)$ cuando $\nu > 2$.

Para trabajar con esta distribución debemos calcular el score T, de manera análoga a como lo hacíamos con la distribución normal

$$T = \frac{\overline{x} - \mu}{s/\sqrt{n}}$$

donde $\overline{x}$ es la media muestral, μ es la media poblacional, n es la cantidad de observaciones de la muestra y s es la desviación estándar muestral definida por

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \overline{x}).$$

Este score T sigue entonces una distribución t con n grados de libertad

$$T \sim \mathrm{t}_n\,.$$