Apuntes de Probabilidad y Estadística

Álvaro Mattus Donaire

1 de septiembre de 2025

Notas personales

Índice general

Índice general **ii**

1 ¿Qué probabilidad hay? 1
1.1 Introducción . . . 1
1.2 Eventos, espacios muestrales y probabilidad . . . 3
1.3 Probabilidad condicional . . . 4
1.4 Principio multiplicativo . . . 4
1.5 Independencia . . . 7
1.6 Principio aditivo . . . 9
1.7 Preguntas frecuentes . . . 13
1.7.1 Una nota sobre visualización de eventos . . . 14
1.8 Conteo . . . 16
1.8.1 Permutaciones . . . 18
1.8.2 Combinaciones . . . 19
1.8.3 Algunos casos extra . . . 20

2 Probabilidades++ 22
2.1 Axiomas de probabilidad . . . 22
2.2 Teorema de Bayes . . . 23
2.2.1 Enfermedades y exámenes . . . 27
2.2.2 Odds . . . 30

3 Variables aleatorias 33
3.1 Introducción . . . 33
3.2 Variables aleatorias discretas . . . 36
3.3 Variables aleatorias continuas . . . 37
3.4 Esperanza y varianza . . . 38
3.4.1 Definición de la esperanza y sus propiedades . . . 38
3.4.2 Definición de la varianza y sus propiedades . . . 42
3.5 ¿Qué significa sumar variables aleatorias? (opcional) . . . 45

4 El zoológico de las variables aleatorias, parte 1 51
4.1 Distribución de Bernoulli . . . 51
4.2 Variables aleatorias discretas y su relación con VAs Bernoulli 53
4.3 Distribución binomial . . . 55
4.4 Distribución geométrica . . . 59

4.5 Distribución binomial negativa 62
4.6 Distribución hipergeométrica 65
4.7 Distribución de Poisson 66

¿Qué probabilidad hay? 1

1.1 Introducción

En este texto, cada vez que el color del mismo sea negro, este texto está más enfocado en las ideas que dan sustento a la teoría.

Todos los días nos encontramos con frases que tienen que ver con probabilidades: ¿Irá a llover? ¡Me encontré con Juanito! No lo veía hace años.

Los matemáticos y científicos también se dieron cuenta que necesitaban hablar de probabilidades pero, a diferencia de nuestro uso cotidiano, es necesario un lenguaje, unas definiciones, más precisas.

El problema es que es difícil. Hay varias formas de ver la probabilidad y ninguna cubre todos los significados que le asignamos de forma cotidiana al término. En este curso, haremos uso de la definición frecuentista de probabilidad. Esta definición opera bajo algunos supuestos, por ejemplo que podemos repetir un proceso varias veces, independientemente y bajo las mismas condiciones.

Esto es algo que suele ocurrir con los juegos de azar. De hecho, uno de los orígenes de la teoría de probabilidad es el estudio de los juegos de azar y apuestas.

Por ejemplo, al lanzar un dado ideal, cada cara tiene la misma probabilidad de aparecer que las otras, $1/6$ o $16{,}67\,\%$. La interpretación es que, al lanzar el dado bajo las mismas condiciones, en el largo plazo cada cara aparecerá $1/6$ de las veces.

Definición 1.1.1 *La probabilidad de algo es el porcentaje de veces que se espera que ocurra en el largo plazo, cuando el proceso que le da origen se repite una y otra vez, de manera independiente y bajo las mismas condiciones.*

Si algo es imposible que pase, su probabilidad es 0. Si algo es seguro, su probabilidad es 100 %. Esos son lógicamente los casos extremos, por lo que

Observación 1.1.1 Todas las probabilidades están entre 0 y 1 (0 % y 100 %).

Otro hecho fundamental: supongamos que estamos jugando un juego en el que tenemos un 30 % de ganar. En otras palabras, esperamos ganar un 30 % de las veces que jugamos. Por lo tanto, esperamos perder el otro 70 % de las veces.

Observación 1.1.2 La probabilidad de algo es 100 % menos la probabilidad de su opuesto.

Problema: Apostamos en un juego en el que, al sacar una pelota de una caja, si es roja ganamos y si es azul perdemos. Cada pelota tiene la misma probabilidad de ser escogida.

Si podemos elegir la caja de entre las dos siguientes:

Caja A: Contiene 2 pelotas rojas y 3 pelotas azules.
Caja B: Contiene 20 pelotas rojas y 30 pelotas azules.

¿cuál nos conviene?

Quizás es un experimento un poco tonto, pero lo que sí es muy útil es la idea de escoger pelotas de colores desde una caja. Resulta que muchas situaciones en probabilidad (y estadística) se pueden modelar de esta forma. Este es, entonces, nuestro primer modelo probabilístico.

1.2 Eventos, espacios muestrales y probabilidad

En este texto, cada vez que el color del mismo sea azul, este texto está más enfocado en la teoría y en las definiciones.

Un experimento es un procedimiento que puede ser repetido indefinidamente y que tiene un conjunto bien definido de resultados. Si el experimento tiene un resultado, es un experimento determinista. Si tiene más de un resultado, es un experimento aleatorio.[1]

1: En este curso sólo nos ocuparemos de experimentos aleatorios.

El conjunto de resultados de un experimento aleatorio se llama el *espacio muestral* del experimento aleatorio.

Cada vez que realizamos un experimento aleatorio, se obtiene un y sólo un resultado. Sin embargo, este resultado puede estar incluido en uno o más *eventos*. Un evento es un subconjunto del espacio muestral. Cada evento está compuesto de cero o más resultados.

Normalmente, nos ocuparemos de eventos con mayor o menor nivel de complejidad en vez de concentrarnos en resultados.

Dicho de otro modo, si tenemos un espacio muestral Ω, cada evento es un elemento de $\mathscr{P}(\Omega)$, el conjunto potencia de Ω.

De esta manera, la probabilidad se define como una función $\mathrm{P} : \mathscr{P}(\Omega) \to [0,1]$ que cumple con ciertas características, los axiomas de probabilidad (que veremos más adelante).

En la sección anterior hablamos acerca del "opuesto" de un evento. En la literatura, esto se conoce como el *complemento* de un evento. Hay varias formas de escribirlo simbólicamente; una de las más comunes es A^{c} para el complemento del evento A.

1.3 Probabilidad condicional

Imaginemos que tenemos una baraja de naipes. Esta baraja tiene 52 cartas (son 13 cartas por pinta y dejamos fuera a los jokers). Supongamos que saco dos cartas y que gano el juego si la segunda carta es el as de picas.

a) ¿Cuál es la probabilidad de ganar?
b) Si doy vuelta la primera carta y es el 6 de corazones, ¿cuál es la probabilidad de ganar?

En la parte a), la primera carta no importa realmente. Podemos dar vuelta la segunda carta inmediatamente. Por lo tanto, como tengo 52 cartas a disposición, mi probabilidad de ganar es 1/52 (o 1,92 %).

En la parte b), ya no tengo 52 cartas que "repartir"; sólo tengo 51. Esto ocurre porque ya sé que la primera carta es el 6 de corazones. Por lo tanto, mi probabilidad de ganar es 1/51 (o 1,96 %).

Esta segunda probabilidad es lo que se conoce como *probabilidad condicional*. El problema pone una condición en la primera carta: tiene que ser el 6 de corazones.

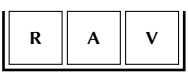
En símbolos,

$$\mathrm{P}(\text{As de picas} \mid \text{6 de corazones}) = \frac{1}{51}$$

(la barra se lee "dado").

1.4 Principio multiplicativo

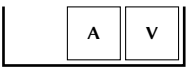
Una caja contiene tres fichas, una roja, una azul y una verde.



Vamos a sacar dos fichas de la caja, sin reemplazo. ¿Cuál es la probabilidad de sacar primero la ficha roja y luego la azul?

Imaginemos que tenemos un grupo grande de personas, digamos 600 personas, cada una de ellas con una caja como la de arriba. Alrededor de 200 de ellas van a sacar la ficha roja la primera vez. De esas doscientas personas, alrededor de 100 van a sacar la ficha azul la segunda vez. Así que $100/600 = 1/6$ o 16,67 % de las personas van a sacar la ficha roja primero y la azul después.

En otras palabras, la cantidad de personas que van a sacar primero la ficha roja es alrededor de $1/3$ de la cantidad original de personas, las que se quedan con



La segunda vez que sacan una ficha, alrededor de la mitad de las personas van a sacar la ficha azul. La fracción que saca la ficha roja y luego la azul es entonces

$$\frac{1}{2} \text{ de } \frac{1}{3} = \frac{1}{2} \cdot \frac{1}{3} = \frac{1}{6}.$$

El método del ejemplo anterior se llama *principio multiplicativo*.

Definición 1.4.1 (Principio multiplicativo) *La probabilidad de que, de dos cosas, ambas ocurran es la probabilidad de que ocurra la primera multiplicada por la probabilidad de que ocurra la segunda dado que la primera ya ocurrió.*

En símbolos, si A y B son eventos, entonces

$$\mathrm{P}(A \cap B) = \mathrm{P}(A)\,\mathrm{P}(B \mid A).$$

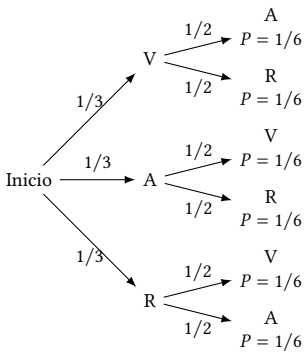


Figura 1.1: Diagrama de árbol para el experimento de sacar dos fichas de la caja.

Podría parecer que tenemos un problema con el orden de los eventos. Sin embargo, si recordamos de teoría de conjuntos que $A \cap B = B \cap A$, podemos escribir el principio multiplicativo como

$$\mathrm{P}(A \cap B) = \mathrm{P}(B)\,\mathrm{P}(A \mid B).$$

Otro ejemplo. En nuestro ejemplo de la baraja de naipes de la sección 1.3 (Probabilidad condicional), la probabilidad de sacar primero el seis de corazones y luego el as de picas es

$$\begin{aligned}\mathrm{P}(6\,\heartsuit \cap \text{As}\,\spadesuit) &= \mathrm{P}(6\,\heartsuit)\,\mathrm{P}(\text{As}\,\spadesuit \mid 6\,\heartsuit)\\ &= \frac{1}{52}\cdot\frac{1}{51}\\ &= \frac{1}{2652}.\end{aligned}$$

Esta probabilidad es pequeña, aproximadamente 4 en 10.000.

¿Qué pasaría si nos preguntáramos por la probabilidad de sacar dos ases? La probabilidad de sacar el primer as es $4/52$. Dado que la primera carta fue un as, la probabilidad de que la segunda carta también sea un as es $3/51$. Por lo tanto, la probabilidad de sacar dos ases es

$$\frac{4}{52}\cdot\frac{3}{51} = \frac{12}{2652}.$$

Esta probabilidad es aproximadamente 1 en 200.

Otro ejemplo. Una moneda se lanza dos veces. ¿Cuál es la probabilidad de sacar cara y luego sello de una moneda justa[2]?

La probabilidad de que el primer lanzamiento sea cara es $1/2$. No importa cómo salga este primer lanzamiento, la probabilidad de que el segundo lanzamiento sea sello es $1/2$. Por lo tanto, la probabilidad de que el primer lanzamiento sea cara y el segundo

2: una moneda justa es aquella que tiene la misma probabilidad de caer en cara o en sello (y 0 de otra forma, como caer de canto)

sello es

$$\frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}.$$

1.5 Independencia

La idea de independencia es una que va a aparecer repetidamente dentro de este texto.

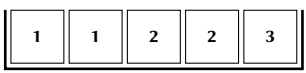
Definición 1.5.1 (Independencia) *Dos eventos son independientes si la probabilidad de que ocurra el segundo dado el primero son iguales, sin importar qué haya ocurrido con el primero. En caso contrario, los eventos son* dependientes.

Un ejemplo. Supongamos que lanzamos una moneda dos veces y ganamos si la segunda vez sale cara.

a) Si en el primer lanzamiento salió cara, ¿cuál es la probabilidad de ganar?
b) Si en el primer lanzamiento salió sello, ¿cuál es la probabilidad de ganar?
c) ¿Los lanzamientos son independientes?

En la parte a), la probabilidad de ganar es 50 % (la probabilidad de que salga cara en el segundo lanzamiento). En la parte b), la probabilidad de ganar es también 50 %. La probabilidad de ganar no se ve influida por el resultado del primer lanzamiento. Eso es independencia.

Otro ejemplo. Se sacan dos fichas con reposición de la siguiente caja



a) Supongamos que la primera ficha tiene una etiqueta 1. ¿Cuál es la probabilidad de que la segunda ficha tenga una etiqueta 2?

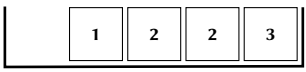
b) Supongamos que la primera ficha tiene una etiqueta 2. ¿Cuál es la probabilidad de que la segunda ficha tenga una etiqueta 2?
c) Es independiente el resultado de la primera ficha del resultado de la segunda?

Si la primera ficha tiene etiqueta 1, 2 o 3, la probabilidad de que la segunda ficha tenga una etiqueta 2 es siempre[3] 2 de 5 o 40 %. Por lo tanto, los resultados son independientes.

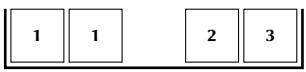
3: porque hay reposición

Otro ejemplo. Tenemos la misma caja del ejemplo anterior, pero ahora sacamos dos fichas sin reposición.

Si la primera ficha tiene etiqueta 1, nos quedamos con la caja



y la probabilidad de que la segunda ficha tenga etiqueta 2 es $2/4 = 1/2$ o 50 %. Si la primera ficha tiene etiqueta 2, nos quedamos con la caja



y la probabilidad de que la segunda ficha tenga etiqueta 2 es $1/4$ o 25 %. Por lo tanto, los resultados no son independientes.

Observación 1.5.1 Cuando el muestreo es con reposición, los eventos son independientes. Cuando el muestreo es sin reposición, los eventos son dependientes.

La versión en símbolos de la definición de independencia es la siguiente. Si A y B son eventos independientes, entonces

$$\mathrm{P}(B \mid A) = \mathrm{P}(B \mid A^{\mathrm{c}}) = \mathrm{P}(B).$$

Sin embargo, esa no es la definición que aparece en los libros.

Para encontrar la versión popular de la definición, tenemos que recordar que

$$\mathrm{P}(A \cap B) = \mathrm{P}(A)\,\mathrm{P}(B \mid A).$$

Por lo tanto, si A y B son independientes, entonces

$$\mathrm{P}(A \cap B) = \mathrm{P}(A)\,\mathrm{P}(B).$$

Esta es la versión más común de la definición de independencia y es un caso especial del principio multiplicativo.

1.6 Principio aditivo

Esta sección trata sobre cómo calcular la probabilidad de que ocurra al menos uno de dos eventos, es decir, que ocurra el primero, el segundo o ambos. Resulta que cuando ocurren ambos, la situación se complica un poco, por lo que haremos una definición.

Definición 1.6.1 (Eventos mutuamente excluyentes) *Dos cosas son mutuamente excluyentes si la ocurrencia de una impide la ocurrencia de la otra. En otras palabras, si una ocurre, la otra no puede ocurrir.*

Con esa definición, podemos establecer el principio aditivo.

Definición 1.6.2 (Principio aditivo) *Para encontrar la probabilidad de que al menos una de dos cosas ocurra, primero verificamos si son mutuamente excluyentes. Si lo son, entonces simplemente sumamos las probabilidades de cada una.*

Un ejemplo. La probabilidad de sacar un corazón de una baraja bien revuelta es $1/4$. La probabilidad de sacar una pica de una baraja bien revuelta es también $1/4$. ¿Cuál es la probabilidad de sacar un corazón o una pica? Como no es posible sacar una carta que sea a la vez corazón y pica, los eventos son mutuamente excluyentes. Por lo tanto, la probabilidad de sacar un corazón o una pica es $1/4+1/4 = 1/2$ o 50 %.

Otro ejemplo. Lanzamos dos dados (pensemos en uno blanco y uno negro para diferenciarlos). Tu amigo dice que la probabilidad de sacar al menos un 1 es

$$\frac{1}{6} + \frac{1}{6} = \frac{1}{3}.$$

¿Tiene razón?

No. La pregunta pide que pase al menos una de estas cosas:

- Que el dado blanco muestre un 1 ⚀.
- Que el dado negro muestre un 1 ⚀.

y que un dado muestre un 1 no impide que el otro también muestre un 1. Estos eventos no son mutuamente excluyentes así que el principio aditivo no corre: no podemos sumar las probabilidades.

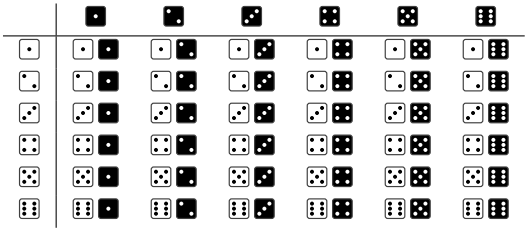


Tabla 1.1: Espacio muestral del lanzamiento de dos dados.

El Tabla 1.1 nos muestra todos los resultados posibles al lanzar dos dados. Hay seis resultados en los que el dado blanco muestra un 1 y seis resultados en los que el dado negro muestra un 1. Pero el número de maneras de obtener al menos un 1 no es $6 + 6$: sumar a la rápida cuenta dos veces el resultado ⚀⚀. La probabilidad de obtener al menos un 1 al lanzar dos dados es

$$(6 + 6 - 1)/36 = 11/36.$$

Observación 1.6.1 Si queremos encontrar la probabilidad de que al menos un evento ocurra, y los eventos no son mutuamente excluyentes, no sumemos las probabilidades individuales: la suma va a ser demasiado grande.

Definición 1.6.3 (Principio aditivo II: el regreso) *Si queremos calcular la probabilidad de que al menos un evento ocurra y los eventos no son mutuamente excluyentes, podemos sumar la probabilidad de cada evento, pero debemos restar la probabilidad de que ocurran ambos eventos conjuntamente. Eso es lo que estamos sumando de más.*

El principio aditivo es sencillo de escribir simbólicamente:

$$\mathrm{P}(A \cup B) = \mathrm{P}(A) + \mathrm{P}(B) - \mathrm{P}(A \cap B).$$

Si recordamos que nuestra definición de eventos mutuamente excluyentes es que la ocurrencia de uno impide la ocurrencia del otro, podemos ver que si A y B son mutuamente excluyentes, entonces

$$\mathrm{P}(A \cap B) = 0.$$

Por lo tanto, en ese caso el principio aditivo se reduce a

$$\mathrm{P}(A \cup B) = \mathrm{P}(A) + \mathrm{P}(B).$$

Evidentemente, esto se puede extender a más de dos eventos.

Definición 1.6.4 *Si $A_1, A_2, \ldots, A_n$ son eventos mutuamente excluyentes, entonces*

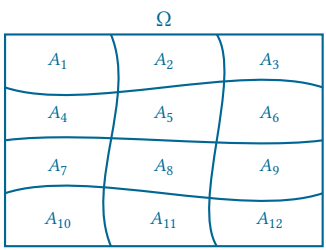
$$\mathrm{P}(A_1 \cup A_2 \cup \cdots \cup A_n) = \mathrm{P}(A_1) + \mathrm{P}(A_2) + \cdots + \mathrm{P}(A_n).$$

Un caso particular de este principio es cuando tenemos una *partición*. Un conjunto de eventos $\{A_1, A_2, \ldots, A_n\}$ es una partición del espacio muestral si son mutuamente excluyentes y su unión es el espacio muestral. En ese caso,

$$\mathrm{P}(A_1 \cup A_2 \cup \cdots \cup A_n) = \mathrm{P}(\Omega) = 1.$$

Por lo tanto, si $A_1, A_2, \ldots, A_n$ es una partición del espacio muestral, entonces

$$\mathrm{P}(A_1) + \mathrm{P}(A_2) + \cdots + \mathrm{P}(A_n) = 1.$$



La figura muestra una partición del espacio muestral. En efecto,

$$\bigcup_{i=1}^{12} A_i = \Omega$$

y

$$A_i \cap A_j = \emptyset,\ i \neq j.$$

1.7 Preguntas frecuentes

1. ¿Cuál es la diferencia entre dos eventos independientes y mutuamente excluyentes?
2. ¿Cuándo sumo y cuándo multiplico?

1. Dos eventos son independientes si la ocurrencia de uno no afecta la probabilidad de que ocurra el otro. Dos eventos son mutuamente excluyentes si la ocurrencia de uno impide la ocurrencia del otro.
   De lo anterior se concluye que dos eventos mutuamente excluyentes no pueden ser independientes: la ocurrencia de uno afecta muy directamente la probabilidad de que ocurra el otro, ya que la lleva a 0.
   Por ejemplo, no podemos lanzar una moneda y que salga cara y sello al mismo tiempo. Si sale cara, no puede salir sello. Por lo tanto esos dos eventos son mutuamente excluyentes. Muchas veces los eventos mutuamente excluyentes tienen que ver con la imposibilidad de obtener más de un resultado al realizar una vez un experimento aleatorio. Por ejemplo, al lanzar un dado, no podemos obtener un 1 y un 2 al mismo tiempo.
   En cambio, dos eventos son independientes porque en realidad no se afectan entre sí. Por ejemplo, al lanzar una moneda dos veces, la moneda no tiene memoria por lo que el resultado del segundo lanzamiento no se ve afectado por el resultado del primero.
   Muchas veces los eventos independientes tienen que ver, o bien con la repetición de un experimento aleatorio *de manera que una repetición que no afecte a las siguientes*[4], o bien con la realización simultanea de experimentos aleatorios diferentes *que no se afectan entre sí*[5].

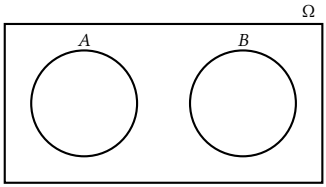


Figura 1.2: Eventos mutuamente excluyentes.

4: por ejemplo, sacar una pelota de una caja con reposición

5: por ejemplo, lanzar un dado y lanzar una moneda

2. Multiplicamos cuando queremos encontrar la probabilidad de que ocurran dos eventos al mismo tiempo. Sumamos cuando queremos encontrar la probabilidad de que ocurra al menos uno de dos eventos.

1.7.1 Una nota sobre visualización de eventos

Muchas veces representamos eventos usando diagramas de Venn, como en la Figura 1.2. Sin embargo, estos diagramas no son muy útiles para calcular probabilidades.

Una alternativa gráfica más útil son los diagramas de árbol. Usamos uno en la Figura 1.1 para el experimento de sacar dos fichas de la caja. En este caso, cada rama del árbol representa un resultado posible y las probabilidades se escriben al lado de cada rama.

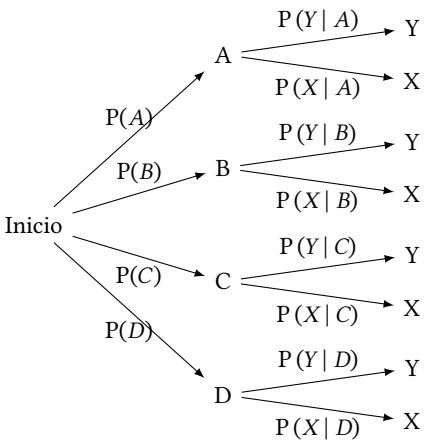


Figura 1.3: Diagrama de árbol con 4 ramas principales y 2 sub-ramas cada una.

Un diagrama de árbol, combinado con los principios aditivo y multiplicativo, nos permite calcular la probabilidad de cualquier evento que involucre los eventos representados en el diagrama. Por ejemplo,

para calcular la probabilidad de que ocurra A y X, podemos seguir la rama que va desde el inicio hasta A y luego hasta X. La probabilidad de que ocurra ese evento es $\mathrm{P}(A) \cdot \mathrm{P}(X \mid A)$. También podemos calcular la probabilidad de que ocurra Y sumando todos los caminos que llevan a Y:

$$\begin{aligned}\mathrm{P}(Y) = \mathrm{P}(A) \cdot \mathrm{P}(Y \mid A) + \mathrm{P}(B) \cdot \mathrm{P}(Y \mid B) + \\ + \mathrm{P}(C) \cdot \mathrm{P}(Y \mid C) + \mathrm{P}(D) \cdot \mathrm{P}(Y \mid D)\end{aligned}$$

Otra visualización, no tan gráfica pero igualmente útil es usar una simple tabla. Si tenemos una tabla simple o de doble entrada, podemos dividir por el total de elementos (asumiendo equiprobabilidad de cada resultado) para encontrar la probabilidad de cada evento. Por ejemplo, si clasificamos los estudiantes de un campus por carrera y género, podemos tener una tabla como la siguiente:

	Matemáticas	Lingüística	Total
Masculino	30	20	50
Femenino	25	25	50
Total	55	45	**100**

Tabla 1.2: Distribución de estudiantes por género y carrera

Dividiendo por el total obtenemos las probabilidades:

	Matemáticas	Lingüística	Total
Masculino	0,3	0,2	0,5
Femenino	0,25	0,25	0,5
Total	0,55	0,45	**1**

Tabla 1.3: Probabilidades de estudiantes por género y carrera

Otra visualización es usar un cuadrado de área 1 para representar el total de estudiantes. Luego, podemos dividir este cuadrado en áreas proporcionales a las probabilidades de cada evento. Por ejemplo, el

si lo hacemos a mano simplemente aproximamos

área correspondiente a los estudiantes masculinos en Matemáticas sería 0,3, en Lingüística 0,2, y así sucesivamente. Esto nos da una representación visual clara de las probabilidades.

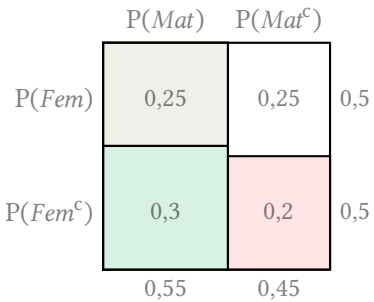


Figura 1.4: Cuadrado de área 1 dividido en áreas proporcionales a las probabilidades de estudiantes por género y carrera.

1.8 Conteo

Hasta ahora, hemos usado ejemplos de eventos sencillos, como sacar una o dos cartas de naipes o lanzar un dado. Si queremos progresar a eventos más complejos, necesitaremos saber contar cuántos resultados tiene nuestro espacio muestral y cuántos de ellos son favorables.

El párrafo anterior lleva un supuesto implícito: que cada resultado es igualmente probable[6]. Esa suposición no es cierta en todos los casos, pero es una buena aproximación. Además, podemos simular situaciones donde se cumple o donde no usando un modelo de cajas apropiado.

6: o, en palabras elegantes, que los resultados son *equiprobables*

Volviendo al tema, el principio básico del conteo es que si tenemos n formas de hacer una cosa y m formas de hacer otra, entonces tenemos $n \cdot m$ formas de hacer ambas cosas. Esto es el principio multiplicativo que vimos antes. En general, podemos extenderlo a un proceso que tenga varias etapas.

Definición 1.8.1 (Principio multiplicativo) *Si una primera etapa de un proceso puede ejecutarse de n_1 formas, una segunda etapa de n_2 formas para cada una de las formas anteriores, y así sucesivamente hasta una k-ésima etapa de n_k formas para cada una de las formas anteriores, entonces el número total de formas de ejecutar el proceso es $n_1 \cdot n_2 \cdots n_k$.*

El ejemplo clásico es contar las patentes posibles de los autos. En Chile, las patentes están compuestas en dos maneras:

- Dos letras y cuatro dígitos,
- Cuatro letras y dos dígitos.

Las letras no incluyen la Ñ, así que hay 26 letras posibles. Los dígitos son $0, 1, 2, \ldots, 9$, así que hay 10 dígitos posibles. Por lo tanto, en el primer caso tenemos

$$26^2 \cdot 10^4 = 6.760.000$$

y en el segundo caso tenemos

$$26^4 \cdot 10^2 = 45.697.600.$$

En total tenemos

$$6.760.000 + 45.697.600 = 52.457.600$$

patentes posibles.[7]

Notemos que usamos otro principio, el principio aditivo, para sumar los dos casos. En general, si tenemos n casos mutuamente excluyentes, entonces el número total de resultados es la suma de los resultados de cada caso.

7: En realidad son menos porque hay varias letras que no se usan, como la I y la O, para evitar confusiones con los números 1 y 0.

1.8.1 Permutaciones

Un caso especial es cuando ordenamos los elementos de un conjunto. Por ejemplo, si queremos ver de cuántas maneras podemos ordenar[8] los elementos de $\{a, b, c, d\}$ es fácil ver que para la primera posición tenemos 4 opciones, para la segunda 3, para la tercera 2 y para la última 1. Por lo tanto, el número total de ordenamientos es $4 \cdot 3 \cdot 2 \cdot 1 = 24 = 4!$.

8: sin repetición

Esta idea de ordenar los elementos de un conjunto se llama *permutación.*

Definición 1.8.2 (Permutación) *Una permutación de un conjunto S es un ordenamiento de todos o algunos de los elementos de S. El número de permutaciones de todos los elementos de un conjunto de n elementos es*

$$n! = n \cdot (n-1) \cdots 2 \cdot 1.$$

Sin embargo, como dice la definición, también podemos ordenar sólo algunos de los elementos de un conjunto. Continuando el ejemplo anterior, si tenemos el conjunto $\{a, b, c, d\}$ y queremos ordenar sólo 2 de sus elementos, entonces tenemos 4 opciones para el primer elemento y 3 para el segundo. Por lo tanto, el número de ordenamientos es $4 \cdot 3 = 12$.

En general, si vamos a ordenar k elementos de un conjunto de n elementos, entonces el número de ordenamientos es

$$\mathrm{P}_k^n = n \cdot (n-1) \cdots (n-k+1).$$

Una forma muy común de escribir esto es reconocer

que

$$n \cdot (n-1) \cdots (n-k+1) = \frac{n \cdot (n-1) \cdots (n-k+1) \cdot (n-k) \cdot (n-k-1) \cdots 2 \cdot 1}{(n-k) \cdot (n-k-1) \cdots 2 \cdot 1}$$
$$= \frac{n!}{(n-k)!}.$$

Un ejemplo clásico: Si tenemos un curso con 37 estudiantes y queremos elegir un presidente, un secretario y un tesorero, entonces tenemos 37 opciones para el presidente, 36 para el secretario y 35 para el tesorero. Por lo tanto, el número de maneras de elegir a los tres es

$$\mathrm{P}_3^{37} = \frac{37!}{(37-3)!} = \frac{37!}{34!} = 37 \cdot 36 \cdot 35 = 46.620.$$

1.8.2 Combinaciones

Ahora, una cosa es elegir miembros de un conjunto y otra cosa es elegirlos y ordenarlos. Si no nos importa el orden, entonces estamos hablando de *combinaciones*. Evidentemente, el número de combinaciones es menor que el número de permutaciones, ya que podemos entender una combinación como un conjunto de permutaciones donde el orden no importa.

La pregunta es ¿qué tan menor? Por ejemplo, si escogemos ordenadamente 2 elementos de $\{a, b, c, d\}$, tenemos como resultado

ab	ac	ad	bc	bd	cd
ba	ca	da	cb	db	dc

pero si no nos importa el orden, podemos colapsar cada columna en un solo elemento, obteniendo $\{ab, ac, ad, bc, bd, cd\}$. Por lo tanto, el número de combinaciones es 6 o, en otras palabras, 12/2.

Definición 1.8.3 (Combinación) *Una combinación de un conjunto S es un subconjunto de S de k elementos, sin importar el orden. El número de combinaciones de k elementos de un conjunto de n elementos es*

$$\mathrm{C}_k^n = \frac{n!}{k!(n-k)!}.$$

Notemos que

$$\mathrm{C}_k^n = \frac{1}{k!}\,\mathrm{P}_k^n.$$

Asimismo, gracias a esta definición, podemos darnos cuenta que

$$\mathrm{C}_k^n = \binom{n}{k},$$

es decir, el número de combinaciones de k elementos de un conjunto de n elementos es el coeficiente binomial $\binom{n}{k}$.

Ejemplo: si en vez de elegir un presidente, un secretario y un tesorero, sólo queremos elegir 3 estudiantes para formar una comisión, entonces el número de maneras de elegir a los 3 es

$$\mathrm{C}_3^{37} = \frac{37!}{3!\,(37-3)!} = \frac{37!}{3!\,34!} = \frac{37\cdot 36\cdot 35}{3\cdot 2\cdot 1} = 7770.$$

1.8.3 Algunos casos extra

Un caso especial de permutaciones es cuando debemos organizar los elementos alrededor de un círculo. En este caso, no son distinguibles dos permutaciones si podemos llegar de una a la otra mediante una rotación. Por ejemplo, si tenemos 4 elementos a, b, c, d, entonces las permutaciones (a, b, c, d) y (b, c, d, a) son indistinguibles (Figura ??).

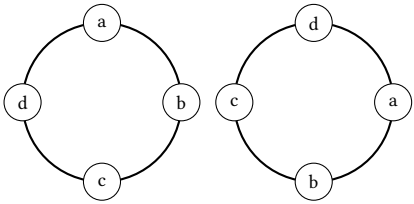


Figura 1.5: Dos permutaciones circulares indistinguibles.

Como podemos hacer n rotaciones, el número de permutaciones es $(n-1)!$.

Otro caso es cuando tenemos n elementos, pero algunos de ellos son iguales. Por ejemplo, si tenemos n letras, pero algunas son iguales, entonces el número de permutaciones es

$$\mathrm{P}^{n}_{k_1,k_2,\ldots,k_m} = \frac{n!}{k_1! \cdot k_2! \cdots k_m!},$$

donde k_i es el número de veces que se repite el elemento i. Esto ocurre porque al contar las permutaciones, cada una de las permutaciones de los elementos iguales se cuenta $k_i!$ veces, así que debemos dividir por ese número para no contar de más.

Ejemplo: contar las permutaciones de la palabra *casada.* Como la palabra tiene 6 letras, en principio tendríamos 6! permutaciones. Sin embargo, los siguientes 6 arreglos son indistinguibles:

$$\begin{array}{ll} ca_1sa_2da_3 & ca_1sa_3da_2 \\ ca_2sa_1da_3 & ca_2sa_3da_1 \\ ca_3sa_1da_2 & ca_3sa_2da_1 \end{array}$$

que son precisamente las permutaciones de los 3 elementos a que hay en la palabra. Por lo tanto, el número de permutaciones es

$$\frac{6!}{3!} = 120.$$

Probabilidades++ 2

2.1 Axiomas de probabilidad

En el capítulo anterior vimos que la probabilidad se define como una función que cumple ciertas condiciones. Definámosla bien de una vez por todas.

Definición 2.1.1 (Probabilidad) *Sea S un espacio muestral y E un evento cualquiera de éste. Se llamará* función de probabilidad *sobre el espacio muestral S a $\mathrm{P}(E)$ si satisface los siguientes axiomas:*

1. $\mathrm{P}(E) \geq 0$
2. $\mathrm{P}(S) = 1$
3. *Si para los eventos $E_1, E_2, \ldots, E_i \cap E_j = \emptyset$ para $i \neq j$, entonces* $\mathrm{P}\left(\bigcup_i E_i\right) = \sum_i \mathrm{P}(E_i)$.

De esta definición se deducen los teoremas que hemos estado usando en la sección anterior. Por ejemplo,

Teorema 2.1.1 $\mathrm{P}(\emptyset) = 0$.

Demostración. $S \cup \emptyset = S$ y $S \cap \emptyset = \emptyset$. Por el axioma 3,

$$\mathrm{P}(S \cup \emptyset) = \mathrm{P}(S) + \mathrm{P}(\emptyset),$$

pero por el axioma 2, $\mathrm{P}(S) = 1$. Por lo tanto,

$$\mathrm{P}(\emptyset) = 0.$$

□

Podemos demostrar los teoremas de probabilidad usando los axiomas de manera similar. Como dicen

los libros, queda como ejercicio al lector.

2.2 Teorema de Bayes

Nos han descrito a Esteban de la siguiente manera:

- Es organizado.
- Le gusta el orden.
- Es callado, pero afable.
- Es servicial.

La pregunta es si Esteban será un bibliotecario o un campesino (no hay más opciones). En una de las secciones, aproximadamente el 85 % pensó que Esteban sería un bibliotecario versus un 15 % que pensó que sería un campesino.

Todo eso está muy bien, pero hay una información que no hemos considerado y que, francamente, debiéramos haber tenido en cuenta: hay muchos más campesinos que bibliotecarios. Como ejemplo, podemos asumir que la razón entre bibliotecarios y campesinos es $1 : 20$ (en realidad debe ser algo como $1 : 100$).

Siendo así, podemos tomar una muestra[1] que siga esa proporción (Figura 2.1).

1: más adelante en el curso definiremos qué es eso

Supongamos que aproximadamente un 40 % de los bibliotecaros siguen la descripción de Esteban, pero sólo un 10 % de los campesinos la siguen. Si fuera así, de nuestros 10 bibliotecarios, 4 serían como Esteban y de los 200 campesinos, 20 serían como Esteban (Figura 2.2).

En este caso, la probabilidad de encontrar un bibliotecario dado que es como Esteban es

$$\mathrm{P}(B \mid E) = \frac{4}{4+20} = \frac{4}{24} = \frac{1}{6},$$



Figura 2.1: Muestra de bibliotecarios y campesinos.



Figura 2.2: Bibliotecarios y campesinos como Esteban.

mientras que la probabilidad de encontrar un campesino dado que es como Esteban es

$$\mathrm{P}(C \mid E) = \frac{20}{4+20} = \frac{20}{24} = \frac{5}{6}.$$

Es decir, es bastante más probable que Esteban sea un campesino, pese a que entre los campesinos personas con su descripción son más difíciles de encontrar.

Lo que nos muestra este ejemplo es que la llegada de nueva información (en este caso, la razón entre bibliotecarios y campesinos en la población general) nos permite actualizar nuestras creencias, expresadas como una probabilidad.

Podemos desempacar un poco nuestros cálculos. La probabilidad de encontrar un biliotecario entre la gente que es como Esteban era

$$\mathrm{P}(B \mid E) = \frac{4}{4+20}$$

pero esos números representan

$$= \frac{40\,\%\text{ de }10}{40\,\%\text{ de }10 + 10\,\%\text{ de }20}$$
$$= \frac{40\,\%\text{ de }\frac{1}{21}\text{ de }210}{40\,\%\text{ de }\frac{1}{21}\text{ de }210 + 10\,\%\text{ de }\frac{20}{21}\text{ de }210}$$

simplificando los 210

$$= \frac{40\,\%\text{ de }\frac{1}{21}}{40\,\%\text{ de }\frac{1}{21} + 10\,\%\text{ de }\frac{20}{21}}$$
$$= \frac{0{,}4 \cdot \frac{1}{21}}{0{,}4 \cdot \frac{1}{21} + 0{,}1 \cdot \frac{20}{21}}$$

y cada uno de esos números representa una probabilidad

$$= \frac{\mathrm{P}(E \mid B)\,\mathrm{P}(B)}{\mathrm{P}(E \mid B)\,\mathrm{P}(B) + \mathrm{P}(E \mid C)\,\mathrm{P}(C)}$$

en resumen

$$\mathrm{P}(B \mid E) = \frac{\mathrm{P}(E \mid B)\,\mathrm{P}(B)}{\mathrm{P}(E \mid B)\,\mathrm{P}(B) + \mathrm{P}(E \mid C)\,\mathrm{P}(C)}$$

El teorema de Bayes aparece como una derivación bastante inocua del principio multiplicativo.

$$\begin{aligned} \mathrm{P}(A \cap B) &= \mathrm{P}(A)\,\mathrm{P}(B \mid A) \\ \mathrm{P}(A \cap B) &= \mathrm{P}(B)\,\mathrm{P}(A \mid B) \end{aligned}$$

por lo tanto

$$\begin{aligned} \mathrm{P}(A)\,\mathrm{P}(B \mid A) &= \mathrm{P}(B)\,\mathrm{P}(A \mid B) \\ \mathrm{P}(B \mid A) &= \frac{\mathrm{P}(B)\,\mathrm{P}(A \mid B)}{\mathrm{P}(A)} \end{aligned}$$

Teorema 2.2.1 (Teorema de Bayes)

$$\mathrm{P}(B \mid A) = \frac{\mathrm{P}(B)\,\mathrm{P}(A \mid B)}{\mathrm{P}(A)}$$

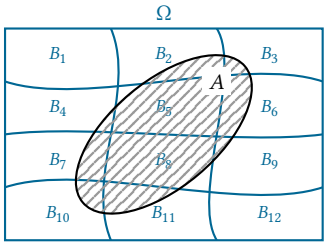
Sin embargo, como el mismo ejemplo de Esteban nos muestra, normalmente la probabilidad de A que encontramos en el denominador no se deja calcular tan directamente. En ese caso, dividimos el denominador en dos partes: los que son bibliotecarios y son como Esteban y los que son campesinos y son como Esteban. En otras palabras usamos una partición.

En un caso general, si tenemos una partición

$$B_1, B_2, \ldots, B_n$$

del espacio muestral Ω, podemos escribir la probabilidad de A como

$$\mathrm{P}(A) = \sum_{i=1}^{n} \mathrm{P}(A \cap B_i) = \sum_{i=1}^{n} \mathrm{P}(A \mid B_i)\,\mathrm{P}(B_i)$$



Esto es conocido como el teorema de la probabilidad total.

Teorema 2.2.2 (Teorema de la probabilidad total) *Si* $\{B_1, B_2, \ldots, B_n\}$ *es una partición del espacio muestral* Ω*, entonces*

$$\mathrm{P}(A) = \sum_{i=1}^{n} \mathrm{P}(A \cap B_i) = \sum_{i=1}^{n} \mathrm{P}\left(A \mid B_i\right) \mathrm{P}(B_i)$$

Como corolario, podemos escribir el teorema de Bayes como

Corolario 2.2.3 *Si* $\{B_i\}_{i=1}^{n}$ *es una partición del espacio muestral* Ω*, entonces*

$$\mathrm{P}\left(B_i \mid A\right) = \frac{\mathrm{P}\left(B_i\right) \mathrm{P}\left(A \mid B_i\right)}{\sum_{j=1}^{n} \mathrm{P}\left(A \mid B_j\right) \mathrm{P}\left(B_j\right)}$$

2.2.1 Enfermedades y exámenes

Un ejemplo importante del teorema de Bayes consiste en su aplicación a enfermedades y exámenes. Además de su importancia práctica, este tipo de ejemplos nos puede mostrar varios detalles interesantes sobre la probabilidad condicional.

Supongamos que hay una enfermedad que afecta a un porcentaje relativamente pequeño de la población, digamos un 1 % (eso es la *prevalencia* de la

enfermedad). Tenemos un examen para detectar la enfermedad, que el fabricante nos dice que tiene una eficacia "sobre el 90 %". ¿Cuál será la probabilidad de tener la enfermedad si el examen nos da positivo?

Para poder empezar a resolver este problema, debemos considerar que hay cuatro posibilidades

	E	E^c
+	E y +	E^c y +
−	E y −	E^c y −

Estas posibilidades tienen nombre

	E	E^c
+	Verdadero positivo	Falso positivo
−	Falso negativo	Verdadero negativo

Esta idea volverá a aparecer cuando estemos haciendo pruebas de hipótesis

Además, lo que el fabricante se refería como "tiene una eficacia sobre el 90 %" en realidad son dos números distintos

Sensibilidad La probabilidad que el examen dé positivo dado que el paciente tiene la enfermedad: $\mathrm{P}(+ \mid E)$.

Especificidad La probabilidad que el examen dé negativo dado que el paciente no tiene la enfermedad: $\mathrm{P}(- \mid E^c)$.

En nuestro caso, imaginemos que el examen tiene una sensibilidad de 90 % y una especificidad de 91 %.

Podemos calcular nuestra probabilidad haciendo un muestreo imaginario. De mil personas, con una

prevalencia del 1 %, debería haber aproximadamente 10 personas enfermas. De las 10 personas enfermas, como la sensibilidad es un 90 % debería haber 9 personas que den positivo al examen. De las 990 personas que no tienen la enfermedad, como el test tiene una especificidad del 91 %, debería haber $0{,}91 \cdot 990 = 900{,}9 \approx 901$ personas que den negativo. Esto quiere decir que, hay $990 - 901 = 89$ personas que no tienen la enfermedad y dan positivo al test.

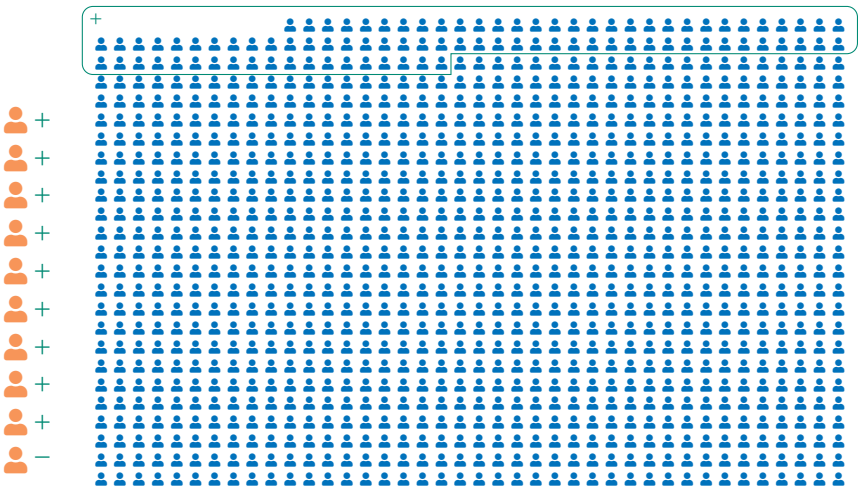


Figura 2.3: Muestra hipotética para el problema

En otras palabras, si calculamos la probabilidad $\mathrm{P}(E \mid +)$, necesitamos contar a los enfermos de entre quienes dieron positivo en el examen

una nueva aparición de la probabilidad total, si nos fijamos bien

$$\mathrm{P}(E \mid +) = \frac{9}{9 + 89}$$

Lo ideal en este tipo de cálculo rápido es sacar ideas para hacer el cálculo formal[2]. En este caso, $\mathrm{P}(E \mid +)$

2: que es lo que se va a evaluar

es

$$\begin{aligned}
\mathrm{P}(E \mid +) &= \frac{\mathrm{P}(E \cap +)}{\mathrm{P}(+)} \\
&= \frac{\mathrm{P}(E \cap +)}{\mathrm{P}(E \cap +) + \mathrm{P}(E^{\mathrm{c}} \cap +)} \\
&= \frac{\mathrm{P}(E)\,\mathrm{P}(+ \mid E)}{\mathrm{P}(E)\,\mathrm{P}(+ \mid E) + \mathrm{P}(E^{\mathrm{c}})\,\mathrm{P}(+ \mid E^{\mathrm{c}})} \\
&= \frac{0{,}01 \cdot 0{,}9}{0{,}01 \cdot 0{,}9 + 0{,}99 \cdot 0{,}09} \\
&= 0{,}0917431193 \approx 9\,\%
\end{aligned}$$

2.2.2 Odds

Una versión alternativa de reportar la probabilidad es dar los *odds* de un evento[3]. Esto se define como la razón entre la probabilidad de que un evento ocurra a la probabilidad de que el evento no ocurra. Por supuesto, es fácil convertir entre odds y probabilidades. Por ejemplo

3: francamente, no sé qué traducción podría ser clara *y* técnica.

$$1 : 4 \to \frac{1}{1+4} = \frac{1}{5}$$

y viceversa.

En el ejemplo de las enfermedades, como la probabilidad de estar enfermo es 1 %, entonces los odds de estar enfermo son $1 : 99$. Lo que queríamos era la probabilidad de estar enfermo dado que nos dio positivo el test, $\mathrm{P}(E \mid +)$. ¿Cómo se ve eso en términos de odds? Eso debería ser la razón entre la probabilidad de estar enfermo dado que el test nos dio positivo y la probabilidad de estar sano dado que nos dio positivo el test

$$\frac{\mathrm{P}(E \mid +)}{\mathrm{P}(E^{\mathrm{c}} \mid +)}.$$

Podemos reemplazar usando el teorema de Bayes

$$\frac{\mathrm{P}(E \mid +)}{\mathrm{P}(E^{\mathrm{c}} \mid +)} = \frac{\frac{\mathrm{P}(E)\,\mathrm{P}(+ \mid E)}{\mathrm{P}(+)}}{\frac{\mathrm{P}(E^{\mathrm{c}})\,\mathrm{P}(+ \mid D^{\mathrm{c}})}{\mathrm{P}(+)}}$$

La probabilidad de que el test dé positivo se cancela

$$= \frac{\mathrm{P}(E)\,\mathrm{P}(+ \mid E)}{\mathrm{P}(E^{\mathrm{c}})\,\mathrm{P}(+ \mid E^{\mathrm{c}})}$$

Podemos separar la expresión anterior en dos factores

$$\underbrace{\frac{\mathrm{P}(E \mid +)}{\mathrm{P}(E^{\mathrm{c}} \mid +)}}_{\substack{\text{odds de enfermo} \\ \text{dado examen positivo}}} = \underbrace{\frac{\mathrm{P}(E)}{\mathrm{P}(E^{\mathrm{c}})}}_{\substack{\text{odds de estar} \\ \text{enfermo}}} \cdot \underbrace{\frac{\mathrm{P}(+ \mid E)}{\mathrm{P}(+ \mid E^{\mathrm{c}})}}_{\substack{\text{factor de} \\ \text{verosimilitud}}}$$

En otras palabras, el teorema de Bayes tiene una versión mucho más sencilla cuando lo expresamos en términos de odds

odds a posteriori = odds a priori × factor de verosimilitud.

Este factor de verosimilitud es una especie de factor *de actualización* y es la fracción entre los verdaderos positivos y los falsos positivos. En nuestro caso, el factor de verosimilitud es

$$\frac{\mathrm{P}(+ \mid E)}{\mathrm{P}(+ \mid E^{\mathrm{c}})} = \frac{0{,}9}{0{,}09} = 10$$

lo que significa que cada nuevo test positivo, asumiendo independencia, mejora nuestros odds en 10 veces

$$\underbrace{1 : 99}_{\text{odds originales}} \xrightarrow{\text{test positivo}} 10 : 99 \xrightarrow[\text{independiente}]{\text{otro test positivo}} 100 : 99 \xrightarrow[\text{independiente}]{\text{otro test positivo}} 1000 : 99$$

lo que en probabilidades se ve como

$$1\,\% \to 9{,}2\,\% \to 50{,}25\,\% \to 90{,}99\,\%.$$

Variables aleatorias 3

3.1 Introducción

El lenguaje de eventos que hemos usado hasta ahora nos ha servido bien, pero al mismo tiempo es una limitante. En el pequeño juego de los productores de pasta de dientes, expresar todas las probabilidades involucradas en varios pasos ya se volvía tedioso. Es por eso que necesitamos algo que nos permita expresar ideas más complejas de manera más fácil.

Y, en realidad, la idea es sencilla. Antes poníamos nombres a los eventos como A y era algo como *sacar un cinco al lanzar el dado.* ¿Por qué no le pusimos simplemente algo como 5? ¿Por qué no enfocarnos en el resultado?

Esa es la idea detrás de una *variable aleatoria.* Una variable aleatoria es codificar el resultado de un experimento como un número. Muchas veces será directamente un número, como en el caso de lanzar un dado, pero también podemos codificar cosas como las monedas:

$$\{C, S\} \to \{0, 1\}$$
$$C \to 0$$
$$S \to 1$$

pero no cuesta mucho ver que esa misma codificación podría ser mucho más general

$$\text{fracaso} \to 0$$
$$\text{éxito} \to 1$$

y eso es parte de la importancia de las variables aleatorias: nos permiten abstraer la idea de experimento aleatorio.

Sin embargo, es importante reconocer qué significa lo de *aleatoria* en variable aleatoria. La aleatoridad *no* está en la variable aleatoria. Fijémonos en la definición anterior: es completamente uno a uno y determinista. Lo aleatorio en esto está en el experimento.

En términos más formales, una variable aleatoria es una función que va del espacio muestral a los reales. Utilizaremos letras mayúsculas para representarlas.

Un ejemplo. Supongamos que nuestro experimento aleatorio es sumar las pintas al lanzar dos dados. Nuestra variable aleatoria es, entonces, algo como lo siguiente

(1,6)	(2,6)	(3,6)	(4,6)	(5,6)	(6,6)	$X = 12$
(1,5)	(2,5)	(3,5)	(4,5)	(5,5)	(6,5)	$X = 11$
(1,4)	(2,4)	(3,4)	(4,4)	(5,4)	(6,4)	$X = 10$
(1,3)	(2,3)	(3,3)	(4,3)	(5,3)	(6,3)	$X = 9$
(1,2)	(2,2)	(3,2)	(4,2)	(5,2)	(6,2)	$X = 8$
(1,1)	(2,1)	(3,1)	(4,1)	(5,1)	(6,1)	
$X = 2$	$X = 3$	$X = 4$	$X = 5$	$X = 6$	$X = 7$	

Notemos que al considerar nuestra variable aleatoria (la suma de los dos dados) hemos hecho una partición del espacio muestral, en este caso marcada con colores. Además, es muy natural llamar a cada

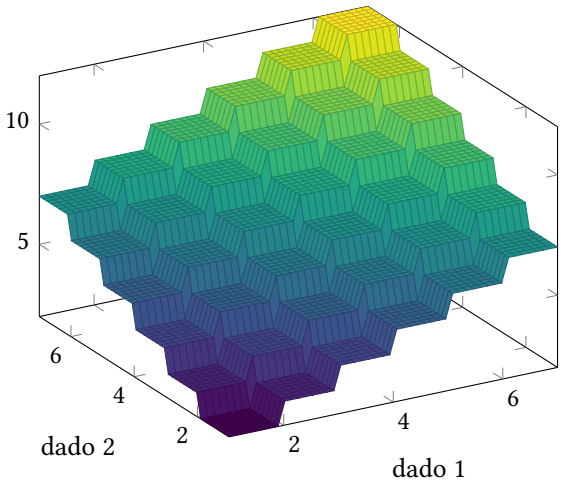


Figura 3.1: X: suma de dos dados

conjunto de la partición por el resultado que marca. Así, por ejemplo, $X = 4$ es el evento compuesto por los resultados $(1, 3), (2, 2), (3, 1)$.

Si reconocemos que nuestro espacio muestral es $\{1, 2, 3, 4, 5, 6\} \times \{1, 2, 3, 4, 5, 6\}$ entonces nuestra variable aleatoria se puede escribir como

$$\begin{aligned} X : \{1, 2, 3, 4, 5, 6\} \times \{1, 2, 3, 4, 5, 6\} &\to \{2, \dots, 11, 12\} \\ (\omega_1, \omega_2) &\to \omega_1 + \omega_2 \end{aligned}$$

Ahora bien, como nuestra variable aleatoria divide a nuestro espacio muestral en una partición de eventos, cada uno de ellos tiene una probabilidad asociada. Sin embargo, aquí debemos empezar a hacer una distinción entre dos tipos de variables, las discretas y las continuas.

3.2 Variables aleatorias discretas

Una variable aleatoria discreta es una variable aleatoria cuyo recorrido es un conjunto finito o infinito numerable (típicamente los enteros o un subconjunto de ellos). Hasta ahora, nuestros eventos se pueden identificar con variables aleatorias discretas.

Cuando tenemos una VA[1] discreta X, podemos definir una función $f(x)$ como

$$f(x) = \mathrm{P}(X = x),$$

es decir, la probabilidad de que la VA X tome el valor x. Esta función se conoce como *función de masa de probabilidad* o como función de cuantía.

1: abreviaremos así variable aleatoria

Un ejemplo. En una librería, la mayoría de la gente que entra no compra libros, supongamos un 70 %, la gente que compra un libro es alrededor del 25 % y los que compran 2 libros son el resto (aproximadamente nadie compra 3 o más libros). Tenemos entonces que

$$X = \text{número de libros comprados}$$

es una variable aleatoria y su función de masa de probabilidad viene dada por

i	0	1	2
$P(X = i)$	0,7	0,25	0,05

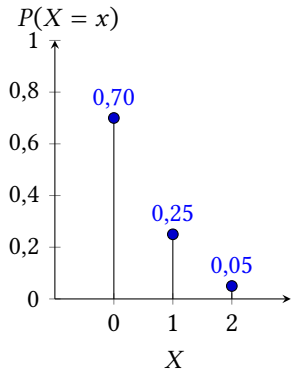


Figura 3.2: Función de masa de probabilidad de X.

La función de masa de probabilidad debe cumplir dos propiedades

1. $f(x) \geq 0$.
2. $\sum_x f(x) = 1$.

También resulta útil calcular la función de probabilidad acumulada, $F(x)$. Esta función viene definida

por

$$F(x) = \mathrm{P}(X \leq x) = \sum_{t \leq x} f(t).$$

3.3 Variables aleatorias continuas

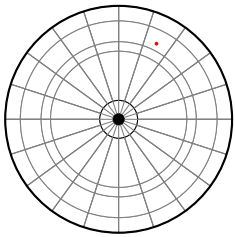


Figura 3.3: La probabilidad de que el dardo caiga *exactamente* en el punto rojo es 0, y sin embargo es posible

Las VA también pueden ser continuas. Una VA es continua si su recorrido es continuo. La gran particularidad de una VA continua es que, si X es una VA continua,

$$\mathrm{P}(X = x_0) = 0$$

para cualquier valor x_0 de la variable.

Esto nos obliga a buscar una manera alternativa de definir la probabilidad. Lo que podemos hacer es darnos cuenta que nos va a interesar obtener la probabilidad en algún tipo de *sección* (un intervalo, un área, una cierta duración, etc). En otras palabras, usaremos una *densidad* de probabilidad.

Definición 3.3.1 *La función de densidad de probabilidad de una VA continua es la función $f(x)$ que cumple con*

$$\mathrm{P}(a \leq x \leq b) = \int_a^b f(t)\,dt$$

Una función de densidad de probabilidad debe cumplir con dos condiciones

1. $f(x) \geq 0, \forall x \in \mathbb{R}$.
2. $\int_{-\infty}^{\infty} f(x)\,dx = 1$.

Al igual que en caso discreto, podemos definir la función de probabilidad acumulada como

$$F(x) = P(X \leq x) = \int_{-\infty}^{x} f(t)\,dt$$

3.4 Esperanza y varianza

Aunque una variable aleatoria no es realmente aleatoria, tampoco sabemos exactamente cuál va a ser su resultado. Lo que sí podemos saber (al menos en teoría) es la distribución de probabilidad de la VA. En base a esa información, podemos aspirar a obtener un resultado *esperado* al ocurrir el experimento o proceso que da origen a la VA.

Ese resultado esperado nos da de alguna manera un *centro* desde el que comenzar a hablar. Es como si entrecerráramos los ojos y viéramos la parte "más importante" de la distribución. Es la señal que nos manda la variable aleatoria junto con su distribución de probabilidad.

Pero el centro no nos cuenta toda la historia. También es importante hablar del *despliegue* de los datos, ver de qué manera se "desparraman" las probabilidades. Pero para esto necesitamos un punto de referencia, el que nos va a proveer el centro.

3.4.1 Definición de la esperanza y sus propiedades

Vamos a definir la *esperanza* de una variable aleatoria como el promedio ponderado de los valores posibles de la variable aleatoria, pero ponderados por la probabilidad de cada uno. En el caso de una VA discreta,

$$\begin{aligned} \mathrm{E}(X) &= \sum_i x_i \, \mathrm{P}(X = x_i) \\ &= \sum_{\omega \in \Omega} X(\omega) \, \mathrm{P}(\omega) \end{aligned}$$

donde x_i se toma a través de todos los valores de la VA. En el caso de una VA continua,

$$\mathrm{E}(X) = \int_{-\infty}^{\infty} x f(x)\, dx$$

donde $f(x)$ es la densidad de probabilidad de la variable aleatoria.

La esperanza es lineal, es decir si a es una constante y X e Y son dos VA,

$$\mathrm{E}(aX + Y) = a\,\mathrm{E}(X) + \mathrm{E}(Y).$$

La demostración es análoga en los casos discreto y continuo, así que haremos la demostración del caso discreto.

$$\begin{aligned}
\mathrm{E}(aX + Y) &= \sum_{\omega\in\Omega} (aX + Y)(\omega)\,\mathrm{P}(\omega) \\
&= \sum_{\omega\in\Omega} (aX(\omega) + Y(\omega))\,\mathrm{P}(\omega) \\
&= \sum_{\omega\in\Omega} aX(\omega)\,\mathrm{P}(\omega) + \sum_{\omega\in\Omega} Y(\omega)\,\mathrm{P}(\omega) \\
&= a\sum_{\omega\in\Omega} X(\omega)\,\mathrm{P}(\omega) + \sum_{\omega\in\Omega} Y(\omega)\,\mathrm{P}(\omega) \\
&= a\,\mathrm{E}(X) + \mathrm{E}(Y)
\end{aligned}$$

Otra propiedad de la esperanza es que podemos aplicar funciones a nuesta VA y calcular la esperanza de esta composición

$$\mathrm{E}(g(X)) = \sum_i g(x_i)\,\mathrm{P}(X = x_i).$$

Normalmente, simbolizaremos la esperanza de una variable aleatoria por μ. Si queremos ser específicos, por ejemplo simbolizar que la esperanza se refiere a la VA Z y no a la VA X, podemos poner un subíndice como μ_Z.

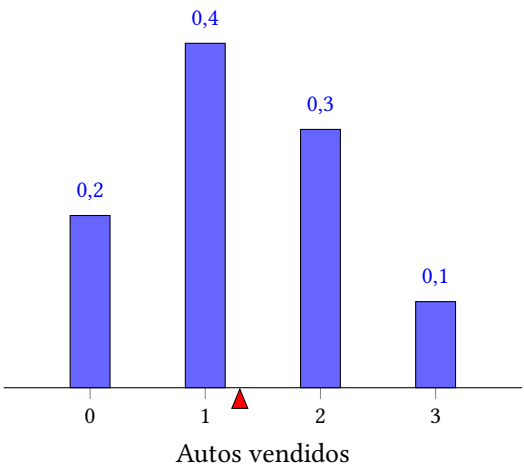
La propiedad más importante de la esperanza, sin embargo, es su significado. La esperanza actúa como el *centro de masa* de la distribución de probabilidad. ¿Qué significa esto? Imaginemos que tenemos una VA que representa la cantidad de autos vendidos por día en una distribuidora con la siguiente distribución de probabilidad

x	0	1	2	3
$P(X = x)$	0,2	0,4	0,3	0,1

La esperanza de esta variable aleatoria nos diría, en promedio, cuántos autos se venden por día. En este caso, podemos calcular la esperanza como

$$\mathrm{E}(X) = \sum_{i=0}^{3} x_i P(X = x_i) = 0{\cdot}0{,}2 + 1{\cdot}0{,}4 + 2{\cdot}0{,}3 + 3{\cdot}0{,}1 = 1{,}3.$$

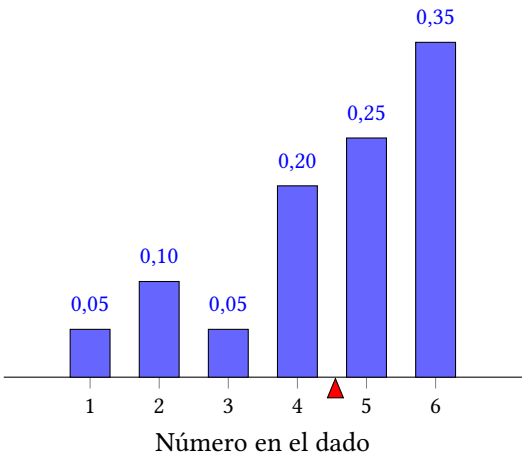
Si graficamos la función de masa de probabilidad junto con la esperanza, tenemos lo siguiente



Si ponemos el punto de apoyo de un balancín con esas masa en la esperanza, el balancín estará equilibrado. ¿Qué pasaría si tuviéramos una distribución más "cargada" para un lado?

x	1	2	3	4	5	6
$P(X = x)$	0,05	0,1	0,05	0,2	0,25	0,35

Grafiquemos esta distribución [2] de probabilidad

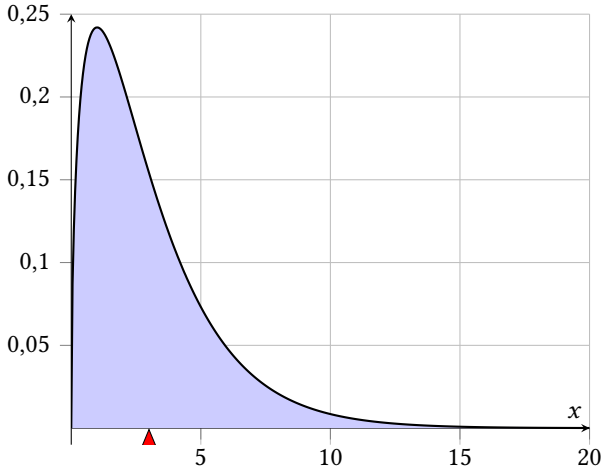


La esperanza está más cerca de los valores con mayor probabilidad. Estos "pesan" más, pero los valores que pesan menos los equilibran (piense en el torque).

En el caso de una VA continua ocurre básicamente lo mismo. Si graficamos una función de densidad de probabilidad podemos ver que la esperanza "equilibra" la lámina de color que está puesta encima del eje. En este caso, aunque el gráfico termina en $x = 20$ la distribución está definida para $x \in [0, \infty[$.

2: La esperanza de esta distribución es

$$1 \cdot 0{,}05 + 2 \cdot 0{,}1 + 3 \cdot 0{,}05 + \\ +4 \cdot 0{,}2 + 5 \cdot 0{,}25 + 6 \cdot 0{,}35 = 4{,}55$$



3.4.2 Definición de la varianza y sus propiedades

La varianza de una VA X se define como

$$\operatorname{Var}(X) = \mathrm{E}\left((X-\mu)^2\right)$$

donde $\mu = \mathrm{E}(X)$. Se simboliza como $\operatorname{Var}(X)$ o bien σ_X^2 (el subíndice se puede omitir si es claro a qué VA nos referimos).

Hay que considerar algo: ni la esperanza es la única definición posible de centro de una distribución ni la varianza la única definición de dispersión. Sin embargo, son las más útiles, al menos para partir.

Notemos algunas cosas. Primero, la varianza depende del valor de la esperanza. De hecho, la varianza *es* un tipo de esperanza. El término $(X-\mu)^2$ es una especie de distancia para cada valor de X a la esperanza y al tomar la esperanza de este término, estamos tomando la distancia esperada a la esperanza o, en otras palabras la *distancia promedio* al centro de la distribución.

Si calculamos la varianza del ejemplo de los autos vendidos que vimos en la esperanza,

x	0	1	2	3
$P(X = x)$	0,2	0,4	0,3	0,1

cuya esperanza era 1,3 entonces podríamos calcular la varianza como

$$\begin{aligned}
\operatorname{Var}(X) &= \mathrm{E}\left((X - 1{,}3)^2\right) \\
&= \sum_{i=0}^{3} (x_i - 1{,}3)^2 \, \mathrm{P}(X = x_i) \\
&= (0 - 1{,}3)^2 \cdot 0{,}2 + (1 - 1{,}3)^2 \cdot 0{,}4 + (2 - 1{,}3)^2 \cdot 0{,}3 + (3 - 1{,}3)^2 \cdot 0{,}1 \\
&= 1{,}69 \cdot 0{,}2 + 0{,}09 \cdot 0{,}4 + 0{,}49 \cdot 0{,}3 + 2{,}89 \cdot 0{,}1 \\
&= 0{,}338 + 0{,}036 + 0{,}147 + 0{,}289 \\
&= 0{,}81
\end{aligned}$$

Claramente es bastante largo. Sin embargo, hay una forma más sencilla de calcular la varianza. Notemos que

$$\begin{aligned}
\operatorname{Var}(X) &= \mathrm{E}\left((X - \mu)^2\right) \\
&= \mathrm{E}\left(X^2 - 2X\mu + \mu^2\right) \\
&= \mathrm{E}\left(X^2\right) - 2\mu\,\mathrm{E}(X) + \mu^2 \\
&= \mathrm{E}\left(X^2\right) - \mu^2
\end{aligned}$$

donde $\mu = \mathrm{E}(X)$. En otras palabras, la varianza es también la diferencia entre la esperanza del cuadrado de la variable aleatoria y el cuadrado de la esperanza de la variable aleatoria.

En el ejemplo,

$$0^2 \cdot 0{,}2 + 1^2 \cdot 0{,}4 + 2^2 \cdot 0{,}3 + \\ + 3^2 \cdot 0{,}1 - 1{,}3^2 = 0{,}81$$

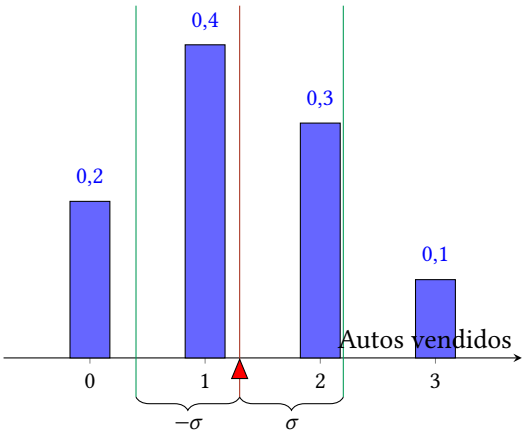
Un problema que tiene la varianza es que la unidad de medida es el cuadrado de la unidad de medida de la variable aleatoria. En nuestro ejemplo, la medida de la variable aleatoria es *autos vendidos*, pero la unidad de medida de la varianza es *autos vendidos al cuadrado*. Para evitar este problema, normalmente trabajamos con la desviación estándar, que es simplemente la raíz cuadrada de la varianza. En nuestro ejemplo, la desviación estándar sería $\sqrt{0{,}81} = 0{,}9$ autos vendidos.

La desviación estándar de una VA X se define como $\sigma_X = \sqrt{\text{Var}(X)}$.

La gran ventaja de la desviación estándar es que está en la misma unidad de medida que la variable aleatoria. Esto permite interpretarla y graficarla. En el ejemplo,

$$\sigma_X = \sqrt{0{,}81} = 0{,}9$$

autos vendidos. Podemos graficar la distribución de probabilidad junto con la esperanza y la desviación estándar.



¿Cómo interpretamos esto? Tenemos que interpretarlo en conjunto. La esperanza es 1,3 y la desviación estándar es 0,9. Esto quiere decir que esperamos vender 1,3 autos por día, pero que la mayoría de los días vamos a vender entre 0,4 y 2,2 autos (es decir, entre $\mu - \sigma$ y $\mu + \sigma$).

Desigualdad de Chebyshev

Una forma muy general para entender la desviación estándar es a través de la desigualdad de Chebyshev. Si tenemos una VA con varianza finita σ^2 (y por lo tanto esperanza finita), la probabilidad de que la variable aleatoria se aleje de su esperanza en más de

k veces la desviación estándar es al menos $1 - 1/k^2$. En otras palabras,

$$\mathrm{P}(\mu - k\sigma < X < \mu + k\sigma) \geq 1 - \frac{1}{k^2}.$$

Esto es *muy general*. Es tan general que, de hecho, cuando $k = 1$ no nos dice nada

$$\mathrm{P}(\mu - \sigma < X < \mu + \sigma) \geq 1 - \frac{1}{1^2} = 0$$

lo que ya... sabíamos. Cuando $k = 2$, la desigualdad nos dice que al menos el 75% de los valores están dentro de dos desviaciones estándar de la media y eso ya es más útil. Sin embargo, cuando conozcamos distribuciones particulares, generalmente podremos decir cosas más precisas.

3.5 ¿Qué significa sumar variables aleatorias? (opcional)

Partimos este capítulo con la variable aleatoria que nace al sumar los puntos de tirar los dados

$$\begin{aligned} X \ &: \{1,2,3,4,5,6\} \times \{1,2,3,4,5,6\} \to \{2,\dots,11,12\} \\ &(\omega_1, \omega_2) \to \omega_1 + \omega_2 \end{aligned}$$

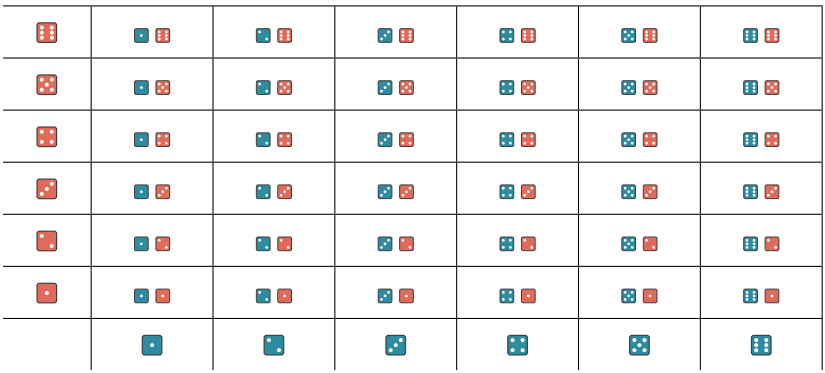
y en algún momento se comentó[3] que podemos entender esta VA como la suma de dos variables aleatorias

3: en clase

$$X = X_1 + X_2$$

donde X_i es el resultado al lanzar el dado i. Sin embargo, cada una de esas variables aleatorias tiene un dominio distinto del de X: el dominio de X_1 es $\{1,2,3,4,5,6\}$. ¿Cómo entonces la suma puede darnos un dominio como $\{1,2,3,4,5,6\} \times \{1,2,3,4,5,6\}$?

Primero, al lanzar los dos dados efectivamente nuestro espacio muestral es $\{1, 2, 3, 4, 5, 6\} \times \{1, 2, 3, 4, 5, 6\}$.

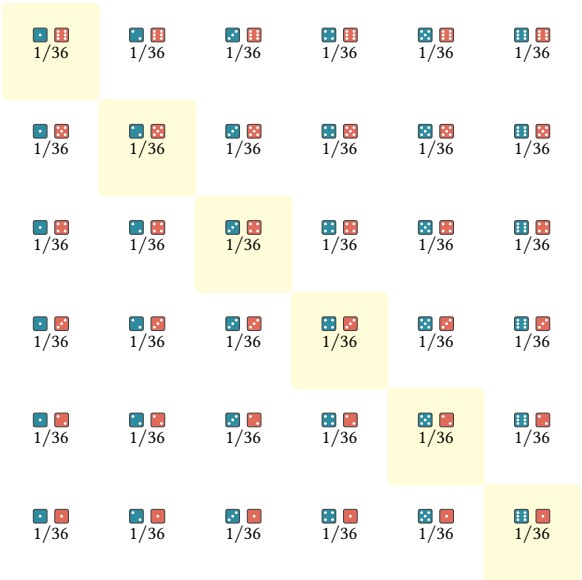


Si los dados son justos y los lanzamientos son independientes, la probabilidad de obtener un resultado cualquiera es $1/36$. Esto podemos obtenerlo, por ejemplo, como

$$\mathrm{P}(\square\square) = \mathrm{P}(\square) \cdot \mathrm{P}(\square) = \frac{1}{6} \cdot \frac{1}{6}.$$

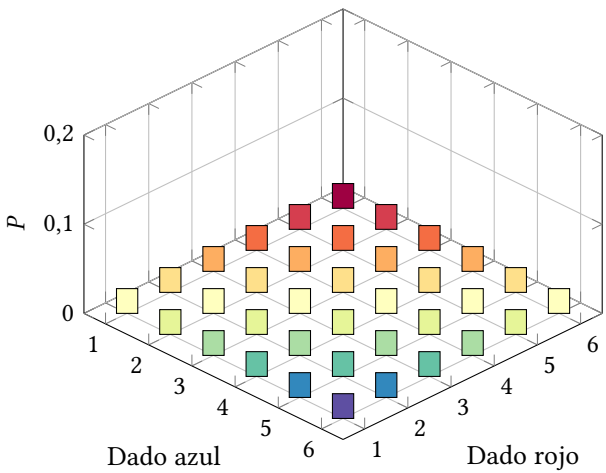
Ahora bien, nuestra variable aleatoria era el resultado de esta operación, y eso tiene distintas probabilidades. En particular, la probabilidad de obtener un resultado va a ser sumar las probabilidades de todas las posibles configuraciones que dan lugar a ese resultado.

La figura muestra la probabilidad de obtener una suma igual a 7

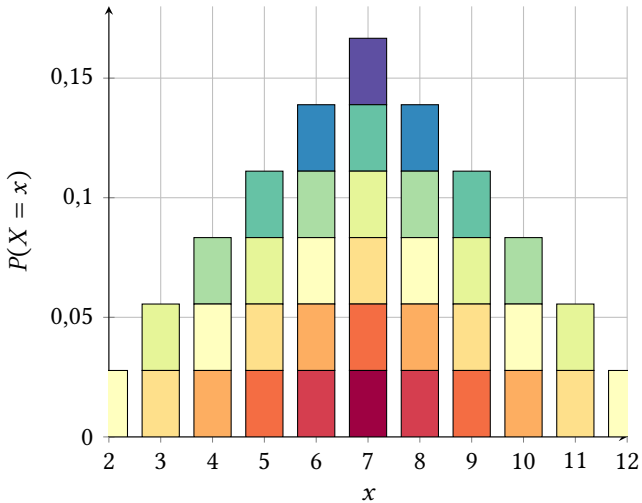


Con eso obtenemos $P(X = 7) = 6/36 = 1/6$.

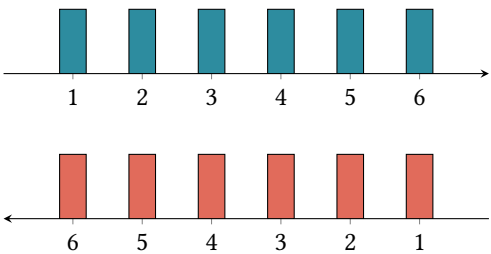
¿Cómo podríamos obtener esa probabilidad a partir de las probabilidades de cada dado?



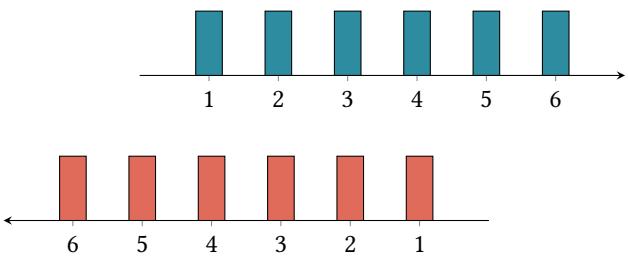
Podemos sumar las probabilidades de cada par de dados para un resultado fijo



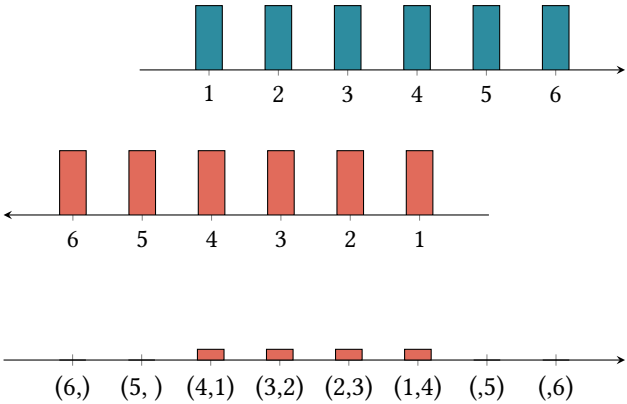
Ahora bien, podemos hacerlo de otra forma que explica mejor el dominio. Imaginemos que tenemos las dos distribuciones, una para cada dado, pero *damos vuelta* una de ellas, digamos la del dado rojo



y ahora corremos los ejes de manera de obtener siempre un valor fijo, por ejemplo $x = 5$.



y multiplicamos la columna de arriba con la de abajo



y ahora sumamos: $4 \cdot \frac{1}{36} = \frac{4}{36}$.

Podemos simbolizar esto que acabamos de hacer como

$$\sum_{i=1}^{6} \mathrm{P}(X = i) \cdot \mathrm{P}(Y = 5 - i) = 4 \cdot \frac{1}{36} = \frac{4}{36}$$

y si variamos el valor fijo 5 por cualquier otro valor x, obtenemos la probabilidad de obtener ese valor x al sumar las dos variables aleatorias X e Y

$$\mathrm{P}(X + Y = x) = \sum_{i=1}^{6} \mathrm{P}(X = i) \cdot \mathrm{P}(Y = x - i)$$

Esta operación se llama *convolución* y es una operación muy importante en probabilidad. En particular, si X e Y son independientes, la probabilidad de la suma es la convolución de las probabilidades individuales.

La convolución de dos funciones es una operación que no sólo se usa en probabilidades, si no que también en otros campos, como procesamiento de imágenes y de señales, procesamiendo digital, etc. Por

ejemplo, un filtro como el de desenfoque de imágenes es una convolución.

El zoológico de las variables aleatorias, parte 1

4

En el mundo[1] hay una infinidad y variedad de hechos que podrían estudiarse como variables aleatorias. En principio, deberíamos estudiar cada uno de ellos de manera individual, pero no cuesta mucho ver que eso sería demasiado difícil. Además, podemos abstraer detalles para quedarnos con los hechos que marcan más presencia.

1: realidad, naturaleza, universo, cosmos o como quiera llamarlo según su tendencia filosófica

De esta manera podemos llegar a varios *modelos de probabilidad* para estudiar diversas variables aleatorias. En este capítulo estudiaremos varios modelos discretos, bajo qué condiciones se pueden aplicar y qué tipo de VA quieren modelar. En el siguiente capítulo continuaremos nuestro paseo pero por modelos continuos. Si bien estudiaremos varias distribuciones, hay varias más que quedarán fuera del alcance de este curso. Para los y las interesados, eventualmente habrá un apéndice con alguna descripción de estas distribuciones.

4.1 Distribución de Bernoulli

Probablemente el modelo de probabilidad más sencillo, la distribución de Bernoulli (o dicotómica) es una con la que, para ser sinceros, nos encontramos desde la primera clase.

Si tenemos un experimento aleatorio, podemos entender su resultado desde el punto de vista de *éxito* o fracaso. El ejemplo clásico es la moneda. Queremos que salga cara y, si sale cara, tenemos un éxito. Si sale sello, tenemos un fracaso.

Pero fenómenos más complejos se pueden reducir a esta perspectiva de éxito-fracaso. Me encantó el ejemplo que dio un estudiante: quiero que mi equipo

gane el partido. Si no gana (pierda o empate), eso es un fracaso. Imagínense estudiar eso desde el punto de vista de todos los resultados posibles (0-0, 1-0, 0-1, 1-1, 2-0,...). Una locura.

Incluso, este lenguaje de éxito-fracaso puede ser todo lo contrario en la realidad. Puedo definir mi éxito como encontrar un resultado positivo en un examen, lo que seguramente para el paciente sería algo negativo, porque sugeriría[2] que tiene la enfermedad.

2: después del capítulo de Bayes, ya no podemos decir "confirmaría"

En resumen, tenemos algún tipo de evento aleatorio. Ese evento tiene un conjunto de resultados. Definiremos algunos como éxito y el resto como fracaso. De esta manera, definiremos la variable aleatoria

$$X = \begin{cases} 1 & \text{éxito} \\ 0 & \text{fracaso.} \end{cases}$$

Además, la probabilidad de esta variable aleatoria será

$$\mathrm{P}(X = x) = \begin{cases} p & x = 1 \\ 1 - p = q & x = 0. \end{cases}$$

Es muy usual esta notación de $q = 1 - p$ para la probabilidad del fracaso. En lo que queda de los apuntes intentaré usarla.

La distribución de Bernoulli en sí misma no es muy interesante, pero la importancia que tiene es que varias distribuciones que sí son interesantes están relacionadas con ella. Pero antes de entrar a eso, cerremos nuestro estudio de esta distribución y veamos su esperanza y varianza.

La esperanza es muy fácil de calcular

$$\mathrm{E}(X) = \sum_{x=0}^{1} x\mathrm{P}(X = x) = 0 \cdot q + 1 \cdot p = p.$$

Es decir, la esperanza de X es p. La varianza es

$$\begin{aligned}\sigma^2 &= \mathrm{E}\left(X^2\right) - \mathrm{E}\left(X\right)^2 \\ &= \sum_{x=0}^{1} x^2 \,\mathrm{P}(X = x) - p^2 \\ &= 0^2 \cdot q + 1^2 \cdot p - p^2 \\ &= p - p^2 \\ &= p(1-p) = pq\end{aligned}$$

Estos resultados nos servirán más adelante.

4.2 Variables aleatorias discretas y su relación con VAs Bernoulli

Una VA Bernoulli representa el éxito o fracaso en *una* repetición de un experimento aleatorio. Pero si repetimos el mismo experimento varias veces bajo las siguientes condiciones

1. cada repetición es independiente y
2. la probabilidad de éxito se mantiene constante

tenemos tres tipos de VAs que aparecen naturalmente.

Una posibilidad es preguntarnos por la probabilidad de tener k éxitos si repetimos el experimento n veces, donde n es un número fijo y k va entre 0 y n. Esta pregunta da origen a la distribución de probabilidad *binomial.*

Otra posibilidad es preguntarnos cuánto nos demoraremos en tener nuestro primer éxito. Esta pregunta da origen a la distribución de probabilidad *geométrica.*

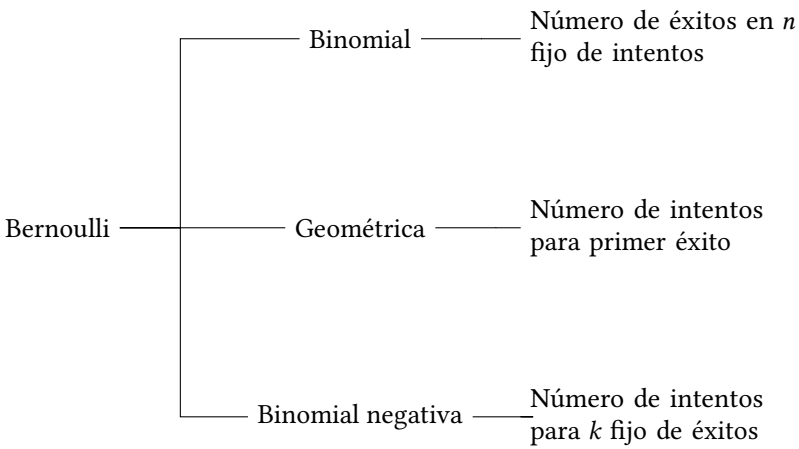


Figura 4.1: Relación entre las variables aleatorias Bernoulli y algunas variables aleatorias discretas.

Una tercera posibilidad es preguntarnos cuánto nos demoraremos en obtener un cierto número (fijo) de éxitos. Esta pregunta da origen a la distribución *binomial negativa.*

Estas relaciones aparecen resumidas en la Figura 4.1.

Existe otra relación. ¿Qué pasa si relajamos la necesidad de independencia? Podemos imaginar que tenemos el experimento aleatorio de sacar pelotas de una caja. Con reposición significa que lo hacemos con independencia, porque las probabilidades vuelven a ser las mismas. Pero si lo hacemos sin reposición, las probabilidades van cambiando. En este caso, la distribución de probabilidad que surge al preguntarnos cuál es la probabilidad de tener k éxitos en n intentos es la distribución *hipergeométrica.*

Una última relación que podemos establecer es cuando tenemos una cantidad promedio fija de eventos independientes que ocurren en una unidad de tiempo (o espacio, área, volumen, etc.). Por ejemplo, si

siempre me llegan en promedio 10 correos de spam por hora, podría calcular la probabilidad de que me lleguen 40 en un día. O, si revuelvo de manera suficientemente buena mi masa, la probabilidad de que la galleta que me voy a comer tenga 5 chips de chocolate si en promedio tienen 3. Eventos de este tipo se modelan con una distribución de Poisson.

Hay una relación entre la distribución binomial y la de Poisson. Si hacemos muchos intentos ($n \to \infty$) y la probabilidad de éxito de cada uno es pequeña ($p \to 0$) pero de manera que $np = \lambda$ sea constante, entonces la distribución de Poisson aparece como un límite de la distribución binomial.

Con eso, entremos más en detalle en cada una de ellas.

4.3 Distribución binomial

Como se dijo en la sección anterior, la distribución binomial modela la probabilidad de obtener k éxitos en n repeticiones independientes de un experimento con probabilidad de éxito p. En este caso, n es un número fijo que se asume sabido de antemano. p también es un número sabido de antemano. Decimos entonces que n y p son *parámetros*[3] de nuestra distribución.

3: la mejor definición de parámetro se la escuché a un físico: una constante que varía

Pensemos qué significa esto. Si tenemos n intentos y queremos obtener k éxitos, tendremos $n-k$ fracasos. La probabilidad que esto ocurra, sabiendo que cada repetición es independiente es, por lo tanto,

$$p^k q^{n-k}.$$

Sin embargo, ¿de cuántas maneras podemos tener esa cantidad de éxitos y fracasos? Recordando lo que aprendimos en la sección 1.8 (Conteo), esto es

equivalente a obtener k elementos de un conjunto con n elementos sin que nos importe el orden

$$\binom{n}{k}.$$

Con esto, entonces, si X es una variable aleatoria con distribución de probabilidad binomial, la probabilidad de obtener k éxitos en n lanzamientos viene dada por

$$\mathrm{P}(X = k) = \binom{n}{k} p^k q^{n-k}.$$

Además, simbolizaremos la idea de que la distribución de probabilidad de X es binomial con parámetros n, k como

el símbolo $\sim$ significa que la variable aleatoria se distribuye como dice la función de la derecha

$$X \sim \mathrm{Bin}(n, p).$$

Exploremos algunos gráficos para entender cómo se ve esta distribución. En la Figura 4.2 vemos la distribución binomial para $n = 20$ y varios valores de p. Vemos que, para p pequeño, la distribución está "cargada" a la izquierda. Para p grande, está "cargada" a la derecha. Y para $p = 0.5$, es simétrica.

Por otra parte, en la Figura 4.3 vemos la distribución binomial para $p = 0.3$ y varios valores de n. La distribución, al aumentar n se va "expandiendo".

Para calcular la esperanza y varianza de una binomial, basta pensar que si $X \sim \mathrm{Bin}(n, k)$, entonces

$$X = X_1 + X_2 + \cdots + X_n,$$

con cada X_i una variable aleatoria con distribución de Bernoulli con probabilidad p.

Por lo tanto,

$$\mathrm{E}(X) = \mathrm{E}\left(\sum_{i=1}^{n} X_i\right) = \sum_{i=1}^{n} \mathrm{E}(X_i) = \sum_{i=1}^{n} p = np$$

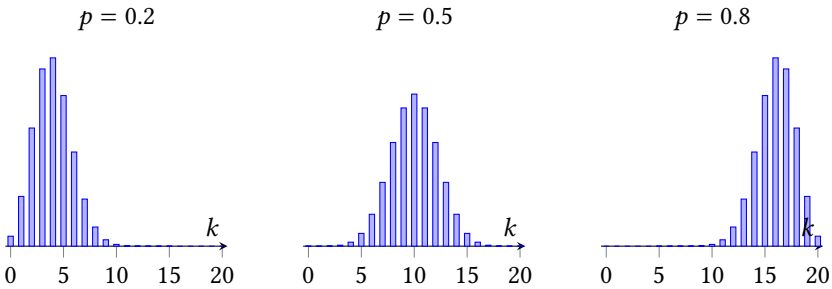


Figura 4.2: Distribución binomial con $n = 20$ y distintos p.

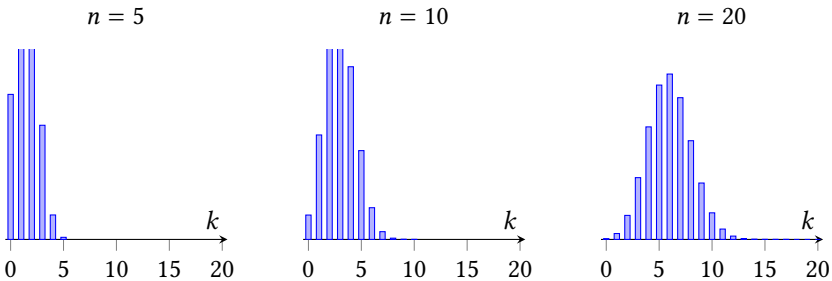


Figura 4.3: Distribución binomial con $p = 0.3$ y distintos n.

La varianza sigue un desarrollo parecido. Como cada repetición del experimento es independiente de las otras, entonces

$$\mathrm{Var}\,(X) = \mathrm{Var}\left(\sum_{i=1}^{n} X_i\right) = \sum_{i=1}^{n} \mathrm{Var}\,(X_i) = \sum_{i=1}^{n} pq = npq$$

Hagamos un ejemplo. Se estima que un 30% del total de bicicletas nuevas en una tienda presentan algún defecto de fábrica. Para obtener más información sobre la magnitud del problema, se determina que debe realizarse algún tipo de inspección. Como es muy costoso revisar todas las bicicletas disponibles, se eligen 10 al azar para someterlas a revisión.

1. Si se utiliza la distribución binomial, ¿cuál

es la probabilidad de que exactamente 3 bicicletas tengan defectos, considerando que la estimación es correcta?
2. ¿Cuál es la probabilidad de que más de 3 bicicletas tengan defectos?

En este caso, nuestro n es 10, la probabilidad de éxito (que es que una bicicleta esté mala) es 0,3. Por lo tanto,

1. Queremos encontrar $P(X = 3)$.

$$\begin{aligned} P(X = 3) &= \binom{10}{3} 0{,}3^3 \cdot 0{,}7^7 \\ &= 0{,}266828 \end{aligned}$$

2. Lamentablemente, la función de probabilidad acumulada de una binomial no tiene una forma cerrada. Podemos sumar, sin embargo.

$$\begin{aligned} P(X > 3) &= 1 - P(X \leq 3) \\ &= 1 - \sum_{i=0}^{3} \binom{10}{i} 0{,}3^i \cdot 0{,}7^{10-i} \\ &= 1 - (0{,}0282475 + 0{,}121061 + 0{,}233474 + 0{,}266828) \\ &= 1 - 0{,}649611 \\ &= 0{,}350389 \end{aligned}$$

Por otra parte, la idea de que el 30 % de las bicicletas nuevas presentan defectos es solo una estimación del encargado de calidad de la tienda. Supongamos que se eligen 10 bicicletas de forma aleatoria y resulta que 6 presentan defectos. ¿Qué implica esto respecto de la estimación inicial?

La pregunta que debemos hacernos es: ¿es consistente con la estimación de que el 30 % de las bicicletas presentan defectos? Para responder, podemos calcular la probabilidad de obtener al menos 6 defectuosas en 10 bicicletas, bajo la suposición de que

la proporción real es de 30 %.

$$\begin{aligned} \mathrm{P}(X \geq 6) &= \sum_{i=6}^{10} \binom{10}{i} 0{,}3^i \cdot 0{,}7^{10-i} \\ &= 0{,}0367569 + 0{,}00900169 + 0{,}0014467 + 0{,}000137781 + 5{,}9049 \times 10^{-6} \\ &= 0{,}047349 \approx 5\,\% \end{aligned}$$

Es poco probable que encontremos 6 bicicletas malas dado que la conjetura es cierta, es decir, que el 30 % de las bicicletas están malas. Esto sugiere que el problema es más grave.

4.4 Distribución geométrica

Como vimos antes, la distribución geométrica modela la probabilidad de obtener el primer éxito en el intento número n. Tenemos que tener ojo aquí: la variable aleatoria ahora es el número de intentos, lo que en la binomial estaba fijo.

No cuesta mucho encontrar la función de masa. Si nuestro primer intento exitoso es el intento n, eso quiere decir que los primeros $n-1$ intentos fueron fracasos. Por lo tanto,

$$\mathrm{Geom}(n, p) = pq^{n-1}.$$

Podemos calcular la probabilidad acumulada

$$\begin{aligned} P(X \leq n) &= \sum_{i=1}^{n} pq^{i-1} \\ &= p \sum_{i=1}^{n} q^{i-1} \\ &= p \sum_{i=0}^{n-1} q^{i} \\ &= p \frac{q^n - 1}{q - 1} \\ &= p \frac{(1-p)^n - 1}{(1-p) - 1} \\ &= 1 - (1-p)^n \end{aligned}$$

aunque en vez de haber calculado, podríamos haber pensado en lo siguiente: la probabilidad de obtener el primer éxito al menos en el intento n es

$$(1-p)^{n-1}$$

porque no hubo ningún éxito en los primeros $n-1$ intentos. Por lo tanto

$$\mathrm{P}(X \geq n) = (1-p)^{n-1}$$

y entonces

$$\mathrm{P}(X \leq n) = 1 - \mathrm{P}(X \geq n+1) = 1 - (1-p)^n.$$

Podemos calcular la esperanza

$$\begin{aligned}
\mathrm{E}(X) &= \sum_{i=1}^{\infty} i p q^{i-1} \\
&= p \sum_{i=1}^{\infty} i(1-p)^{i-1} \\
&= p\left(\frac{d}{dp} \sum_{i=1}^{\infty} (1-p)^i\right) \\
&= p\left(\frac{d}{dp} \frac{1-p}{p}\right) \\
&= p\left(\frac{d}{dp}\left(1 - \frac{1}{p}\right)\right) \\
&= p\frac{1}{p^2} \\
&= \frac{1}{p}
\end{aligned}$$

La varianza de una distribución geométrica es

$$\mathrm{Var}(X) = \frac{1-p}{p^2}.$$

¿Cómo se ve la distribución geométrica? Hagamos el mismo ejercicio de antes, con algunos parámetros distintos. En la Figura 4.4 vemos la distribución geométrica para varios valores de p. Vemos que, a medida que p aumenta, la distribución se concentra más en los primeros valores de k, es decir, la probabilidad de obtener un primer éxito "rápido" es mayor.

Además, no cuesta mucho notar la similaridad de este gráfico con los de funciones del estilo a/b^x. De ahí viene el nombre de geométrica.

Hay autores que definen la distribución geométrica no como el número de intentos para el primer éxito, si no como el número de fracasos antes del primer

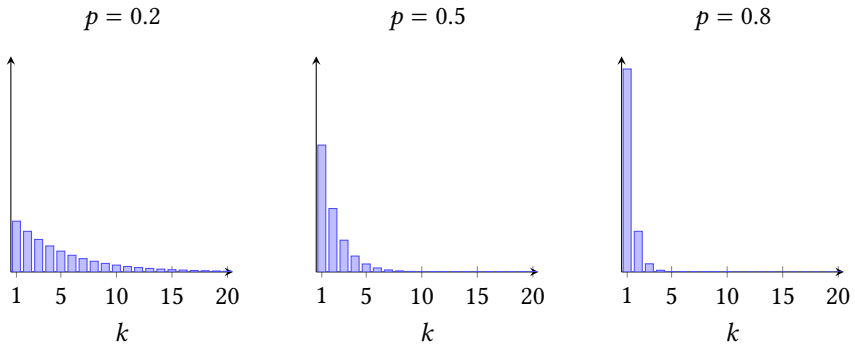


Figura 4.4: Distribución geométrica con distintos p.

éxito. No cuesta mucho ver que estas dos definiciones son equivalentes, pero con la definición que usamos acá la VA está definida para $x = 1, 2, 3, \ldots$ mientras que con esta otra definición la VA está definida para $x = 0, 1, 2, \ldots$. Python usa la definición que usamos nosotros (usando la librería NumPy), mientras que R y Mathematica usan la definición con el número de fracasos.

4.5 Distribución binomial negativa

Una distribución binomial negativa es una generalización de la distribución geométrica. La diferencia es que, en vez de esperar el primer éxito, esperamos obtener un número k de éxitos. A diferencia de la binomial, donde el número de intentos era fijo, aquí repetiremos los experimentos hasta obtener el número deseado de intentos. La distribución geométrica, por lo tanto, es un caso particular cuando $k = 1$.

Al igual que la geométrica, podemos definirla de una forma alternativa: como el número de fracasos

antes de obtener k éxitos. Nos quedaremos en este texto con la definición del párrafo anterior.

Para encontrar la función de masa de probabilidad, pensemos que nuestro número de éxitos k y la probabilidad de éxito de cada intento son parámetros de nuestra distribución. Si tuvimos que hacer n intentos, entonces la probabilidad de obtener k éxitos *de una forma particular* es

$$p^k q^{n-k}.$$

Pero, además, tenemos que obtener el último de nuestros k éxitos en el intento n. Por lo tanto, podemos repartir $k-1$ éxitos en $n-1$ intentos. Como no importa el orden, tenemos

$$\binom{n-1}{k-1}$$

maneras de hacerlo. Por lo tanto, si $X \sim \text{NegBin}(k, p)$ tenemos

$$P(X = n) = \binom{n-1}{k-1} p^k q^{n-k}.$$

Podemos entender la distribución binomial negativa como una suma de distribuciones geométricas independientes. En efecto, nuestra situación es algo como

$$\underbrace{FFFFE}_{\text{geom}}\underbrace{FFFFFFFE}_{\text{geom}}\underbrace{\cdots E}_{\text{geoms}}\underbrace{FFE}_{\text{geom}}$$

por lo que si $X \sim \text{NegBin}(k, p)$ entonces

$$X = X_1 + X_2 + \cdots + X_k$$

con cada $X_i \sim \text{Geom}(p)$. Esto hace muy fácil el cálcu-

lo de la esperanza y la varianza:

$$\mathrm{E}(X) = k\frac{1}{p}$$
$$\mathrm{Var}(X) = k\frac{1-p}{p^2}$$

Por ejemplo, un encuestador telefónico puede terminar su jornada cuando ha completado veinte encuestas. El problema es que la probabilidad que alguien complete la encuesta es baja, digamos 0,2. ¿Cuál será la probabilidad que logre completar sus encuestas cuando ha llamado a 50 personas?

Tenemos aquí que X, el número de intentos para completar 20 encuestas, sigue una distribución binomial negativa,

$$X \sim \mathrm{NegBin}(20; 0{,}2).$$

Queremos encontrar

$$P(X = 50)$$

y para eso no necesitamos hacer nada más que

$$P(X = 50) = \binom{49}{19} 0{,}2^{20} \cdot 0{,}8^{30} = 0{,}000245$$

lo que es bastante bajo. ¿Por qué? Si calculamos la esperanza,

$$E(X) = 20\frac{1}{0{,}2} = 100.$$

Parece que el encuestador va a tener que hacer muchas llamadas antes de poder terminar la jornada.

4.6 Distribución hipergeométrica

Así como la distribución binomial representa la probabilidad de obtener k éxitos en n intentos *con independencia entre cada intento,* podemos calcular pero sin suponer independencia. En otras palabras, la distribución binomial saca pelotas de cajas *con reposición* y ahora vamos a sacar las pelotas de la caja *sin reposición.*

Volvamos un poco a nuestra infancia y supongamos que luego de una piñata, nos quedamos con 9 dulces, de los que 4 son con sabor a manzana. Los papás nos dejan sacar 3 dulces a la vez. ¿Cuál será la probabilidad de sacar exactamente 2 dulces de manzana?

Para sacar 3 dulces de 9 tenemos $\binom{9}{3}$ formas y necesitamos 2 dulces de manzana de 4, lo que da $\binom{4}{2}$ formas, mientras que de los otros cinco dulces, necesitamos uno de ellos, que podemos escoger de $\binom{5}{1}$ formas. Por lo tanto,

$$\mathrm{P}(X = 2) = \frac{\binom{4}{2}\binom{5}{1}}{\binom{9}{3}}$$

Extrapolando de este ejemplo, diremos que la VA X, la cantidad de éxitos que obtenemos al sacar n elementos de una bolsa con N elementos, de los que r son éxitos y lo hacemos sin reemplazo sigue una distribución de probabilidad hipergeométrica: $X \sim \mathrm{Hip}(N, r, n)$ cuya función de masa viene dada por

$$\mathrm{P}(X = x) = \frac{\binom{r}{x}\binom{N-r}{n-x}}{\binom{N}{n}}, 0 \leq x \leq r, 0 \leq n - x \leq N - r.$$

La esperanza de esta distribución viene dada por

$$\mathrm{E}(X) = n\frac{r}{N}.$$

mientras que la varianza viene dada por

$$\mathrm{Var}(X) = n\frac{r}{N}\frac{N-r}{N-1}.$$

4.7 Distribución de Poisson

La distribución de Poisson es una de esas ideas que, siendo simple en la superficie, tiene conexiones profundas con otras áreas. Una manera de llegar a ella es definiendo un *proceso de Poisson*. Un proceso de Poisson es un proceso estocástico (una sucesión de variables aleatorias) indexadas por $t \in \mathbb{R}_0^+$, de manera que $X(t)$ es la cantidad de sucesos que ocurre en el intervalo $[0, t]$ que cumple las siguientes condiciones:

1. Los eventos ocurren de manera independiente entre sí.
2. La tasa promedio de ocurrencia de eventos es constante en el tiempo.
3. La probabilidad de que ocurran dos o más eventos en un intervalo de tiempo infinitesimal es despreciable.
4. En el tiempo 0, no ha ocurrido ningún evento: $X(0) = 0$.

De un proceso de este tipo emergen dos VAs, el tiempo entre eventos (que estudiaremos más adelante) y la cantidad de eventos en un periodo dado. Esta última VA sigue una distribución de probabilidad de Poisson.

El punto 2 es importante: si la tasa de eventos es constante en el tiempo, ese será nuestro parámetro. Es un parámetro un poco exótico, si lo pensamos bien. Por ejemplo, una tasa constante en el tiempo

es 5 eventos *por hora*. Es decir, hay un espacio de tiempo en que estos eventos ocurren.[4]

4: un ejercicio favorito es decir "si ocurren en promedio 5 eventos por hora, ¿cuál es la probabilidad de que ocurran 100 en un día?" lo que implica ajustar el parámetro.

La función de masa de probabilidad se puede derivar desde la de la distribución binomial (!). En efecto, un proceso de Poisson corresponde al límite cuando mantenemos una relación constante entre n, el número de eventos, y p, la probabilidad de éxito. Si $\lambda = np$, tomando el límite

$$\lim_{n\to\infty} \text{Bin}\left(n, \frac{\lambda}{n}\right)$$

obtenemos una nueva distribución. Esta es la distribución de Poisson con parámetro λ

$$X \sim \text{Poi}(\lambda).$$

La función de masa de probabilidad viene dada por

$$\text{P}(X = x) = \frac{\lambda^x}{x!} e^{-\lambda}.$$

Su esperanza es λ y su varianza también es λ.

Podemos calcular la esperanza como sigue

$$\begin{aligned}
\text{E}(X) &= \sum_{x=0}^{\infty} x \frac{\lambda^x}{x!} e^{-\lambda} \\
&= \sum_{x=1}^{\infty} \frac{\lambda^x}{(x-1)!} e^{-\lambda} \\
&= \sum_{x=1}^{\infty} \lambda \frac{\lambda^{x-1}}{(x-1)!} e^{-\lambda} \\
&= \lambda \sum_{x=1}^{\infty} \frac{\lambda^{x-1}}{(x-1)!} e^{-\lambda}
\end{aligned}$$

pero esta última expresión no es más que reescribir la suma de la función de masa a través de todo el dominio

$$= \lambda \cdot 1 = \lambda$$

Para calcular la varianza, podemos notar que

$$\mathrm{E}\left(X^2\right) = \mathrm{E}\left(X(X-1)\right) + \mathrm{E}\left(X\right)$$

por la linealidad de la esperanza. Además,

$$\begin{aligned}\mathrm{E}\left(X(X-1)\right) &= \sum_{x=0}^{\infty} x(x-1)\frac{\lambda^x}{x!}e^{\lambda} \\ &= \sum_{x=2}^{\infty} \frac{\lambda^x}{(x-2)!}e^{\lambda} \\ &= \lambda^2 \sum_{x=2}^{\infty} \frac{\lambda^{x-2}}{(x-2)!}e^{\lambda}\end{aligned}$$

pero por el mismo argumento anterior

$$= \lambda^2$$

Por lo tanto, $\mathrm{E}\left(X(X-1)\right) + \mathrm{E}\left(X\right) = \lambda^2 + \lambda$ y entonces

$$\mathrm{Var}\left(X\right) = \mathrm{E}\left(X^2\right) - \mathrm{E}\left(X\right)^2 = \mathrm{E}\left(X(X-1)\right) + \mathrm{E}\left(X\right) - \mathrm{E}\left(X\right)^2 = \lambda^2 + \lambda - \lambda^2 = \lambda$$

Supongamos que en Santiago nacen dos guaguas cada media hora. ¿Cuál será la cantidad esperada de guaguas que nazcan en un día? ¿Y qué probabilidad habrá de que en una hora nazcan 6?

Para responder la primera pregunta, debemos encontrar *el parámetro que corresponde.* En principio λ es 2, pero eso es *cada media hora.* Por lo tanto,

$$\frac{2 \text{ nacimientos}}{1 \text{ media hora}} \cdot \frac{48 \text{ medias horas}}{1 \text{ día}} = 96 \frac{\text{nacimientos}}{\text{día}},$$

por lo que esperamos 96 nacimientos en un día.

Del mismo modo, no cuesta ver que $\lambda = 4$ nacimientos por hora. Por lo tanto, la probabilidad de que en una hora nazcan 6 guaguas es

$$P(X = 6) = \frac{4^6}{6!}e^{-4} = \frac{4096}{720}0{,}0183156389 = 5{,}6888888889 \cdot 0{,}0183156389 = 0{,}1041956346.$$

Casi que por definición, si tenemos dos variables aleatorias independientes X e Y que siguen una distribución de Poisson

$$X \sim \text{Poi}(\lambda_1), \quad Y \sim \text{Poi}(\lambda_2)$$

entonces su suma también seguirá una distribución de Poisson

$$X + Y \sim \text{Poi}(\lambda_1 + \lambda_2).$$

Por ejemplo, si X es el número de guaguas nacidas en Santiago, con $\lambda_1 = 4$ guaguas por hora, e Y es el número de guaguas nacidas en Curicó, con $\lambda_2 = 1$ guagua por hora, es relativamente fácil imaginar que esperamos 5 guaguas nacidas por hora entre Santiago y Curicó.

Un proceso de Poisson no solamente ocurre a través del tiempo. Podemos imaginarlo también en extensiones de largo, de área, etc. Por ejemplo, podríamos pensar en fallas a través de una tubería, con un número promedio constante de fallas por kilómetro o mutaciones a lo largo de un cromosoma. También podríamos pensar en píxeles muertos en una pantalla o impactos de granito por metro cuadrado en un techo. Habría que verificar si estos ejemplos siguen un proceso de Poisson, pero al menos intuitivamente pareciera que sí.