Apuntes de Probabilidad y Estadística

Álvaro Mattus Donaire

27 de abril de 2026

Notas personales

Índice general

Índice general **ii**

1 ¿Qué probabilidad hay? 1
1.1 Introducción . . . 1
1.2 Eventos, espacios muestrales y probabilidad . . . 3
1.3 Probabilidad condicional . . . 4
1.4 Principio multiplicativo . . . 5
1.5 Independencia . . . 7
1.6 Principio aditivo . . . 9
1.7 Preguntas frecuentes . . . 13
1.7.1 Una nota sobre visualización de eventos . . . 14
1.8 Conteo . . . 16
1.8.1 Permutaciones . . . 18
1.8.2 Combinaciones . . . 19
1.8.3 Algunos casos extra . . . 20

2 Probabilidades++ 23
2.1 Axiomas de probabilidad . . . 23
2.2 Teorema de Bayes . . . 24
2.2.1 Enfermedades y exámenes . . . 29
2.2.2 Odds . . . 31

3 ¡Resultados! ¡Resultados! ¡Resultados! 34
3.1 Introducción . . . 34
3.2 Variables aleatorias discretas . . . 37
3.3 Variables aleatorias continuas . . . 39
3.4 Esperanza y varianza . . . 40
3.4.1 Definición de la esperanza y sus propiedades . . . 40
3.4.2 Definición de la varianza y sus propiedades . . . 45
3.5 ¿Qué significa sumar variables aleatorias? (opcional) . . . 48

4 El zoológico de las variables aleatorias, parte 1 54
4.1 Distribución de Bernoulli . . . 54
4.2 Variables aleatorias discretas y su relación con VAs Bernoulli 56
4.3 Distribución binomial . . . 59

4.4 Distribución geométrica 63
4.4.1 Otra forma de escribir la distribución geométrica . . 66
4.5 Distribución binomial negativa 67
4.6 Distribución hipergeométrica 70
4.7 Distribución de Poisson 71

5 El zoológico de las variables aleatorias, parte 2 75
5.1 Distribución uniforme 75
5.2 Distribución exponencial 78
5.3 Distribución normal 82
5.3.1 Trabajando con la distribución normal 85
5.3.2 Tablas para la distribución normal estándar 88
5.4 Distribución χ^2 92
5.5 Distribución *t* 94

6 ¿Qué dicen los datos? 97
6.1 Señal versus ruido 98
6.2 Encontrando señales: las medidas de tendencia central . . . 98
6.3 Midiendo el ruido: las medidas de dispersión 102
6.3.1 El rango 103
6.3.2 La desviación media absoluta 104
6.3.3 La varianza y la desviación estándar 105

7 La muestra y la población 107
7.1 La ley de los grandes números 107
7.2 Teorema del límite central 109
7.3 Distribuciones muestrales 111
7.3.1 Distribución muestral de la media muestral 111
7.3.2 Distribución muestral de la proporción muestral . . 111
7.3.3 La distribución muestral de la media muestral para poblaciones de varianza desconocida 112
7.3.4 Distribución muestral de la varianza muestral 113

8 El arte de estimar 117
8.1 ¿Qué hace que un estimador sea bueno? Error cuadrático medio y amigos 120
8.1.1 Cota de Cramér-Rao 122

9 ¿Qué tan seguros estamos? 123

¿Qué dicen los datos? 6

Idea central

Tenemos datos. ¿Qué podemos decir de ellos de manera honesta y útil? La estadística descriptiva busca resumir lo esencial de un conjunto de datos, distinguiendo la señal del ruido, sin distorsionar lo que realmente muestran.

Con este capítulo salimos de la parte puramente probabilística del curso para entrar en la parte estadística. ¿Cuál es la diferencia? Simplificando, probabilidad es un estudio matemático del azar, mientras que la estadística nace anclada en la realidad. Por supuesto, a lo largo del tiempo la estadística y la matemática se han nutrido e influenciado, pero no son necesariamente lo mismo y la manera de pensarlas tampoco.

En particular, el problema de la estadística descriptiva es uno muy simple: ¿Qué puedo decir de un montón de datos? Como dice el nombre, ¿cómo puedo describir lo que les pasa?

Para empezar, en un trabajo real de estadística tendríamos que *limpiar* los datos. Nuestras bases de datos, incluso si las recogemos nosotros mismos, nunca serán perfectas. Siempre pasará que habrá datos faltantes, datos en formato incorrecto, etc. Limpiar los datos quiere decir tomar decisiones sobre qué hacer con los datos "erróneos" que tenemos. Si bien es parte importante del proceso, por ahora nos concentraremos en datos ya limpios.

6.1 Señal versus ruido

Una interpretación fundamental que podemos hacer de los datos es la de *señal versus ruido.* Muchas veces nuestros datos vienen generados por un proceso, por ejemplo el testeo del tiempo de vida útil de un material, el tiempo de llegada de paquetes en una red, etc. A partir de esos resultados, nos gustaría saber *cuál es la señal,* es decir, cuál es el patrón que está detrás de esos datos. Al mismo tiempo, también hay un cierto *ruido,* es decir las diferencias de nuestra supuesta señal real con los resultados que obtenemos.

Por ejemplo, podemos pesar diez veces una pelotita y obtenemos los siguientes resultados

24,83	24,91	24,78	24,86	24,94
24,80	24,88	24,76	24,92	24,85

Tabla 6.1: Mediciones del peso de una pelotita de goma

Es claro que la pelota tiene siempre la misma masa: esa es la señal. El problema es que cada resultado que obtenemos es una combinación de esa señal junto con un cierto nivel de ruido. Tenemos que aceptar que nunca lograremos saber la masa real de la pelota, pero tampoco lo necesitamos: nos basta una buena aproximación.

6.2 Encontrando señales: las medidas de tendencia central

Una idea relativamente razonable es que la señal se encuentra "al medio" de los datos. La pregunta es cómo encontrar ese medio. Algunas alternativas:

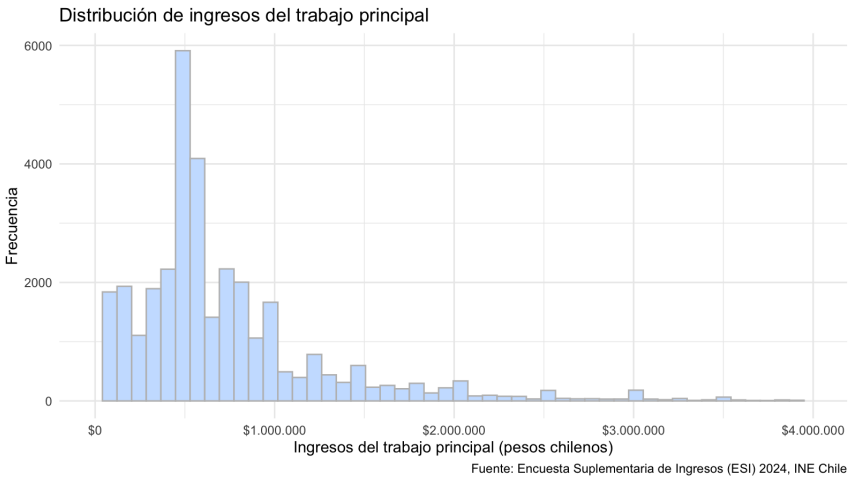


Figura 6.1: Distribución del ingreso.

Media aritmética También conocida como promedio. Todos lo conocemos.

Mediana Ordenando los datos de menor a mayor, el dato que queda al medio.

Moda El dato más frecuente.

Esas tres alternativas son las clásicas. No son las únicas y cada una de ellas tiene pros y contras. Para entenderlos, veamos un caso real.

El gráfico (Figura 6.1) muestra una parte de la distribución de los ingresos en Chile. Antes de intentar hacer algún cálculo, podemos notar algunas cosas. Por ejemplo, la mayor parte de la gente gana menos de $1.000.000. Asimismo, hay gente que gana *mucha* plata.

Ahora marquemos la media (aritmética), la mediana y la moda (Figura 6.2).

¿Cuáles son las diferencias? Podemos observar que la media se separa de las otras dos medidas. La razón es que la media es sensible a valores extremos. Las pocas personas que ganan muchos millones de

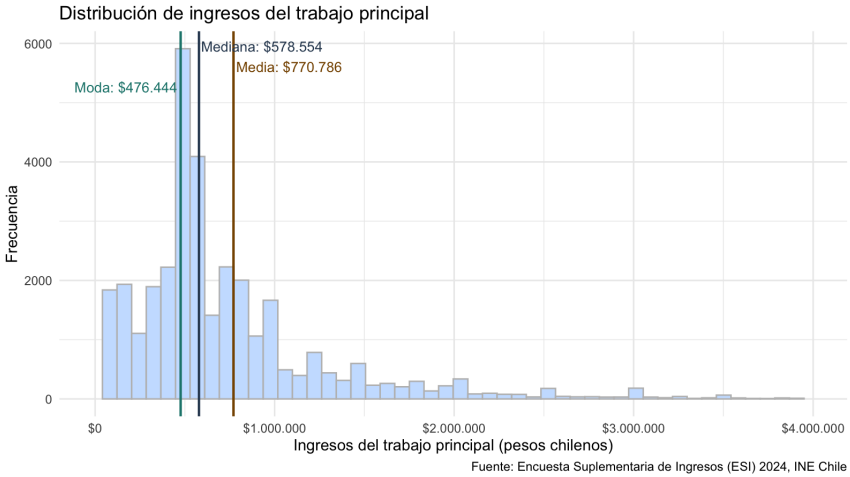


Figura 6.2: Distribución del ingreso anotada.

pesos "se llevan" la media hacia la derecha, aunque sean una minoría. La mediana, en cambio, no se ve afectada por las personas muy millonarias: solo le importa quién queda al medio de la distribución. La moda, por otra parte, sólo se preocupa de quién se repite más.

Por otra parte, la media necesita un cálculo realmente fácil y además,

$$\frac{x_1 + x_2 + x_3 + \cdots + x_n}{n}$$

es derivable para cada x_i. Por otra parte, ¿cuál es la fórmula (general) para la mediana? Suena a difícil. Lo mismo con la moda. Además, la mediana y la moda no tienen realmente en cuenta a todos los datos, como la media.

Como norma general, conviene escoger la media para describir. La excepción es una distribución que presente una gran asimetría, lo que se puede calcular con una medida como el *coeficiente de asimetría* (aptly named) o mediante inspección de un gráfico.

Tabla 6.2: Comparación de medidas de tendencia central

	Pros	Contras
Media	Usa toda la información de los datos. Fácil de calcular y de trabajar matemáticamente.	Sensible a valores extremos (*outliers*); puede dar una imagen distorsionada en distribuciones asimétricas.
Mediana	Robusta ante valores extremos. Representa bien el valor "típico" en distribuciones asimétricas.	Ignora la magnitud de los datos fuera del centro. No tiene una fórmula cerrada simple.
Moda	Funciona con datos categóricos. Útil cuando interesa el valor más frecuente.	Puede no ser única (distribuciones multimodales). Poco informativa en datos continuos.

El caso de los sueldos es ilustrativo de un conjunto de datos *muy* asimétrico. En casos como estos, es más honesto usar la mediana. La moda, como norma general, presenta menos interés. La Tabla 6.2 muestra un resumen de los pros y contras de cada medida.

Nótese que el párrafo anterior dice "más *honesto* usar la mediana." No es una obligación, si no que una medida wque representa mejor los datos. Podemos imaginar a un corredor de propiedades un poco tramposo que nos quiera convencer que el vecindario donde estamos viendo un departamento es muy bueno diciendo "el promedio de los sueldos es

de 2 millones de pesos." Para desarmarlo, habría que contrapreguntar "¿y la mediana?"

Hay que hacer una diferencia entre *qué es* la media, mediana o moda y *cómo se calculan.* La media es el número que, si lo reemplazo en cada dato, me da el mismo resultado al sumar. En otras palabras, si reemplazo cada dato por la media, la suma total no cambia.

La mediana, por otra parte, no funciona así. Hay una diferencia entre la media y la mediana, y es que la media aparece como un objeto algebraico mientras que la mediana aparece como un objeto de orden. En ese sentido, lo que conserva la mediana es el orden. Por otra parte, la media c es el valor que minimiza

$$\sum_x (x-c)^2$$

mientras que la mediana es el valor c que minimiza

$$\sum_x |x-c|.$$

6.3 Midiendo el ruido: las medidas de dispersión

Supongamos que somos ayudantes de dos secciones y nos toca revisar un control. En una sección los puntajes tuvieron un promedio de 55 puntos y los puntajes estuvieron todos entre 50 y 60 puntos. En la otra, el promedio fue también 55 puntos, pero resulta que los alumnos sacaron o bien 10 puntos o bien 100 puntos.

¡Hey!

¿Cuál de las dos secciones les da más tranquilidad como ayudantes?

Naturalmente, las dos secciones para el promedio son exactamente iguales: 55 puntos. Sin embargo, nuestra intuición nos dice que las dos secciones probablemente son muy distintas.

Volviendo a la idea de señal versus ruido, la señal "general" ya fue capturada. Ahora necesitamos capturar a donde nos lleva el ruido. Mejor dicho, necesitamos medir cómo varían los datos. Para medir esa variación es conveniente que establezcamos alguna referencia. Como veremos, la primera medida nos muestra que no es obligatorio, pero tampoco nos cuenta mucho.

6.3.1 El rango

La medida más sencilla es el rango. El rango mide cuánto "espacio" ocupan nuestros datos.

Definición 6.3.1 (Rango) *Si $x_1, x_2, \ldots, x_n$ es un conjunto de datos, entonces el rango es*

$$\max_i x_i - \min_i x_i$$

El rango es muy fácil de calcular y además nos da una idea tremendamente rápida sobre cómo se portan nuestros datos. Por ejemplo, en el ejemplo de los puntajes el primer grupo tiene un rango de 10 puntos y el segundo grupo tiene un rango de 90 puntos.

Sin embargo, tampoco es muy descriptivo. Además, entra la idea de *outliers*. Por ejemplo si hubiera otro grupo donde todo el mundo sacó 40 puntos *excepto* un estudiante, que sacó 60, el rango sería 20 puntos, pero no parece que eso describa muy bien al grupo.

¿Por qué no es muy descriptivo el rango? Un problema conectado, pero más profundo que el de los

outliers, es que en realidad el rango sólo considera *dos* datos: el máximo y el mínimo. Los otros datos son como el arroz del almuerzo: sólo acompañamiento.

6.3.2 La desviación media absoluta

Una idea para solventar el problema anterior es que consideremos todos los datos. Para hacer eso, debemos pensar en un estándar para la desviación. Este estándar podría ser cualquiera de nuestras medidas de centro, la media, mediana o moda. La moda, como podría no existir o haber más de una, suele dejarse de lado. Se puede hacer una estadística muy interesante con la mediana, pero es *bastante* más difícil. La media funciona suficientemente bien y es fácil de calcular y es fácil calcular cosas alrededor de la media.

Uno de los problemas de la media, sin embargo, es que su centralidad viene de considerar *todos* los datos de manera que queda, por así decirlo, igualmente separada de todos. Explicándolo mejor, la media fue construida dando igual peso a cada dato. Por lo tanto, si yo considero las desviaciones de la media a cada dato

$$x_i - \mu$$

y las agregamos todas

$$\sum_{i=1}^{n}(x_i - \mu)$$

nos encontramos con que

$$\sum_{i=1}^{n}(x_i - \mu) = \sum_{i=1}^{n} x_i - n\mu$$

pero $n\mu$ es $x_1 + x_2 + \cdots + x_n$

$$= \sum_{i=1}^{n} x_i - (x_1 + x_2 + \cdots + x_n)$$
$$= 0$$

¡Hey!

¿Cómo podemos solventar ese problema?

Definición 6.3.2 (Desviación media absoluta) *Podemos solventar el problema usando la desviación media absoluta*

$$DMA = \frac{\sum |x_i - \mu|}{n}$$

pero no es necesariamente la mejor manera de solventar el problema. Just saying.

En la Tabla 6.3 podemos ver dos conjuntos de datos. Ambos tienen el mismo rango, pero no cuesta mucho ver (Figura 6.3) que el conjunto B tiene una distribución mucho más concentrada, salvo dos puntos extremos. El rango no refleja eso, pero la desviación media absoluta sí.

¿Entonces por qué no se usa más? Un gran problema: algebraicamente es incómodo. En particular, al aparecer un valor absoluto inmediatamente deja de ser derivable en 0. Además, no hay una buena relación con la suma de variables aleatorias. ¿Qué hacer?

6.3.3 La varianza y la desviación estándar

La idea es simple: necesitamos una manera de eliminar los signos que no traiga los problemas algebraicos del valor absoluto. Y hay una manera muy

Observación	Conjunto A	Conjunto B
1	2	2
2	18	44
3	27	46
4	35	48
5	44	50
6	56	50
7	65	52
8	73	54
9	82	56
10	98	98
Rango	96	96
Media	50	50
DMA	24,8	12,0

Tabla 6.3: Dos conjuntos con igual rango y media, pero distinta dispersión.

natural de hacerlo: elevar al cuadrado. Si $x_i - \mu$ puede ser negativo, $(x_i - \mu)^2$ es siempre no negativo, igual que $|x_i - \mu|$. Pero a diferencia del valor absoluto, el cuadrado es derivable en todas partes y se comporta mucho mejor matemáticamente.

Hay además una consecuencia que vale la pena notar: elevar al cuadrado *penaliza más los datos lejanos.* Un dato que está a 2 unidades de la media contribuye 4 a la suma; uno que está a 4 unidades contribuye 16. Eso es una decisión deliberada, no un capricho matemático: la varianza le dice al resumen "presta más atención a los extremos." Si se prefiriera no hacer eso, se usaría el valor absoluto. Si se prefiriera hacerlo aún más agresivamente, se elevaría al cubo o a la cuarta potencia. El cuadrado es el balance que resultó ser más manejable.

Sin embargo, elevar al cuadrado tiene un costo: las unidades cambian. Si los puntajes están en puntos, entonces $(x_i - \mu)^2$ está en *puntos al cuadrado.* La varianza, que promedia esas desviaciones al cuadrado, también está en puntos al cuadrado. Esto puede sonar extraño porque lo es: "puntos cuadrados" no

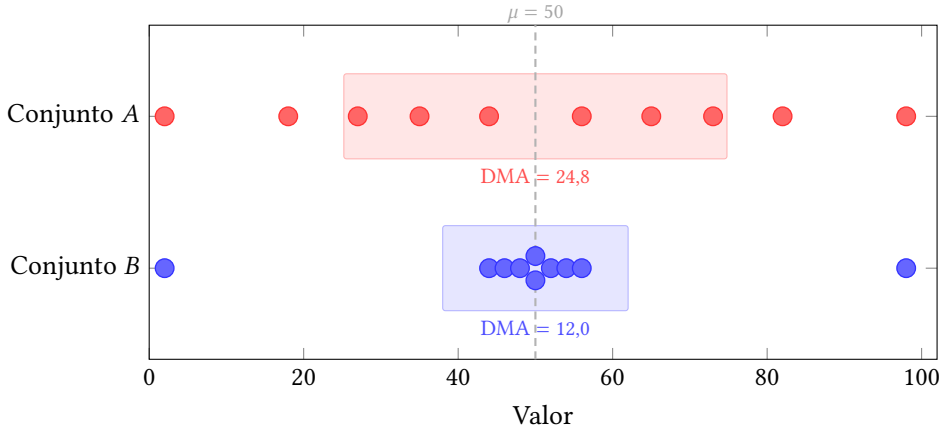


Figura 6.3: Dos conjuntos con igual rango y media ($\mu = 50,\ R = 96$) pero distinta dispersión. La banda sombreada representa $\mu \pm \text{DMA}$.

tiene un significado concreto en la realidad. La solución es obvia: sacar raíz cuadrada. Eso nos da la *desviación estándar,* que vuelve a estar en las mismas unidades que los datos originales y es, por eso mismo, la medida que más se usa en la práctica.

Definición 6.3.3 (Varianza poblacional) *Si $x_1, x_2, \ldots, x_N$ es una población completa con media μ, la varianza poblacional es*

$$\sigma^2 = \frac{1}{N}\sum_{i=1}^{N}(x_i - \mu)^2.$$

Definición 6.3.4 (Desviación estándar poblacional) *La desviación estándar poblacional es la raíz cuadrada de la varianza poblacional,*

$$\sigma = \sqrt{\sigma^2} = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(x_i - \mu)^2}.$$

Sus unidades son las mismas que las de los datos originales.

Volvamos a los dos grupos del comienzo de la sección (Tabla 6.3). Ya sabíamos que son muy distintos aunque compartan media y rango; ahora podemos medirlo con precisión.

Tabla 6.4: Cálculo paso a paso de la varianza poblacional ($\mu = 50$ en ambos casos).

Conjunto A			**Conjunto B**		
x_i	$x_i - \mu$	$(x_i - \mu)^2$	x_i	$x_i - \mu$	$(x_i - \mu)^2$
2	-48	2304	2	-48	2304
18	-32	1024	44	-6	36
27	-23	529	46	-4	16
35	-15	225	48	-2	4
44	-6	36	50	0	0
56	6	36	50	0	0
65	15	225	52	2	4
73	23	529	54	4	16
82	32	1024	56	6	36
98	48	2304	98	48	2304
	0	8236		0	4720

Dividiendo por $N = 10$ en cada caso:

$$\sigma_A^2 = \frac{8236}{10} = 823{,}6 \qquad \sigma_A \approx 28{,}7$$

$$\sigma_B^2 = \frac{4720}{10} = 472{,}0 \qquad \sigma_B \approx 21{,}7$$

El conjunto A tiene una desviación estándar casi un 32% mayor que el conjunto B. Nótese que ambos grupos comparten los mismos valores extremos (2 y 98), así que el cuadrado los penaliza por igual en ambos lados. La diferencia viene del interior: en B los ocho datos del centro están muy apretados cerca de 50, mientras que en A están esparcidos por todo el rango.

¿Qué significa ese número concretamente? La desviación estándar responde a la pregunta: *¿qué tan lejos se aleja un dato típico de la media?* Así, en el conjunto A un dato "normal" está a unas 29 unidades de la media; en el conjunto B, a unas 22. Como veremos en el capítulo sobre la distribución normal, cuando los datos siguen esa distribución aproximadamente el 68% cae dentro de un intervalo de una desviación estándar a cada lado de la media, y alrededor del 95% dentro de dos. Eso le da a σ un significado concreto incluso antes de saber la forma exacta de los datos.

Observación 6.3.1 La desviación estándar poblacional σ mide cuánto se alejan típicamente los datos de su media μ. Un dato a más de 2σ de la media es inusual; uno a más de 3σ, extraordinariamente raro.

Volvamos por un momento a la pelotita de goma del inicio del capítulo. Pesamos la pelota diez veces y obtuvimos diez resultados ligeramente distintos. Podemos escribir cada medición como

$$\text{medición} = \text{valor exacto} + \text{error de azar}.$$

El valor exacto es siempre el mismo: es la señal. El error de azar cambia en cada pesada: es el ruido. La media de las diez mediciones nos da una buena estimación del valor exacto. ¿Y la desviación estándar? No describe a la pelota, sino a la *balanza.* Una balanza precisa produce errores pequeños y una desviación estándar pequeña; una balanza de mala calidad produce errores grandes y una desviación estándar grande. Dos balanzas pueden dar exactamente el mismo promedio y, sin embargo, ser muy distintas en confiabilidad.

¡Hey!

Dos balanzas pesan la misma pelotita diez veces cada una. Ambas dan un promedio de 24,85 g*, pero la primera tiene una desviación estándar de* 0,01 g *y la segunda de* 0,30 g*. ¿Cuál usarías? ¿Cambiaría tu respuesta si supieras que la segunda cuesta diez veces menos?*

La dispersión no es el final del análisis: es el comienzo de la inferencia. En los capítulos que siguen veremos cómo estimar parámetros y construir intervalos de confianza; en ambos casos, σ volverá a aparecer como medida de la incertidumbre que arrastramos al trabajar con datos reales.

¿Cuándo es "grande" una desviación estándar? Depende de la escala. Una desviación de 5 kg en el peso de personas adultas es pequeña; la misma desviación en el peso de un ratón de laboratorio sería enorme. Para comparar dispersiones entre variables medidas en escalas distintas, se puede usar el *coeficiente de variación:*

$$CV = \frac{\sigma}{\mu} \times 100\%.$$

El CV expresa la desviación estándar como porcentaje de la media, lo que permite comparar, por ejemplo, cuán variable es el sueldo de los trabajadores de una empresa respecto a cuán variable es su estatura.

Consideremos los pesos de cinco saltamontes (en gramos) y cinco elefantes (en toneladas) de la Tabla 6.5. ¿Cuál de las dos especies es más variable?

Saltamontes (g)	Elefantes (t)
10,5	4,90
9,8	5,10
11,2	4,80
7,7	5,05
10,3	4,92

Tabla 6.5: Pesos de saltamontes (g) y elefantes (t).

Calculando:

$$\mu_S = 9{,}9\,\text{g} \qquad \sigma_S \approx 1{,}19\,\text{g} \qquad CV_S \approx 12{,}0\,\%$$

$$\mu_E = 4{,}954\,\text{t} \qquad \sigma_E = 0{,}108\,\text{t} \qquad CV_E \approx 2{,}2\,\%$$

En términos absolutos, $\sigma_E = 0{,}108\,\text{t} = 108\,\text{kg}$: los elefantes varían muchísimo más que los saltamontes. Pero eso no es sorprendente: los elefantes son animales enormes. La pregunta más interesante es cuánto varían *respecto a su propio tamaño.* Ahí el resultado se invierte: los saltamontes tienen un CV de 12 %, mientras que los elefantes tienen apenas 2,2 %. Relativo a lo que pesan, los elefantes son notablemente uniformes y los saltamontes bastante variables.