Apuntes de Probabilidad y Estadística

Álvaro Mattus Donaire

9 de mayo de 2026

Notas personales

Índice general

Índice general **ii**

1 ¿Qué probabilidad hay? 1
1.1 Introducción . . . 1
1.2 Eventos, espacios muestrales y probabilidad . . . 3
1.3 Probabilidad condicional . . . 4
1.4 Principio multiplicativo . . . 5
1.5 Independencia . . . 7
1.6 Principio aditivo . . . 9
1.7 Preguntas frecuentes . . . 13
1.7.1 Una nota sobre visualización de eventos . . . 14
1.8 Conteo . . . 16
1.8.1 Permutaciones . . . 18
1.8.2 Combinaciones . . . 19
1.8.3 Algunos casos extra . . . 20

2 Probabilidades++ 23
2.1 Axiomas de probabilidad . . . 23
2.2 Teorema de Bayes . . . 24
2.2.1 Enfermedades y exámenes . . . 29
2.2.2 Odds . . . 31

3 ¡Resultados! ¡Resultados! ¡Resultados! 34
3.1 Introducción . . . 34
3.2 Variables aleatorias discretas . . . 37
3.3 Variables aleatorias continuas . . . 39
3.4 Esperanza y varianza . . . 40
3.4.1 Definición de la esperanza y sus propiedades . . . 40
3.4.2 Definición de la varianza y sus propiedades . . . 45
3.5 ¿Qué significa sumar variables aleatorias? (opcional) . . . 48

4 El zoológico de las variables aleatorias, parte 1 54
4.1 Distribución de Bernoulli . . . 54
4.2 Variables aleatorias discretas y su relación con VAs Bernoulli 56
4.3 Distribución binomial . . . 59

4.4 Distribución geométrica 63
4.4.1 Otra forma de escribir la distribución geométrica . . 66
4.5 Distribución binomial negativa 67
4.6 Distribución hipergeométrica 70
4.7 Distribución de Poisson 71

5 El zoológico de las variables aleatorias, parte 2 75
5.1 Distribución uniforme 75
5.2 Distribución exponencial 78
5.3 Distribución normal 82
5.3.1 Trabajando con la distribución normal 85
5.3.2 Tablas para la distribución normal estándar 88
5.4 Distribución χ^2 92
5.5 Distribución *t* 94

6 ¿Qué dicen los datos? 97
6.1 Señal versus ruido 98
6.2 Encontrando señales: las medidas de tendencia central . . . 98
6.3 Midiendo el ruido: las medidas de dispersión 103
6.3.1 El rango 103
6.3.2 La desviación media absoluta 104
6.3.3 La varianza y la desviación estándar 107
6.3.4 Comparando dos grupos 110
6.4 Medidas de posición: orden y progreso 111
6.5 Gráficos 113
6.6 Software 115

7 E pluribus unum...duo, tres... 116
7.1 Población y muestra 116
7.2 La ley de los grandes números 118
7.3 Teorema del límite central 121
7.4 Distribuciones muestrales 123
7.4.1 Distribución muestral de la media muestral 123
7.4.2 Distribución muestral de la proporción muestral . . 124
7.4.3 La distribución muestral de la media muestral para poblaciones de varianza desconocida 125
7.4.4 Distribución muestral de la varianza muestral 126

8 El arte de estimar **126**
8.1 ¿Qué hace que un estimador sea bueno? Error cuadrático medio y amigos 129
8.1.1 Cota de Cramér-Rao 131

9 ¿Qué tan seguros estamos? **132**

E pluribus unum...duo, tres... 7

Idea central

Una muestra es una fracción del todo. ¿Cuál es la relación que hay entre la muestra y el todo y lo que podemos calcular a partir de cada uno?

7.1 Población y muestra

Una *población* es un grupo que queremos estudiar. Con cierta formalidad, podemos decir que la población es el grupo completo de unidades (personas, resultados de un experimento, etc.) que comparten una característica de interés, o una condición de interés.

Más formalmente, una población es el conjunto de todas las unidades de observación o resultados posibles sobre los que definen parámetros y de los que se puede obtener conclusiones (o se desea obtenerlas), sin importar si este conjunto se observa en la realidad o está solamente definido conceptualmente.[1]

1: Por ejemplo, nuestra población puede ser la producción de una serie de medicamentos y *técnicamente* la podemos conocer completa. Por otra parte, puede ser las personas que están en el país en un momento dado, como el censo, y es imposible conocerla 100 % completamente.

Por otra parte, una *muestra* es un subconjunto de la población. Este subconjunto finito de la población se escoge para medir la característica o condición de interés. A partir de esta muestra, podemos calcular distintos valores y, como veremos, podremos empezar a decir *suposiciones educadas* acerca de la población.

Si tenemos una muestra, al igual que calculábamos algunos parámetros de la población, como la media, desviación estándar y otros, también podemos calcularlos a partir de la muestra. En general, nos concentraremos en tres tipos de parámetro: la media, la varianza (y desviación estándar) y la proporción. Para diferenciarlos, en una muestra los llamaremos

estadístico o *estadígrafo* mientras que en la población los llamaremos *parámetros.* También para distinguirlos usaremos distintos signos.

Medida	Población	Muestra
Media	μ	$\overline{X}$
Varianza	σ^2	s^2
Proporción	p	$\hat{p}$

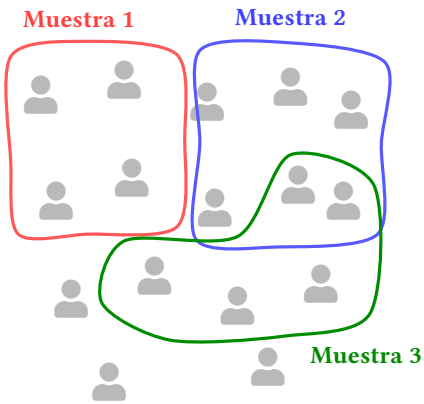


Figura 7.1: Tres muestras extraídas de la misma población.

El tema, como muestra la Figura 7.1, es que distintas muestras son posibles a partir de una misma población. Uno podría asumir que las tres muestras son parecidas, pero eso no es necesariamente cierto. Si las muestras son *aleatorias,* no hay nada que impida que, por azar, las tres muestras sean muy diferentes entre sí.

En particular, nada asegura que, por ejemplo, las medias $\overline{X_1}, \overline{X_2}, \overline{X_3}$, sean iguales. Lo que suponemos que siempre es igual es la media poblacional μ, pero la media de las distintas muestras no tiene por qué ser igual.

En otras palabras, como la muestra es *azarosa*, los cálculos que hacemos a partir de ella también son

azarosos: La media, varianza, proporción, etc., son variables aleatorias. Como buenas variables aleatorias, estas tienen una distribución de probabilidad. En este capítulo hablaremos sobre estas distribuciones de probabilidad, pero para ello necesitaremos dos teoremas principales: la ley de los grandes números y el teorema del límite central.

Para cerrar la introducción sobre las muestras, asumiremos en lo que viene que tenemos una población sobre la cual nos interesa una variable cuantitativa. Esta variable tiene una media μ y una varianza σ^2 finitas y además σ^2 es mayor que 0.

Una muestra es un conjunto de observaciones o mediciones $X_1, X_2, \dots X_n$ de la variable de interés hechas a partir de la población. Idealmente, la muestra es aleatoria, es decir, hecha completamente al azar. En términos matemáticos, para que esto se cumpla diremos que

1. Cada observación X_i es independiente de las otras.
2. Como vienen de una misma población, cada X_i comparte una misma distribución de probabilidad respecto a la variable de interés.

Abreviaremos esto diciendo que el conjunto $\{X_i\}_{i=1}^n$ es iid: independiente e idénticamente distribuido.

7.2 La ley de los grandes números

En la clase hicimos un pequeño experimento tirando una moneda diez veces. No recuerdo los resultados, pero en casa lo repetí veinte veces, es decir, lancé[2] diez veces una moneda veinte veces

2: simulé

Número de Caras	Frecuencia	Porcentaje (%)
1	1	5
2	1	5
3	1	5
4	6	30
5	7	35
6	3	15
7	1	5

La mayoría de los resultados están dentro del intervalo $[4, 6]$, lo que es más o menos esperable. Si nos metemos en el intervalo $[3, 7]$ ya están casi todos los resultados: sólo faltan dos.

Sin embargo, si hacemos el experimento 1000, 5000 o más veces la intuición nos dice que esa diferencia tenía que irse achicando, ¿no? Es decir, al hacer este lanzamiento mil veces, *ciertamente* casi todos los resultados darán 5 caras, asumiendo una moneda justa.

NO. Los resultados se muestran en la Figura 7.2. Siempre habrá resultados que "se escapan" de lo que se espera que debería pasar.



Figura 7.2: 1000 lanzamientos de 10 veces una moneda

¿Por qué no "colapsa" a 5 caras?

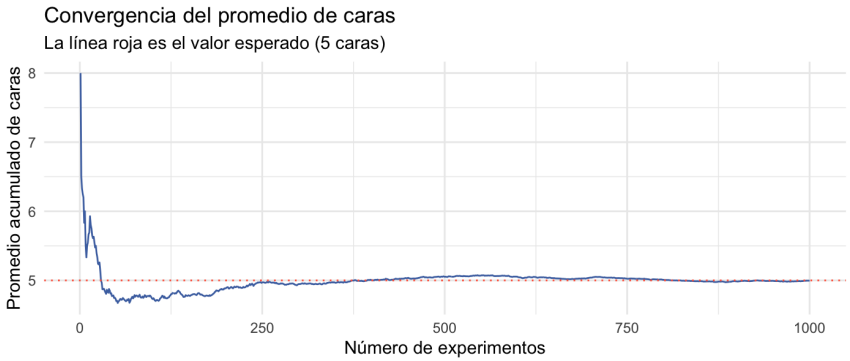


Figura 7.3: Promedio del número de caras a medida que aumenta el número de lanzamientos

Porque estamos pensando mal. Lo que colapsa no es el número de caras que obtenemos, si no que el promedio del número de caras. La Figura 7.3 muestra cómo va evolucionando el promedio de caras a medida que realizamos más lanzamientos.

Nuestra intuición no está tan errada, pero hay que afinarla. En general, cuando tenemos una suma (o promedio o conteo) tendremos que

$$\text{suma} = \text{valor esperado} + \text{error aleatorio}.$$

La pregunta es qué tan grande es ese error aleatorio. Hay una fórmula que nos permite establecer el tamaño de este error, llamado *error estándar*. Cuando contabilicemos la suma de las extracciones de una caja, con reposición, el error estándar de la suma es

$$\sqrt{\text{número de extracciones}} \cdot (\text{desviación estándar de la caja})$$

En otras palabras, el error *aumenta* a medida que repetimos nuestro experimento, de manera proporcional a la raíz del número de repeticiones. En ese sentido, nuestra intuición estaba completamente incorrecta. Sin embargo, si consideramos el prome-

dio

$$\frac{\sqrt{\text{número de extracciones}} \cdot (\text{SD de la caja})}{\text{número de extracciones}} = \frac{\text{SD de la caja}}{\sqrt{\text{número de extracciones}}}$$

y cuando el número de extracciones crece, el error estándar decrece.

Esta idea está representada en la *ley de los grandes números*. Hay varias versiones de esta ley, pero todas son teoremas que hablan de la convergencia de una serie de variables aleatorias.

Si $X_1, X_2, \cdots, X_n$ son variables aleatorias independientes e idénticamente distribuidas, con esperanza μ y varianza σ^2 finitas, entonces la variable $\overline{X} = \sum_{i=1}^{n} X_i/n$ cumple que para todo $\varepsilon > 0$,

$$\lim_{n\to\infty} \mathrm{P}\left(|\overline{X} - \mu| \leq \varepsilon\right) = 1$$

Lo que dice este teorema es que, efectivamente, el promedio muestral converge hacia el promedio poblacional a medida que aumenta el tamaño de la muestra. Es posible que esa convergencia no ocurra, pero si la muestra es realmente azarosa, es lo que ocurrirá la mayor, muy mayor, parte del tiempo[3].

3: tan mayor que en realidad casi nunca no ocurre

7.3 Teorema del límite central

El teorema del límite central (o teorema central del límite) es quizás el resultado más importante en probabilidad. En cierta manera, es una continuación de la ley de los grandes números.

¡Hey!

Si tomara muchas muestras distintas de la misma población y calculara la media de cada una, ¿qué distribución cree que seguirían esas medias?

Si $X_1, X_2, \cdots, X_n$ son variables aleatorias independientes e idénticamente distribuidas, con esperanza μ y varianza σ^2 finitas (y la varianza mayor que 0), entonces la VA

$$Z_n = \frac{\overline{X} - \mu}{\sigma/\sqrt{n}}$$

converge en distribución a la normal estándar cuando n se va a infinito, es decir,

$$\lim_{n\to\infty} P(Z_n \leq x) = P(Z \leq x)$$

donde $Z \sim \mathcal{N}(0, 1)$.

Hay algunas cosas que decir. La primera es una observación menor. Si nos fijamos, la variable Z_n nos está diciendo el comportamiento de la media muestral. Mediante un truco algebraico bien conocido (amplificar por n) obtenemos lo siguiente

$$Z_n = \frac{\overline{X} - \mu}{\sigma/\sqrt{n}} = \frac{\sum_{i=1}^{n} X_i - n\mu}{\sqrt{n}\sigma}$$

y por lo tanto el teorema también nos cuenta acerca de la suma de las variables, lo que puede ser de utilidad.

Una segunda cosa es que si

$$\lim_{n\to\infty} Z_n = \mathcal{N}(0, 1)$$

(usando una notación un poco liberal), y recordamos qué es estandarizar una distribución normal, descubriremos que otra forma de enunciar el teorema es

$$\overline{X_n} \approx \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$$

(usando una idea todavía más liberal, porque estamos obviando el límite).

Un tercer punto es que, y esto es lo más increíble, el teorema no puso *ninguna* restricción a la distribu-

ción que siguen los X_i, salvo que tuvieran media y varianza finitas y varianza no nula además.

Por ejemplo, los X_i podrían provenir de una distribución de Bernoulli (éxito con probabilidad p, fracaso con probabilidad $1 - p$, como tirar una moneda). Si es así, $\mathrm{E}(X_i) = p$ y $\mathrm{Var}(X_i) = p(1 - p)$. Además, la variable

$$Y_n = X_1 + X_2 + \cdots + X_n$$

sigue una distribución binomial

$$Y_n \sim \mathrm{Bin}(n, p).$$

Por lo tanto,

$$Z_n = \frac{Yn - np}{\sqrt{np(1-p)}}$$

converge hacia una normal estándar.

7.4 Distribuciones muestrales

Las secciones anteriores nos llevan a un resultado: las distribuciones muestrales de la media muestral, la varianza muestral y la proporción muestral.

7.4.1 Distribución muestral de la media muestral

Básicamente, esta sección es reiterar lo dicho en la anterior. Gracias al teorema del límite central, sabemos que la media muestral sigue una distribución normal con media μ y desviación estándar $\sigma/\sqrt{n}$

$$\overline{X} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$$

o, equivalentemente, la variable

$$Z = \frac{\overline{X} - \mu}{\sigma/\sqrt{n}}$$

sigue una distribución normal estándar.

7.4.2 Distribución muestral de la proporción muestral

El teorema del límite central nos dice que la variable puede seguir, básicamente, cualquier distribución. En particular, podría seguir la distribución binomial.

Recordemos que la distribución binomial cuenta la cantidad de *éxitos* registrados dentro de n intentos. Por ejemplo, si estamos si alguien es zurdo o diestro, podemos usar la distribución binomial para ver la probabilidad de que 5 personas en nuestro curso de 37 sean zurdas.

Pero una forma equivalente es preguntarnos por la probabilidad de que la proporción de personas zurdas sea 5/37. En otras palabras, al dividir por la cantidad total obtenemos una nueva distribución binomial, pero esta vez con esperanza p y varianza pq.

En otras palabras, la proporción muestral $\hat{p}$ se distribuye según una distribución normal

$$\hat{p} \sim \mathcal{N}\left(p, \frac{pq}{n}\right)$$

o lo que es lo mismo, la variable

$$Z = \frac{\hat{p} - p}{\sqrt{pq/n}}$$

sigue una distribución normal estándar.

7.4.3 La distribución muestral de la media muestral para poblaciones de varianza desconocida

Volviendo a la media, hasta ahora hemos asumido algo un poco extraño: la varianza poblacional es conocida[4]. Esto es raro porque, si conocemos la media y la varianza poblacional, no tiene sentido que nos preocupemos por las muestras. Sin embargo, es donde estamos y pronto ya no conoceremos ninguna de las dos.

4: y que la media poblacional también es conocida

Por lo pronto, ¿qué pasa si no conocemos la varianza poblacional, es decir, si sólo tenemos la varianza muestral? Podemos aproximar la distribución de la media muestral, pero no podremos aproximarla mediante una normal.

Ese fue (parte d)el problema que trató de resolver William Sealy Gosset mientras trabajaba en la cervecería Guiness. En particular, le interesaba ver cómo podía resolver el problema de trabajar con muestras pequeñas. Su trabajo junto con Ronald Fisher[5] los llevó a postular la distribución t.

5: básicamente el padre de la estadística moderna

La distribución t_ν es una distribución que depende sólo de un parámetro: los grados de libertad (ν). La media siempre es 0 y la varianza es $\nu/(\nu-2)$ cuando $\nu > 2$.

Para trabajar con esta distribución debemos calcular el score T, de manera análoga a como lo hacíamos con la distribución normal

$$T = \frac{\overline{x} - \mu}{s/\sqrt{n}}$$

donde $\overline{x}$ es la media muestral, μ es la media poblacional, n es la cantidad de observaciones de la muestra

y s es la desviación estándar muestral definida por

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \overline{x}).$$

Este score T sigue entonces una distribución t con $n-1$ grados de libertad

$$T \sim \mathrm{t}_{n-1}\,.$$

7.4.4 Distribución muestral de la varianza muestral

Lamentablemente, el teorema del límite central no nos ayuda con la varianza en general. El TLC está definido para el promedio y se puede extender a otras ideas relacionadas con el promedio, como sumar o contar, pero la varianza con su suma de diferencias cuadradas no se presta bien para ser adoptada por el TLC. Por si acaso, recordemos que la varianza muestral viene dada por

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \overline{x})$$

Sin embargo, hay un caso especial y es cuando sabemos que la muestra proviene de una distribución normal. Supongamos que tenemos una muestra $X_1, X_2, \ldots, X_n$, es decir, n variables aleatorias independientes e idénticamente distribuidas según una distribución normal $\mathcal{N}\left(\mu, \sigma^2\right)$. Para cada X_i podemos estandarizarla y obtener $Z_i = (X_i - \mu)/\sigma$ y por lo tanto

$$\sum_{i=1}^{n}\left(\frac{X_i - \mu}{\sigma}\right)^2 = \sum_{i=1}^{n} Z_i^2 \sim \chi_n^2$$

por definición de la distribución χ_n^2.

¿Cómo podemos relacionar la media y varianza muestrales? Partamos por

$$\sum_{i=1}^{n}\left(\frac{X_i-\mu}{\sigma}\right)^2=\sum_{i=1}^{n}\left(\frac{\left(X_i-\overline{X}\right)+\left(\overline{X}-\mu\right)}{\sigma}\right)^2$$

consideremos el numerador

$$\sum_{i=1}^{n}\left(\left(X_i-\overline{X}\right)+\left(\overline{X}-\mu\right)\right)^2$$

expandamos el cuadrado

$$\begin{aligned}&=\sum_{i=1}^{n}\left(\left(X_i-\overline{X}\right)^2+2\left(X_i-\overline{X}\right)\left(\overline{X}-\mu\right)+\left(\overline{X}-\mu\right)^2\right)\\&=\sum_{i=1}^{n}\left(X_i-\overline{X}\right)^2+2\left(\overline{X}-\mu\right)\sum_{i=1}^{n}\left(X_i-\overline{X}\right)+n\left(\overline{X}-\mu\right)^2\end{aligned}$$

consideremos la segunda sumatoria: como es la suma de las diferencias en torno a la media, por propiedades de ésta se hace 0

$$\begin{aligned}&=\sum_{i=1}^{n}\left(X_i-\overline{X}\right)^2+2\left(\overline{X}-\mu\right)\cdot 0+n\left(\overline{X}-\mu\right)^2\\&=\sum_{i=1}^{n}\left(X_i-\overline{X}\right)^2+n\left(\overline{X}-\mu\right)^2\end{aligned}$$

y considerando la sumatoria restante, podemos ver que es s^2 multiplicado por $n-1$

$$=(n-1)\,s^2+n\left(\overline{X}-\mu\right)^2$$

para volver a lo original, debemos dividir por σ^2

$$\sum_{i=1}^{n}\left(\frac{X_i-\mu}{\sigma}\right)^2=\frac{(n-1)\,s^2}{\sigma^2}+\frac{n\left(\overline{X}-\mu\right)^2}{\sigma^2}$$

observemos el término de la derecha

$$\frac{n\left(\overline{X}-\mu\right)^2}{\sigma^2}=\frac{\left(\sqrt{n}\right)^2\left(\overline{X}-\mu\right)^2}{\sigma^2}=\left(\frac{\overline{X}-\mu}{\sigma/\sqrt{n}}\right)^2$$

por el TLC lo que está dentro del cuadrado sigue una distribución normal estándar y, al estar al cuadrado obtenemos

$$\left(\frac{\overline{X}-\mu}{\sigma/\sqrt{n}}\right)^2\sim\chi_1^2$$

como resumen, tenemos lo siguiente

$$\sum_{i=1}^{n}\left(\frac{X_i-\mu}{\sigma}\right)^2=\frac{(n-1)\,s^2}{\sigma^2}+\frac{n\left(\overline{X}-\mu\right)^2}{\sigma^2}$$

el término de la izquierda sigue una distribución χ_n^2 mientras que el último sumando de la derecha sigue una distribución χ_1^2

$$\sum_{i=1}^{n}\left(\frac{X_i-\mu}{\sigma}\right)^2\sim\chi_n^2\qquad\frac{n\left(\overline{X}-\mu\right)^2}{\sigma^2}\sim\chi_1^2$$

aquí tendremos que hacer un pequeño salto de fe: las distribuciones de la suma son independientes. Si esto es cierto (y lo es), entonces tenemos

$$\chi_n^2=\frac{(n-1)\,s^2}{\sigma^2}+\chi_1^2$$

y esto obliga a que

$$\frac{(n-1)\,s^2}{\sigma^2}\sim\chi_{n-1}^2$$